

第一章 介绍

优化的目标是为了“最大”和“最小”。比如对人类而言，最大的利益，最小的风险。对自然也是如此。很多自然系统能够稳定存在和它的能量最小状态密切相关。从数学角度看，最大和最小并无区别，统一般，我们用

$$\min_{x \in \Omega} f(x)$$

的形式来表示。这里 f 被称为目标函数 (objective function)， x 被称为变量 (variables)，它一般是一个向量。 Ω 表示 x 可以取值的范围，称为可行域 (feasible region)。

这里 f 和 Ω 的不同取法会导致完全不同性质的模型 (modeling)。比如，若 $\Omega \subseteq \mathbb{R}^n$ 是连续区域， f 在 Ω 上连续是一种典型的情况；而相对的，比如 Ω 是离散的点集，而 f 在这些离散的点上有定义 (自然不可能连续)。甚至 f 未必是确定的映射，它可能包含一个在 Ω 中分布的随机变量。这三种典型模型，分别被称为连续优化问题、组合优化问题和随机优化问题。它们的数学基础和理论体系完全不同，因此分别有三门不同的专业课程来讲授。我们这门课，只限第一种模型：连续优化问题的算法。

为了能胜任本课程的学习，你必须确保你已经具备了如下基础知识：

- 数学分析 (特别是微分学)
- 线性代数 (特别是线性空间、特征分解)
- 计算机编程基础 (任何一门语言)

如果你缺少以上特别是数学基础，我强烈建议你考虑一下调整你的课程选择。而本课程中的内容，将会在未来的绝大多数应用数学相关领域用到。

我们先进一步缩小讨论的范围，并建立符号体系。

例如:

$$\begin{cases} \min f(x) \\ \text{s.t. } C_i(x) = 0, i \in E \\ C_i(x) \geq 0, i \in I \end{cases}$$


② 的代数表示.

这里 s.t. 是 subject to 的缩写, 意味着 x 并非在 \mathbb{R}^n 的全空间取遍. 我们必须在一系列 $C_i(x) = 0$ 和 $C_i(x) \geq 0$ 规定的闭区域中寻找我们的能使 $f(x)$ 取得最小值的 x . 显然闭集对这种最小值的存在性是很重要的.

例如:

$$\begin{cases} \min f(x_1, x_2) = (x_1 - 2)^2 + (x_2 - 1)^2 \\ \text{s.t. } C_1: x_1^2 - x_2 \leq 0 \\ C_2: x_1 + x_2 \leq 2 \end{cases}$$

s.t. 约束的闭集, 称为可行域 (feasible region), 在此例中即加红色部分. 我们需要在可行域中寻找使目标函数 (object function) -



↙ (我们以后都默认用 x^* 表示优化问题的解 (solution))

取极小值的点 x^* . 此例中似乎看上去是蓝色的粗点. 在这里根据我们的约定, $E = \emptyset$, $I = \{1, 2\}$.

基本上所有我们感兴趣的优化模型都可以化为上面这种形式, 除了有时下标会用更复杂一些, 比如两个变化的整数 x_{ij} , $i, j \in \mathbb{Z}^+$. 或者我们求的不是极小 min 而是极大 max. 但后者很容易用 $-f$ 替换 f 使其变为 min 问题.

运输问题 (transportation problem) 的例子 = 一个公司有两个工厂 F_1 和 F_2 和 12 个门市 R_1, R_2, \dots, R_{12} . 每个工厂 F_i 的每周出货量是 a_i , 而每个门市 R_j 每周的需求是 b_j . 而从工厂 F_i 到门市 R_j 的单位运费是 c_{ij} . 请决定运输方案以满足所有要求并使总运输成本最低. 令从 F_i 到 R_j 的每周运量是 x_{ij} , 则

$$\begin{cases} \min & f(\{x_{ij}, i=1,2, j=1,2,\dots,12\}) \\ & = \sum_{i=1,2, j=1,2,\dots,12} c_{ij} x_{ij} \quad (\text{运输总成本}). \\ \text{s.t.} & \sum_{j=1}^{12} x_{ij} \leq a_i, \quad i=1,2 \quad (\text{每个工厂运到 12 个门市的总量}) \end{cases}$$

考虑这里的约束是

否合理? 是否可能

有其它可接受的设计?

$$\sum_{i=1}^2 x_{ij} \geq b_j, \quad j=1,2,\dots,12 \quad (\text{每个门市的每周获得总量})$$

$$x_{ij} \geq 0, \quad i=1,2, \quad j=1,2,\dots,12 \quad (\text{运量不得为负数})$$

上述模型的一个特点是目标函数和所有约束都是线性函数, 这样的模型也被称为线性规划. 它在实际生活中十分有用. (Linear programming)

连续和离散 (continuous and discrete) 优化 (optimization)

注意: 上述问题中, 我们的目标函数都是连续函数 (更多情况下还会要求连续可微). 若 x 不在 \mathbb{R} 中取值, 而是在 \mathbb{Z} 中取值, 则我们不再有连续性, 而问题也相应的变为整数规划 (integer programming).

比如在运输问题中, 我们运输的是某种固定单位的产品, 比如冰箱, 那么, 我们只能以整数为单位运输. 有别于连续优化问题, 这是一类离散优化问题. 这里我请大家仔细想一想连续性的本质, 尝试这两

连续和离散的本质区别。


类问题在算法选择上有什么本质不同。这里我提两个例子供大家参考：① 请寻找紫金山校区的最低点；② 此时此刻，我们班里谁身上现金最多。

约束 (constrained) 和无约束 (unconstrained) 优化。

若 s.t. 给定的可行域是全体 \mathbb{R}^n ，则此时我们可以无视 s.t.，这就是无约束优化问题，否则则是约束优化问题。当目标函数连续可微时，无约束优化问题立刻变为求 $\nabla f = 0$ 的非线性方程求根问题。而约束优化问题，我们一般要设法将其转为等价的无约束优化问题，例如 Lagrange 乘子法。我们前面已经看到了线性规划，若目标函数和约束中至少有一个非线性函数，则问题相应的被称为非线性规划 (nonlinear programming)。这个是我们这门课所重点讨论的。

局部 (local) 和全局 (global) 优化。

对于连续问题，一个邻域内的最优值被称为问题的局部最优解。而我们往往更关心的是全局最优解。当有多个局部最优解时，确定全局最优解是困难的，特别是当问题可行域十分复杂且目标函数变化剧烈时。尽管复杂的问题有其实际背景，但数学家们往往喜欢先挑软柿子捏。选出可行区域是凸集，且目标函数也是凸函数的问题。在这样的假设下，我们往往有一些很好的结论（尽管未必实际），比如有且仅有一个局部最优解，因此它必然也是全局最优。



随机 (stochastic) 和确定 (deterministic) 优化。


随机优化问题指目标函数中含有随机项或随机变量。这类问题往往有其实际背景，特别是金融领域。（一个有趣的结果是金融海啸）。尽管这个问题很热，我们在这个学期不会去碰它，但我们不排除会用一些随机和统计的算法。

优化算法 (algorithms)

优化算法一般是迭代算法。也即我们需要从一个初值 x_0 开始，构造一个序列 x_k ，使 $x_k \rightarrow x^*$ 。和大多数算法一样，我们在构造算法的时候要考虑：

- 鲁棒性 (或健壮性, Robustness), 问题对参数和初值要有一定的容忍性, 不能太敏感。
- 效率 (Efficiency), 用尽量少的内存, 用尽量少的机器时间。
- 精确性 (Accuracy), 数值解要有一定的精度。

上述三个要素必须结合在一起考虑, 单独追求其中一项是没有意义的。



凸性 (Convexity)


凸集: 称 $S \subseteq \mathbb{R}^n$ 是凸集, 若 S 中任意两点的连线也属于 S . 用公式表达, 则是

$$\forall x, y \in S, \text{ 有 } \alpha x + (1-\alpha)y \in S, \forall \alpha \in [0, 1].$$

凸函数: 称定义在凸集上的函数 f 是凸函数, 若定义域中任意两点, 它们像之间的连线都在 f 的图像之上. 用公式表达, 则是

$$\forall x, y \in S, \text{ 有 } f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y). \quad \forall \alpha \in [0, 1].$$

称 f 是凹的 (concave) 若 $-f$ 是凸的。




于是我们发现凸函数基本上就是一只碗的形状, 所以它的无约束优化具有全局最优解就很明显了。而有一类特殊的优化问题称为凸优化 (convex programming), 若:

i) 目标函数是凸函数;

ii) 等式 (equality) 约束函数 $C_i(\cdot)$, $i \in E$, 都是线性的;

ii) 不等式 (inequality) 约束函数 $C_i(x)$, $i \in I$, 都是凹的.
(ii)、iii) 说的其实是约束区域可以构成一个封闭的凸区域.)



二维凸函数示意.