

## 第2章 无约束优化基础

无约束优化的一般形式:


$$\min_{\vec{x} \in \mathbb{R}^n} f(\vec{x})$$

这里  $n \geq 1$ ,  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  是光滑函数 (smooth function), 光滑一般指有至少一阶的连续函数. 在很多实际情况, 我们没有  $f$  的全局表示形式, 而只有在一些离散点上, 如  $x_0, x_1, \dots$  的值, 而我们要根据这些信息来设计我们的算法.

例子: 我们在测量一个关于时间  $t$  的值  $y = y(t)$ , 我们测得了一些值:

$t$	$t_1$	$t_2$	$t_3$	$\dots$	$t_m$
$y$	$y_1$	$y_2$	$y_3$	$\dots$	$y_m$

表  $\Leftrightarrow$  图



根据这些数据的形状和规律, 我们猜测

$$y \approx \phi(t; \vec{x}) = x_1 + x_2 e^{-(x_3 - t)^2 / x_4} + x_5 \cos(x_6 \cdot t) \quad (\text{这个公式的给出是没道理讲的})$$

这里  $\phi$  是  $y$  的模型近似, 而  $\vec{x} = \{x_1, x_2, \dots, x_6\}$  是一组人为选取的参数.

现在我们试图找一组“最好”的  $\vec{x}$ , 使用  $\phi$  来计算  $y$  “尽可能”好. 也就是说, 我们希望

$$r_j(\vec{x}) = y_j - \phi(t_j; \vec{x}), \quad j = 1, 2, \dots, m \quad (\text{这个其实是误差}).$$

尽可能正负偏差都小. 这里有两种建模, 一种是

$$\min_{\vec{x} \in \mathbb{R}^6} f(\vec{x}) = \sum_{j=1}^m |r_j(\vec{x})| \quad \text{或} \quad \min_{\vec{x} \in \mathbb{R}^6} f(\vec{x}) = \sum_{j=1}^m r_j^2(\vec{x})$$

哪一种好? 倾向性是明显的, 后一个模型的  $f$  是光滑的, 而前一个不是. 因此后一个求解更容易. 事实上, 后一种模型是我们熟悉的, 它又叫非线性最小二乘 (nonlinear least-squares).

这个模型是一个无约束优化问题的特例。它显示了即使  $x$  的方量很少，这里  $n=6$ ，但目标函数的计算仍然可以非常昂贵，比如说  $m$  很大 ( $> 10^5$ ) 时。

假设对上述这样一个颇为复杂的问题，我们有了一个近似解  $x^* = (1.1, 0.01, 1.2, 1.5, 2.0, 1.5)$ ，而对应的  $f(x^*) = 0.34$ 。因为  $f$  总是大于零的，因此在一些（往往是大多数）指标上，实验观测值  $\phi_j$  和模型值  $\phi(t_j, x^*)$  之间是有误差的。于是在这种情况下，我们如何验证  $x^*$  确实就是  $f$  的一个最优解？（或者，它是否足够接近最优解？）为此，我们有必要仔细考虑一下什么是所谓的最优解，及其性质。

**解的定义。** 点  $\vec{x}^*$  是一个全局最优解，若  $\forall \vec{x} \in \mathbb{R}^n$ ,  $f(\vec{x}^*) \leq f(\vec{x})$ 。

**局部最优解的定义** 点  $\vec{x}^*$  是一个局部最优解，若存在  $\vec{x}^*$  的邻域  $N$ ，使  $f(\vec{x}^*) \leq f(\vec{x})$ ,  $\forall \vec{x} \in N$ 。（注意  $N$  是开集）。


有时上述定义也被称为弱 (weak) 局部最优解，它区别于强 (strong) 局部最优解，或者又称为严格 (strict) 局部最优解，定义为：点  $\vec{x}^*$  是一个严格局部最优解，若存在  $\vec{x}^*$  的邻域  $N$ ，使  $f(\vec{x}^*) < f(\vec{x})$ ,  $\forall \vec{x} \in N$  且  $\vec{x} \neq \vec{x}^*$ 。

例：对常 (constant) 函数  $f(x) = 2$ ，任一点  $x$  都是它的弱局部最优点。而对  $f(x) = (x-2)^4$ ， $x=2$  是它的严格局部最优点。

大家可能会有一个印象，严格局部最优点总是落在“山谷”底部，因此它们是孤立的 (isolated)。

(相邻域内有且仅有这一个局部最优点)

示意图



事实上, 这个印象是错误的. 例:

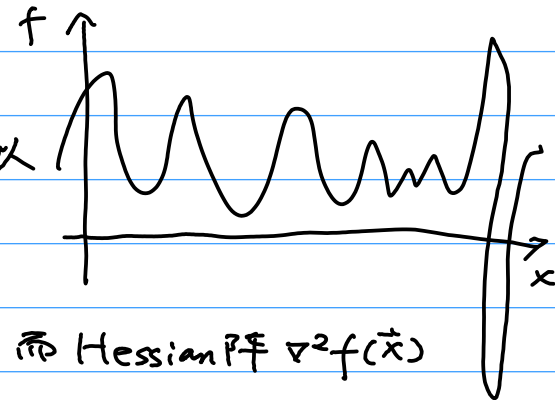
$$f(x) = x^4 \cos(1/x) + 2x^4, \quad f(0) = 0.$$

这个函数有二次连续导数, 有严格局部最优点  $x^* = 0$ . 但注意到  $\cos(1/x)$  在 0 附近无穷振荡, 因此在距 0 任意近的地方, 都有无穷多的严格局部最优点. (可 matlab 绘图).

于是我们有了一个理解, 多峰函数的全局极值的求解是困难的.

确定局部最小值 (minimum)

这里我们要充分利用光滑性, 比如当目标函数存在二阶连续导函数时, 我们可以考察最优点  $x^*$  处的梯度  $\nabla f(x^*)$  和 Hessian 阵  $\nabla^2 f(x^*)$  的性质.



注: 多元函数的梯度  $\nabla f(\vec{x})$  是一个向量, 它对应于一元函数的一阶导函数. 而 Hessian 阵  $\nabla^2 f(\vec{x})$  是一个矩阵, 对应于一元函数的二阶导函数.

例:  $f(x_1, x_2) = x_1^3 + 2x_1x_2 + x_2^3 + e^{x_1}$

$$\nabla f(x_1, x_2) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 3x_1^2 + 2x_2 + e^{x_1} \\ 2x_1 + 3x_2^2 \end{pmatrix} \quad \nabla^2 f(x_1, x_2) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{pmatrix} = \begin{pmatrix} 6x_1 + e^{x_1} & 2 \\ 2 & 6x_2 \end{pmatrix}$$

所有一阶偏导数形式

所有二阶偏导数形式

Taylor定理  $\hat{=} f: \mathbb{R}^n \rightarrow \mathbb{R}$  连续可微 (continuously differentiable),  $\vec{p} \in \mathbb{R}^n$ , 则存在  $t \in (0, 1)$ , 使

$$f(\vec{x} + \vec{p}) = f(\vec{x}) + \nabla f(\vec{x} + t\vec{p})^T \vec{p}.$$

特别地, 对于  $f$  二阶连续可微 (twice continuously differentiable), 存在  $t \in (0, 1)$ , 使

$$\nabla f(\vec{x} + \vec{p}) = \nabla f(\vec{x}) + \int_0^1 \nabla^2 f(\vec{x} + t\vec{p}) \vec{p} dt.$$

证

$$f(\vec{x} + \vec{p}) = f(\vec{x}) + \nabla f(\vec{x})^T \vec{p} + \frac{1}{2} \vec{p}^T \nabla^2 f(\vec{x} + t\vec{p}) \vec{p}.$$



注记: 上述其实就是中值定理. 且可以很快从一元中值定理导出. 只需令

$$\phi(t) = f(\vec{x} + t\vec{p}), \quad \phi(0) = f(\vec{x}), \quad \phi(1) = f(\vec{x} + \vec{p})$$

则有

$$\phi'(t) = \nabla f(\vec{x} + t\vec{p})^T \cdot \vec{p}, \quad \phi''(t) = \vec{p}^T \nabla^2 f(\vec{x} + t\vec{p}) \vec{p}$$

注记: 在开始进一步讨论之前, 让我们先回顾一下可微这个概念. 在一维的时候, 函数在  $x$  点可微意味着在该点附近, 函数的变化  $\Delta f$  和自变量的变化  $\Delta x$  是一个线性变化, 比率为  $f'(x)$ , 误差为  $o(\Delta x)$ . 也就是说函数在  $x$  点附近的改变大致是一个关于  $\Delta x$  的线性函数. 因此当我们知道了  $f$  在  $x$  点可微, 我们可以容易地通过  $f(x)$  求得  $x$  附近所有函数值的近似. 而二维的时候, 函数的变化可以近似地看作在  $x_0 z$  平面和  $y_0 z$  平面上两个斜率为  $\frac{\partial f}{\partial x}$  和  $\frac{\partial f}{\partial y}$  向量张成的线性空间.



于是我们同样可以根据  $f(x)$  的值估计  $f(x)$  附近的值. 可微的本质意义就在于此. 进一步, 若二次可微, 则在  $x$  点附近, 当我们知道  $f(x)$  值之后, 估值可以做得更准确. 因为我们知道在  $x$  点附近,  $f(x)$  的变化是关于  $\Delta x$  的一个二次函数.

以上论述对于学过微积分的同学应该不是新内容. 但对它的正确理解恰好构成了我们优化算法的理论基础. 而正由于它的简单, 因此也格外地基本和重要.

自然啦, 下面我们考虑连续可微函数在其局部最优点附近会有什么性质. 这个很容易想到, 如果  $x^*$  是一个局部最小点, 那么在  $x^*$  点出发的任何方向上, 不能有负的方向导数, 否则沿那个方向我们有更小的值, 也不能有正的方向导数, 否则沿这个方向的反方向我们会更小的值 (这一点体现连续性本质). 于是过这一点的任何方向, 我们只能有零导数. 严格归纳可得下面定理:

定理 (一阶必要条件) (First-Order Necessary Conditions) 若  $x^*$  是一个局部最优, 且  $f$  在  $x^*$  的开邻域内连续可微, 则  $\nabla f(x^*) = 0$ . [P. 15 Thm 2.2]

证明: 反证, 假设 (suppose for contradiction)  $\nabla f(x^*) \neq 0$ . 令  $\vec{p} = -\nabla f(x^*)$ , 则

(这总是成立)  $\rightarrow p^T \nabla f(x^*) = -\|\nabla f(x^*)\|^2 < 0$

由于  $\nabla f$  在  $x^*$  附近连续可微, 故存在  $T > 0$ , 使得

$$p^T \nabla f(x^* + t\vec{p}) < 0, \quad \forall t \in [0, T] \quad (\text{还是连续性本质}).$$

故对任意  $\bar{t} \in (0, T]$ , 由 Taylor 定理知, 存在  $t \in (0, \bar{t})$ , 使

$$f(x^* + \bar{t}\vec{p}) = f(x^*) + \bar{t} \vec{p}^T \nabla f(x^* + t\vec{p}), \quad (\text{中值定理直接隐含方向变化定性})$$

于是  $f(x^* + \bar{\epsilon} \vec{p}) < f(x^*)$ , 对  $\forall \bar{\epsilon} \in (0, T)$  成立. 于是我们得到  $x^*$  的一个下降方向 ( $\vec{p} = -\nabla f$ ), 这与  $x^*$  是局部最小值矛盾 (contradiction).

注记: 很容易把  $\vec{p}$  变成任意方向.

我们称  $x^*$  是一个稳定点 (stationary point), 若  $\nabla f(x^*) = 0$ . 一个局部最小点必然是稳定点.

回顾一下, 矩阵 (matrix)  $B$  是正定的 (positive definite), 若  $\vec{p}^T B \vec{p} > 0$ ,  $\forall \vec{p} \neq 0$ ; 而半正定 (positive semidefinite) 指  $\vec{p}^T B \vec{p} \geq 0$ , 对所有  $\vec{p}$  成立.

定理 (二阶 (second-order) 必要性条件)

若  $x^*$  是  $f$  的一个局部极小点, 且  $f$  在  $x^*$  的开邻域二次连续可微, 则  $\nabla f(x^*) = 0$  且  $\nabla^2 f(x^*)$  半正定. [P16, Thm 2.3]

有了二次连续可微, 使我们可以考虑上一个定理剩下的东西. 因为上一个定理只是必要条件. 也就是  $\nabla f(x^*) = 0$  不能保证  $x^*$  是  $f$  的局部极小点, 但若我们有更多的信息 (二次连续可微) 则我们可以做进一步的判断 ( $\nabla^2 f(x^*)$  正定?) 证明的思路其实基本一致.

证明: 显然  $\nabla f(x^*) = 0$ . 反证, 假设  $\nabla^2 f(x^*)$  不正定, 也即存在  $\vec{p}$  使  $\vec{p}^T \nabla^2 f(x^*) \vec{p} < 0$ . 于是由连续性, 存在  $T > 0$  使

$$\vec{p}^T \nabla^2 f(x^* + t\vec{p}) \vec{p} < 0, \quad \forall t \in [0, T].$$

于是对  $\forall \bar{\epsilon} \in (0, T]$  总有  $t \in (0, \bar{\epsilon})$ , 使

$$f(x^* + \bar{\epsilon} \vec{p}) = f(x^*) + \bar{\epsilon} \vec{p}^T \nabla f(x^*) + \frac{1}{2} \bar{\epsilon}^2 \vec{p}^T \nabla^2 f(x^* + t\vec{p}) \vec{p} < f(x^*).$$

矛盾.

下面我们考虑  $f$  在  $x^*$  点是局部极小点的充分条件 (sufficient condition). (书上这里 P16. Thm 2.4 之前一行,  $z^*$  应该是  $x^*$ ).

定理 (二阶充分条件)

设  $f$  在  $x^*$  的开邻域二次连续可微,  $\nabla f(x^*) = 0$  且  $\nabla^2 f(x^*)$  正定, 则  $x^*$  是一个严格局部最小点.

前一定理留下了一丝空隙, 半正定. 意味着 Taylor 展开的第二项和第三项可以同时为零. 这样一来  $f$  的性质必须交由第四项去判断, 这一点很痛苦. 于是干脆给一个让第三项永远大于零的条件. 因此定理的出现和证明都是显然的.

证明: 由条件, 存在  $r > 0$ , 使对开邻域  $\mathcal{D} = \{x \mid \|x - x^*\| < r\}$ , 有  $\forall z \in \mathcal{D}$ ,  $\nabla^2 f(x)$  正定. (连续性) 于是  $\forall p \neq 0$ , 且  $x^* + p \in \mathcal{D}$ , 有

$$\begin{aligned} f(x^* + p) &= f(x^*) + p^T \nabla f(x^*) + \frac{1}{2} p^T \nabla^2 f(x) p \\ &= f(x^*) + \frac{1}{2} p^T \nabla^2 f(x) p. \end{aligned}$$

$$\Rightarrow f(x^* + p) > f(x^*).$$

注意以上定理不是必要条件. 例如  $f(x) = x^4$ , 对  $x^* = 0$ , 显然是其严格最小值. 但  $\nabla^2 f(x^*)$  是零阵, 不满足条件.

若  $f$  是凸函数, 则局部极小值和全局极小值都变得容易刻画.

定理 若  $f$  是凸函数, 任何局部极小值点  $x^*$  都是其全局极小值点. 进而若  $f$  可微, 则任何稳定点  $x^*$  都是  $f$  的全局极小值点.

证明: 假设  $x^*$  是局部但不是全局极小值点, 也即存在  $z \in \mathbb{R}^n$ , 使  $f(z) < f(x^*)$ . 则在线段 (line segment)  $x^*z$  上的点  $x$  可表为

$$x = \lambda z + (1-\lambda)x^*, \quad \lambda \in (0, 1]. \quad (\text{注意 } x \text{ 过 } x^* \text{ 的邻域}).$$



由于  $f$  是凸的, 致

$$f(x) \leq \lambda f(x) + (1-\lambda)f(x^*) < f(x^*). \quad (\text{与 } x^* \text{ 局部极小矛盾}).$$

第二部分书上的证明过于技术化. 直观上理解是若有一点  $x$  比  $x^*$  还小, 那么由于凸函数, 可以把凸从  $x$  一直拉到  $x^*$ , 从而使  $x^*$  的梯度“有点斜”.

以上定理是无穷优化问题的基础. 几乎所有算法都寻找  $f$  的退化 (vanish) 点.

不光滑问题 (nonsmooth). (困难的且不在本书讨论范围).

本书只考虑通常目标函数存在二阶连续导数的光滑情形.

## 2.2 算法概览

两个基本策略 (stratage): 线搜索 (line search) 和信任域 (trust region)

所谓线搜索, 算法要在一个已选定的方向  $p_k$  上沿这个方向, 从当前的点  $x_k$  开始, 寻找一个新的更优的函数值做为新的迭代值. 这个问题, 即在  $p_k$  方向上走多远距离的问题, 可以看作是一个一维优化问题, 即找步长  $\alpha$ :

$$\min_{\alpha > 0} f(x_k + \alpha p_k) \quad (2.9)$$

尽管精确地求解 (2.9) 能够在  $p_k$  方向上获得最大的收益, 但是一个精确的搜索不仅过于昂贵, 而且没有必要. 作为替代, 线搜索算法应该产生一系列有限数量的尝试步长, 直到找到一个 (2.9) 问题的一个低精度 (但够用) 的逼近.

而第二个策略, 即信任域. 我们对问题目标函数  $f$  的信息的获取是通过  $f$  的一个在  $x_k$  附近的近似模型  $m_k$  获取的. (直接计算  $f$  代价巨大). 于是当  $x$  远离  $x_k$  时,  $m_k$  就不再是  $f$  的一个良好的逼近.



我们在  $x_k$  的附近求  $m_k$  的最小值, 也即寻找  $p$ , 满足

$$\min_p m_k(x_k + p), \quad x_k + p \text{ 离 } x_k \text{ 不可太远 (在信任域内)}. \quad (2.10)$$

若上述问题的解不能在  $f$  上形成一个令人满意的下降, 我们则认为信任域取得过大, 于是缩小其范围, 并重解问题 (2.10). 通常, 信任域是一个球, 记为  $\|p\|_2 \leq \Delta$ , 这里数值  $\Delta > 0$  被称为信任域的半径 (radius). 当然椭圆或矩形的信任域也可以被考虑.

问题 (2.10) 中模型  $m_k$  一般记为一个二次函数形式:

$$m_k(x_k + p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p, \quad (2.11)$$

这里  $f_k$ ,  $\nabla f_k$  和  $B_k$  相应地 (respectively) 是数值, 向量, 和矩阵. 这里下标  $k$  表示  $f_k$  和  $\nabla f_k$  是  $x_k$  点的函数值和梯度值 (下同), 于是  $m_k$  和  $f$  在点  $x_k$  的导数值相等. 矩阵  $B_k$  一般是 Hessian 阵  $\nabla^2 f_k$  或者它的某种近似.

信任域和线搜索分别决定了下一个迭代步中的搜索方向和步长. 线搜索在  $p_k$  方向上寻找一个令人满意的步长  $\alpha_k$ , 而信任域则是先规定一个最大范围  $\Delta_k$ , 然后在这个范围内寻找一个有最大改进的方向 (根据  $m_k$  而非  $f$ ). 若之后在  $f$  中发观实际效果不好, 则减少  $\Delta_k$ , 然后重试.

线搜索和信任域分别在第三章和第四章详细讨论. 我们先预览两个主要问题: 为线搜索选择搜索方向  $p_k$ , 和在信任域方法中选择 Hessian 阵  $B_k$ . 这是两个密切相关的问题.

为线搜索确定搜索方向

最速下降方向  $-\nabla f_k$  对线搜索的方向来说是一个最显然的选择. 在从  $x_k$  出发的所有方向中, 它是  $f$  下降最快的方向, 这个只要从 Taylor 定理 (Thm 2.1) 中不难看出.

$$f(x_k + \alpha p) = f(x_k) + \alpha p^T \nabla f_k + \frac{1}{2} \alpha^2 p^T \nabla^2 f(x_k + t p) p, \quad t \in (0, 1).$$

于是从  $x_k$  出发沿  $p$  方向下降率由  $\alpha$  的系数,  $p^T \nabla f_k$  决定, 因此, 将  $p$  单位化后, 下降最快的方向由下面问题决定

$$\min_p p^T \nabla f_k, \quad \|p\| = 1.$$

而  $p^T \nabla f_k = \|p\| \cdot \|\nabla f_k\| \cdot \cos \theta$ , 这里  $\theta$  是  $p$  和  $\nabla f_k$  之间的夹角. 于是显然有当  $\theta = \pi$  时, 有最小值  $-1$ . 所有方向为和等高线 (contours) 正交 (orthogonal) 的方向.

最速下降法就是线搜索每次都沿  $p_k = -\nabla f_k$  搜索的方法, 有多种方法可以选择步长  $\alpha_k$ , 留待第3章解决. 这个方法的优点是: 最速下降方向的选择只需计算  $\nabla f_k$  而不用二阶导数, 但它对于复杂问题而言非常的慢.

除了最速下降方向, 线搜索还可以用很多其它方向. 事实上, 任何下降方向, 一个方向和  $-\nabla f_k$  之间夹角小于  $\frac{\pi}{2}$  的方向, 这样就能保证在该方向上  $f$  下降. 这一点也可以用 Taylor 定理验证:

$$f(x_k + \varepsilon p_k) = \varepsilon p_k^T \nabla f_k + O(\varepsilon^2)$$

当  $p_k$  是下降方向,  $p_k$  和  $\nabla f_k$  之间的夹角满足  $\cos \theta_k < 0$ , 因此

$$p_k^T \nabla f_k = \|p_k\| \|\nabla f_k\| \cos \theta_k < 0,$$

于是  $f(x_k + \varepsilon p_k) < f(x_k)$ , 对任何足够小的  $\varepsilon > 0$ .

另一个重要的搜索方向,也许是最重要的,是 Newton 方向. 这个方向可以以  $f(x_k+p)$  的二阶 Taylor 逼近, 即

$$f(x_k+p) \approx f_k + p^T \nabla f_k + \frac{1}{2} p^T \nabla^2 f_k p \stackrel{\text{def}}{=} m_k(p)$$

得到.

假设  $\nabla^2 f_k$  对称正定, 我们可以通过求解使  $m_k(p)$  最小的  $p$  得到 Newton 方向, 只要书  $m_k(p)$  的导数零点, 就有

$$p_k^N = -\nabla^2 f_k^{-1} \nabla f_k.$$

当函数  $f(x_k+p)$  和二次模型  $m_k(p)$  区别不大时 Newton 方向是合理的. 当  $\|p\|$  不大时,  $f(x_k+p)$  和  $m_k(p)$  非常接近.

Newton 方向用于线搜索时要求  $\nabla^2 f_k$  是对称正定的, 此时

$$\nabla f_k^T p_k^N = -(p_k^N)^T \nabla^2 f_k p_k^N \leq -\sigma_k \|p_k^N\|^2, \quad \sigma_k > 0.$$

只要  $\nabla f_k \neq 0$ , 我们就有 Newton 方向是下降方向. 不像最速下降方向, Newton 方向上有一个自然的步长是  $\alpha=1$ . 只有当这个步长不能令人满意时, 我们才会调整步长.

当  $\nabla^2 f_k$  不正定时, Newton 方向可能连定义都没有, 即便有, 可能也不是下降方向. 在这些情况下, 需要对  $p_k$  做一些基于  $\nabla^2 f_k$  信息的调整. 这些技巧我们在第 6 章讨论.

使用 Newton 方向的方法收敛率很高, 一般是二阶. 也意味着通常只需几步就可以收敛. 但缺点是 Hessian 阵的计算有很多实际困难.

拟 Newton 方向 (Quasi-Newton) 提供了一个不需要计算 Hessian 阵但能保持超收敛率的替代方法.

这里  $\nabla^2 f_k$  被它的一个近似  $B_k$  取代,  $B_k$  在迭代的每步都用来自新步长的新信息加以更新 (也即有一个  $B_{k+1} = \phi(B_k)$  的迭代公式). 比如从中值定理

$$\nabla f(x+p) = \nabla f(x) + \nabla^2 f(x)p + \int_0^1 [\nabla^2 f(x+tp) - \nabla^2 f(x)]p dt,$$

由  $\nabla f$  连续, 令  $x = x_k$ ,  $p = x_{k+1} - x_k$  (注意这里是向量减法),

$$\nabla f_{k+1} = \nabla f_k + \nabla^2 f_{k+1}(x_{k+1} - x_k) + o(\|x_{k+1} - x_k\|).$$

当  $x_k$  和  $x_{k+1}$  都和真解  $x^*$  很近时, 且  $\nabla^2 f$  是正定 (书上这里读作  $\nabla f$ , p24 公式 (2.15) 之上倒数两行) 于是有

$$\nabla^2 f_{k+1}(x_{k+1} - x_k) \approx \nabla f_{k+1} - \nabla f_k. \quad (2.15)$$

因此当我们构造  $B_{k+1}$  (从  $B_k$ ), 要考虑这一点:

$$B_{k+1} s_k = \eta_k \quad (2.16)$$

这里

$$s_k = x_{k+1} - x_k, \quad \eta_k = \nabla f_{k+1} - \nabla f_k$$

我们一般还要对  $B_{k+1}$  施加额外要求, 比如对称, 同时要求  $B_k$  和  $B_{k+1}$  之差是一个低秩的矩阵 (为了容易构造), 而  $B_0$  则由用之选取.

两类流行的 Hessian 阵近似  $B_k$  更新的方法是 对称秩 1 (symmetric-rank-one, SR1) 公式

$$B_{k+1} = B_k + \frac{(\eta_k - B_k s_k)(\eta_k - B_k s_k)^T}{(\eta_k - B_k s_k)^T s_k} \quad (2.17)$$

和 BFGS 公式 (Broyden, Fletcher, Goldfarb 和 Shanno)

$$B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k} \quad (2.18)$$

注意这里  $B_k$  和  $B_{k+1}$  之间的差, (2.17) 是秩为 1 的矩阵, (2.18) 是秩为 2 的矩阵. 可以证明 (2.18) 只要  $B_0$  是正定的和  $s_k^T y_k > 0$ , 则  $B_k$  总是正定的. 这些在第 8 章讨论.

$B_k$  在构造拟 Newton 方向时, 用来替代精确的 Hessian 阵, 也即

$$p_k = -B_k^{-1} \nabla f_k.$$

有一些实际使用的拟 Newton 法用一系列  $B_k^{-1}$  的更新来替代  $B_k$  的更新, 比如对应 (2.17) 和 (2.18) 的逆阵逼近为 ( $H_k := B_k^{-1}$ )

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T, \quad \rho_k = \frac{1}{y_k^T s_k}.$$

于是  $p_k$  的计算为:

$$p_k = -H_k \nabla f_k.$$

两个用拟 Newton 方法求解大规模问题时的主要因素: 不分离 (partially separable) 和更新中的内存限制将在第 9 章讨论.

我们预想的最后一类搜索方向是通过非线性共轭梯度法产生的 (nonlinear conjugate gradient methods). 形式为:

$$p_k = -\nabla f(x_k) + \beta_k p_{k-1}$$

这里  $\beta_k$  是一个数值, 用来确保  $p_k$  和  $p_{k-1}$  共轭. 这个概念我们将在第5章讨论. 共轭梯度法原本是用来计算系数矩阵对称正定的线性方程组  $Ax=b$ , 这个问题可等价地转为

$$\min \phi(x) = \frac{1}{2} x^T A x + b^T x.$$

这个方法没有 Newton 或拟 Newton 造快, 但好处是不用存储矩阵.

我们上面讨论的所有方法, 除了共轭梯度法以外, 都可纳入信任域法的框架.

信任域方法的模型,

若在公式 (2-11)

$$m_k(x_k + p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p,$$

中令  $B_k = 0$ , 则得信任域框架导出的最速下降法

$$\min_p f_k + p^T \nabla f_k, \quad \|p_k\|_2 \leq \Delta_k.$$

于是有

$$p_k = - \frac{\Delta_k \nabla f_k}{\|\nabla f_k\|} \quad (\text{一切计算信息具备, 因此称为 closed form})$$

若  $B_k$  取精确的 Hessian 阵, 则为 Newton 法. 由于有 (限制)  $\|p\|_2 \leq \Delta_k$ , 因此即便  $\nabla^2 f_k$  不对称正定时,  $p_k$  也不会无效. 因此信任域框架下的 Newton 法保证了实际操作中的高效率. 若  $B_k$  的取法是某种拟 Newton 方法的取法, 则成为信任域拟 Newton 法.

规模比例 (scaling, 自己看)

收敛率 (rates of convergence)

令  $\{x_k\}$  是  $\mathbb{R}^n$  中的序列, 收敛至  $x^*$ . 我们称收敛是 Q-线性的, 若存在  $r \in (0, 1)$ , 使

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \leq r, \text{ 对 } k \text{ 充分大成立.}$$

若收敛被称为 Q-超线性, 若

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = 0.$$

特别地, Q-平方收敛, 指

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^2} \leq M, \text{ 对 } k \text{ 充分大成立.}$$

Q-p阶收敛指

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^p} \leq M, \text{ 对 } k \text{ 充分大成立.}$$

R收敛率 (r-rates of convergence)

我们称收敛是 R-线性的, 若有非负数量序列  $\{v_k\}$ , 使

$$\|x_k - x^*\| \leq v_k$$

对全部  $k$  成立. 且  $\{v_k\}$  Q-线性收敛至 0.



类似地, 若  $\{v_k\}$  以一起线性收敛至 0, 则称  $\{x_n\}$   $R$ -一起线性收敛. 若  $\{v_k\}$   $Q$ - $p$  阶收敛, 则称  $\{x_n\}$   $R$ - $p$  阶收敛.