

线性规划(Linear Programming)

对偶(Duality)

我们已经注意到，问题的表述形式会严重影响问题的求解方法。有时候，一个问题存在对称的另一种“相反”方式的描述，这种表示在数学上被称为对偶表示（这里借用这个名称，真正的对偶在数学上都是有严格定义的）。有时将一个问题转成对偶形式，能更方便地求解。

以下考虑问题(12.1)的一个特例： $\mathcal{E} = \phi$ ，且目标函数 f 和 $c_i(x)$ 都是凸的， $i \in \mathcal{I}$ 。也即(12.1)现在可以写成

$$\min f(x), \quad \text{s. t. } c(x) \geq 0, \quad (12.81)$$

这里

$$c(x) := [c_1(x), c_2(x), \dots, c_m(x)]^T, \mathcal{I} = \{1, 2, \dots, m\}.$$

对应的Lagrange乘子函数为：

$$\mathcal{L}(x, \lambda) = f(x) - \lambda^T c(x).$$

现定义对偶目标函数 $q: \mathbb{R}^n \mapsto \mathbb{R}$,

$$q(\lambda) := \inf_x \mathcal{L}(x, \lambda), \quad (12.82)$$

由于对某些 λ ， $q(\lambda)$ 可以取到 $-\infty$ ，因此我们限制 q 的定义域为：

$$\mathcal{D}(q) := \{\lambda \mid q(\lambda) > -\infty\}. \quad (12.83)$$

（原问题我们一般是先确立 x ，然后判定 λ 。而在对偶情形下，我们先确定 λ ，然后再判定 x 。不论是原问题还是对偶，二者通过 $\mathcal{L}(x, \lambda)$ 建立对应。）

注意当 f 和 $c_i(x)$ 是凸的且 $\lambda \geq 0$ 时， $\mathcal{L}(\cdot, \lambda)$ 也是凸的。因此任何局部极值都是其全局极值。定义问题(12.81)的对偶问题如下：

$$\max_{\lambda \in \mathbb{R}^n} q(\lambda), \quad \text{s. t. } \lambda \geq 0. \quad (12.84)$$

例 12.10

$$\min_x 0.5(x_1^2 + x_2^2), \quad \text{s. t. } x_1 - 1 \geq 0. \quad (12.85)$$

该问题的Lagrange乘子函数为

$$\mathcal{L}(x, \lambda) = 0.5(x_1^2 + x_2^2) - \lambda_1(x_1 - 1),$$

对给定的 λ_1 ，有 $\mathcal{L}(x, \lambda_1)$ 是凸的，故其稳定点：

$$\begin{cases} \frac{\partial \mathcal{L}(x, \lambda_1)}{\partial x_1} = x_1 - \lambda = 0 \\ \frac{\partial \mathcal{L}(x, \lambda_1)}{\partial x_2} = x_2 = 0 \end{cases} \Rightarrow \begin{cases} x_1 = \lambda_1 \\ x_2 = 0 \end{cases}$$

就是其全局极小值点，故

$$\begin{aligned}
q(\lambda_1) &= \inf_x \mathcal{L}(x, \lambda_1) = \mathcal{L}(\lambda_1, 0, \lambda_1) \\
&= 0.5(x_1^2 + x_2^2) - \lambda_1(x_1 - 1) \Big|_{x_1=\lambda_1, x_2=0} \\
&= 0.5(\lambda_1^2) - \lambda_1(\lambda_1 - 1) \\
&= -0.5\lambda_1^2 + \lambda_1.
\end{aligned}$$

因此对偶问题为：

$$\max_{\lambda_1 \geq 0} -0.5\lambda_1^2 + \lambda_1, \quad (12.86)$$

解为 $\lambda_1^* = 1$ ，代回有 $x^* = (1, 0)^T$ 。（对偶问题和原问题等解。）

定理 12.10 q 是凹(concave)的， \mathcal{D} 是凸的。

证明 $\forall \lambda^0, \lambda^1 \in \mathbb{R}^n, x \in \mathbb{R}^n, \alpha \in [0, 1]$ ，有

$$\mathcal{L}(x, (1 - \alpha)\lambda^0 + \alpha\lambda^1) = (1 - \alpha)\mathcal{L}(x, \lambda^0) + \alpha\mathcal{L}(x, \lambda^1),$$

两边同时取inf，并用不等式

$$\inf(a + b) \geq \inf a + \inf b,$$

有

$$q((1 - \alpha)\lambda^0 + \alpha\lambda^1) \geq (1 - \alpha)q(\lambda^0) + \alpha q(\lambda^1),$$

即 q 是凹的（和凸不等式反向）。而对 $\lambda^0, \lambda^1 \in \mathcal{D}$ ，则上式右端 $> -\infty$ ，而上式左端亦 $> -\infty$ ，于是

$$(1 - \alpha)\lambda^0 + \alpha\lambda^1 \in \mathcal{D},$$

即 \mathcal{D} 是凸的。

从上述证明可以看到，对偶问题的目标函数，事实上是原问题目标函数的下界。这个事实总结为以下定理：

定理 12.11(弱对偶) 任取(12.81)的可行点 \bar{x} ，以及 $\bar{\lambda} \geq 0$ ，有 $q(\bar{\lambda}) \leq f(\bar{x})$ 。

证明：略。

在(12.81)的形式下，KKT条件有如下形式：

$$\nabla f(\bar{x}) - \nabla c(\bar{x})\bar{\lambda} = 0, \quad (12.87a)$$

$$c(\bar{x}) \geq 0, \quad (12.87b)$$

$$\bar{\lambda} \geq 0, \quad (12.87c)$$

$$\bar{\lambda}_i c_i(\bar{x}) = 0, i = 1, 2, \dots, m. \quad (12.87d)$$

其中 $\nabla c(x)$ 表示 $n \times m$ 矩阵

$$\nabla c(x) = [\nabla c_1(x), \nabla c_2(x), \dots, \nabla c_m(x)].$$

定理12.12 若 \bar{x} 是问题(12.18)的解，且 f 和 $-c_i$ 均凸并在 \bar{x} 点连续可微， $i = 1, 2, \dots, m$ ，则对任何满足KKT条件的 $(\bar{x}, \bar{\lambda})$ ， $\bar{\lambda}$ 是(12.84)的解。

定理12.13 假设 f 和 $-c_i, i = 1, 2, \dots, m$ 是凸的且连续可微。若 \bar{x} 是(12.81)的解且LICQ成立。假设 $\hat{\lambda}$ 是(12.84)的解，且 $\inf_x \mathcal{L}(x, \lambda)$ 在 \hat{x} 取到。若 $\mathcal{L}(\cdot, \hat{\lambda})$ 是严格凸的，则 $\bar{x} = \hat{x}, f(\bar{x}) = \mathcal{L}(\hat{x}, \hat{\lambda})$ 。

以上两个定理证明略，它们说明可以在必要的时候用对偶问题来代替原问题求解。而在计算上，我们讲对偶问题整理成更方便的形式，称为Wolfe对偶：

$$\max_{x, \lambda} \mathcal{L}(x, \lambda), \quad \text{s. t. } \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0. \quad (12.88)$$

这种转换只需要机械地计算。

定理 12.14 假设 f 和 $-c_i, i = 1, 2, \dots, m$ 是凸的并连续可微。若 $(\bar{x}, \bar{\lambda})$ 是(12.81)的解, 且有LICQ成立。则 $(\bar{x}, \bar{\lambda})$ 也是(12.88)的解。

例 12.11 (线性规划, Linear Programming)

$$\min c^T x, \text{ s. t. } Ax - b \geq 0. \quad (12.89)$$

对偶目标为:

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda],$$

若 $c - A^T \lambda \neq 0$, 则 $q(\lambda) = -\infty$ (无界)。故由定义, $q(\lambda)$ 需满足 $A^T \lambda = c$ 。而此时 $q(\lambda) = b^T \lambda$, 对偶问题为:

$$\max_{\lambda} b^T \lambda, \text{ s. t. } A^T \lambda = c, \lambda \geq 0. \quad (12.90)$$

直接计算可得, 对应的Wolfe对偶为

$$\max_{\lambda, x} c^T x - \lambda^T (Ax - b), \text{ s. t. } A^T \lambda = c, \lambda \geq 0.$$

和(12.90)是等价的。对于 A 的某些形式, (12.90)比(12.89)更易求解。

例 12.12 (凸二次规划, Convex Quadratic Programming)

$$\min \frac{1}{2} x^T G x + c^T x, \text{ s. t. } Ax - b \geq 0, \quad (12.91)$$

其中 G 正定。对偶目标函数为

$$q(\lambda) = \inf_x \mathcal{L}(x, \lambda) = \inf_x \frac{1}{2} x^T G x + c^T x - \lambda^T (Ax - b), \quad (12.92)$$

由 G 对称正定, $\mathcal{L}(x, \lambda)$ 严格凸, 故 \inf 在 $\nabla_x \mathcal{L}(x, \lambda) = 0$, 即

$$Gx + c - A^T \lambda \Rightarrow x = G^{-1}(A^T \lambda - c). \quad (12.93)$$

由上式, 得

$$\begin{aligned} q(\lambda) &= x^T G x + c^T x - \lambda^T A x + \lambda^T b - \frac{1}{2} x^T G x \Big|_{Gx+c-A^T\lambda=0} \\ &= -\frac{1}{2} (A^T \lambda - c)^T G^{-1} G G^{-1} (A^T \lambda - c) + b^T \lambda \\ &= -\frac{1}{2} (A^T \lambda - c)^T G^{-1} (A^T \lambda - c) + b^T \lambda. \end{aligned}$$

同样, 我们可以给出Wolfe对偶:

$$\max_{\lambda, x} -\frac{1}{2} x^T G x + \lambda^T b, \text{ s. t. } Gx + c - A^T \lambda = 0, \lambda \geq 0. \quad (12.95)$$

这里事实上 G 只需半正定。

以上都只是引言, 我们现在真正将注意力集中到线性规划上来。这是一类最简单, 也是最重要的优化模型, 同时也是一种最基本的建模思路。它的目标函数和约束, 全部都是线性的。

例: 如何找对象?

我们如何用简单的线性模型来表达这么复杂的一个主题呢?

$$\min f(x) = -c^T x, \text{ s. t. } Ax \geq b.$$

$$\begin{aligned}
f(x) &= \sum_{i=1}^n c_i x_i + 0 \cdot z \\
&= \sum_{i=1}^n c_i (x_i^+ - x_i^-) + 0 \cdot z \\
&= \sum_{i=1}^n c_i x_i^+ + \sum_{i=1}^n (-c_i) x_i^- + 0 \cdot z,
\end{aligned}$$

重新整理一下，现令

$$x = [x^+ \quad x^- \quad z]^T, c = [c \quad -c \quad 0]^T, A = [A \quad -A \quad I],$$

则一般问题就转变成等解的标准形式：

$$\min f(x) = c^T x, \quad \text{s. t. } Ax = b, x \geq 0.$$

例

$$\begin{cases} \min & x_1 - 2x_2 + 5x_3, \\ \text{s.t.} & x_1 - x_3 \geq 6, \\ & 2x_2 + x_3 \leq 2, \\ & x_1, x_2 \geq 0. \end{cases}$$

化为标准形式：

引入 $x_4 \geq 0$, 使

$$x_1 - x_3 \geq 6 \Leftrightarrow x_1 - x_3 - x_4 = 6.$$

引入 $x_5 \geq 0$, 使

$$2x_2 + x_3 \leq 2 \Leftrightarrow 2x_2 + x_3 + x_5 = 2.$$

引入 $x_6, x_7 \geq 0$, 并令

$$x_3 = x_6 - x_7,$$

则原问题化为：

$$\begin{cases} \min & x_1 - 2x_2 + 5x_6 - 5x_7, \\ \text{s.t.} & x_1 - x_4 - x_6 + x_7 = 6, \\ & 2x_2 + x_6 - x_7 + x_5 = 2, \\ & x_1, x_2, x_4, x_5, x_6, x_7 \geq 0. \end{cases}$$

我们对 x 的各分量做一个重排：

$$x_4 \rightarrow x_3, x_5 \rightarrow x_4, x_6 \rightarrow x_5, x_7 \rightarrow x_6,$$

其余分量不变，则原问题整理成标准形式：

$$\begin{cases} \min & x_1 - 2x_2 + 5x_5 - 5x_6, \\ \text{s.t.} & x_1 - x_3 - x_5 + x_6 = 6, \\ & 2x_2 + x_4 + x_5 - x_6 = 2, \\ & x \geq 0. \end{cases} \Leftrightarrow \begin{cases} \min & f(x) = c^T x, \\ \text{s.t.} & Ax = b, \\ & x \geq 0. \end{cases}$$

其中，

$$\begin{aligned}
c &= (1, -2, 0, 0, 5, -5)^T, \quad x = (x_1, x_2, \dots, x_6)^T, \quad b = (6, 2)^T, \\
A &= \begin{bmatrix} 1 & 0 & -1 & 0 & -1 & 1 \\ 0 & 2 & 0 & 1 & 1 & -1 \end{bmatrix}.
\end{aligned}$$

我们可以写出(13.1)的Lagrange乘子函数,

$$\mathcal{L}(x, \lambda, s) = c^T x - \lambda^T (Ax - b) - s^T x. \quad (13.3)$$

这里 λ 是针对等值约束的 m 维Lagrange乘子向量, s 则是针对不等值约束 $x \geq 0$ 的 n 维Lagrange乘子。对线性规划应用定理12.1, 就得到 x^* 是问题(13.1)的解的必要条件为:

$$A^T \lambda + s = c, \quad (13.4a)$$

$$Ax = b, \quad (13.4b)$$

$$x \geq 0, \quad (13.4c)$$

$$s \geq 0, \quad (13.4d)$$

$$x_i s_i = 0, i = 1, 2, \dots, n. \quad (13.4e)$$

令 (x^*, λ^*, s^*) 表示一个满足条件(13.4)的向量三元组, 由(13.4a), (13.4d)和(13.4e)有

$$c^T x^* = (A^T \lambda^* + s^*)^T x^* = (Ax^*)^T \lambda^* = b^T \lambda^*. \quad (13.5)$$

在线性规划情形, 容易看出(13.4)也是有解的充分条件 (问题也只要一阶), 即满足(13.4)的 x^* 必是问题(13.1)的全局最优解。令 \bar{x} 是任何可行点, 则

$$A\bar{x} = b, \quad \bar{x} \geq 0.$$

于是

$$c^T \bar{x} = (A\lambda^* + s^*)^T \bar{x} = b^T \lambda^* + \bar{x}^T s^* \geq b^T \lambda^* = c^T x^*. \quad (13.6)$$

也即不会有比 x^* 取值更小的可行点。并且由(13.6)取等号的条件我们还可以看到, 若可行点 \bar{x} 是问题(13.1)的全局最优点, 当且仅当

$$\bar{x}^T s^* = 0.$$

线性规划问题的对偶问题是非常简单干净的, 问题(13.1)的对偶问题为:

$$\max b^T \lambda, \quad \text{s.t. } A^T \lambda \leq c. \quad (13.7)$$

现在变量变成了 λ 。相应地, (13.1)被称为原问题(primal)。这个问题也可以引入“对偶松弛变量”(dual slack variables) s , 将其改写成类似的标准形式:

$$\max b^T \lambda, \quad \text{s.t. } A^T \lambda + s = c, s \geq 0. \quad (13.8)$$

在这里, (λ, s) 一起成为新问题的变量, 有时也被称为对偶变量。

对偶问题和原问题其实是同一个问题的不同建模方式, 它们在Lagrange乘子函数和解的条件上达成了一致。这里我们不再过多讨论细节, 有兴趣的同学自己看书第361页后剩下的部分。我们直接用一个定理来总结一下:

定理 13.1 (强对偶)

1. 若(13.1)和(13.7)其中之一有有限解, 则另一个也有有限解, 且解和优化目标值相同;
2. 若(13.1)和(13.7)其中之一解无界, 则另一个必不可行 (无解)。

