

优化实用算法: 第五次作业

2022 年 5 月 28 日

指导老师: 徐翔

徐圣泽 3190102721

Problem 1

1. Let $r_1(x) = x_2 - x_1^2$, $r_2(x) = 1 - x_2$, $r(x) = (r_1(x), r_2(x))^T$, $f(x) = \frac{1}{2}[r_1(x)^2 + r_2(x)^2] = \frac{1}{2}r(x)^T r(x)$. It is known that the solution to $\min f(x)$ is $x^* = (1, 1)^T$.

(a) For any initial guess x_0 , give the Newton algorithm of

$$\begin{cases} x_{k+1} = x_k + \alpha_k p_k, \\ p_k = -[\nabla^2 f(x)]^{-1} \nabla f(x), \\ \alpha_k : f(x_k + \alpha_k p_k) = \min f(x + \alpha p_k). \end{cases}$$

(b) Try to prove when $x \rightarrow x^*$,

$$\nabla^2 f(x) \rightarrow \nabla r(x) \nabla r(x)^T.$$

解:

(a) 记 $J(x) = \nabla r(x)^T = (\nabla r_1(x), \nabla r_2(x))^T$, 则函数 $f(x)$ 的梯度为 $\nabla f(x) = r_1(x) \nabla r_1(x) + r_2(x) \nabla r_2(x) = J(x)^T r(x)$, 对应的 Hesse 矩阵为 $\nabla^2 f(x) = \nabla r_1(x) \nabla r_1(x)^T + \nabla r_2(x) \nabla r_2(x)^T + r_1(x) \nabla^2 r_1(x) + r_2(x) \nabla^2 r_2(x) = J(x)^T J(x) + S(x)$.

其中

$$\nabla^2 r_1(x) = \begin{pmatrix} -2 & 0 \\ 0 & 0 \end{pmatrix}, \nabla^2 r_2(x) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}, S(x) = \begin{pmatrix} -2r_1(x) & 0 \\ 0 & 0 \end{pmatrix}$$

该问题需要给出牛顿法, 与第一次作业的算法要求基本一致, 下面进行编程求解。

首先写出函数及其梯度和 Hesse 矩阵。

```
1 function y=f(x)
2   r=[x(2)-x(1)^2;1-x(2)];
3   y=r'*r/2;
4   end
```

```
1 function y=Gradf(x)
2   r=[x(2)-x(1)^2;1-x(2)];
3   J=[-2*x(1),1;0,-1];
4   y=J'*r;
5   end
```

```
1 function y=Hessef(x)
2   J=[-2*x(1),1;0,-1];
3   y=J'*J+[-2*(x(2)-x(1)^2),0;0,0];
4   end
```

下面我们首先根据书本 57 至 58 页的算法编写了利用进退法进行一维搜索确定区间的函数:

```
1 function [a,b]=Range(f,a0,h0,x,p)
2   t=2;k=0;ak=a0;yk=f(x+ak*p);h=h0;ak1=0;yk1=0;alpha=0;
3   while(0<=k)
4       ak1=ak+h;
5       if(ak1<0)
```

```

6         ak1=0;
7         break;
8     end
9     yk1=f(x+ak1*p);
10    if(yk1<=yk)
11        h=t*h; alpha=ak; ak=ak1; yk=yk1; k=k+1;
12    else
13        if k==0
14            h=-h; ak=ak1; yk=f(x+ak*p);
15        else
16            break;
17        end
18    end
19 end
20 if(alpha<ak1)
21     a=alpha;
22     b=ak1;
23 else
24     a=ak1;
25     b=alpha;
26 end
27 end

```

下面利用 0.618 法进行精确一维搜索：

```

1 function y = Minimum(f,a0,b0,x,p,epsilon)
2 a=a0;b=b0;
3 lambda=a+0.382*(b-a);mu=a+0.618*(b-a);
4 y1=f(x+lambda*p);y2=f(x+mu*p);
5 k=1;y=0;
6 while(k<=10000)
7     if(y1>y2)
8         if(b-lambda<=epsilon)
9             y=mu;
10            break;
11        end
12        a=lambda; lambda=mu;
13        y1=f(x+lambda*p);
14        mu=a+0.618*(b-a);
15        y2=f(x+mu*p);
16    else
17        if(mu-a<=epsilon)
18            y=mu;
19            break;
20        end
21        b=mu;mu=mu-lambda;
22        y2=f(x+mu*p);

```

```

23         lambda=a+0.382*(b-a);
24         y1=f(x+lambda*p);
25     end
26     k=k+1;
27 end
28 end

```

下面是带线搜索牛顿法的函数：

```

1  function [x,k]=NewtonsLineSearch(f,Gradf,Hesfef,x0,epsilon1,epsilon2)
2  k=0;x=x0;
3  while(k>=0)
4      if(sqrt((Gradf(x))'*Gradf(x))<=epsilon1)
5          break;
6      end
7      p=-inv(Hesfef(x))*Gradf(x);
8      a0=2;h0=0.5;
9      [a,b] = Range(f,a0,h0,x,p);
10     x=x+Minimum(f,a,b,x,p,epsilon2)*p;
11     k=k+1;
12 end
13 end

```

下面是主程序的代码：

```

1  x0=unifrnd(-1000,1000,2,1);
2  epsilon=10^(-12);
3  [x,k] = NewtonsLineSearch(@f,@Gradf,@Hesfef,x0,epsilon,epsilon);

```

下面是三次随机选取初值后运行的结果：

```

1  随机选定的初值：
2  600.5609
3  -716.2273
4
5  带线搜索牛顿法得到的函数极小值点：
6  -1.0000
7  1.0000
8
9  带线搜索牛顿法得到的函数极小值：
10 2.4850e-26

```

```

1  随机选定的初值：
2  389.6572
3  -365.8010
4
5  带线搜索牛顿法得到的函数极小值点：

```

```

6  -1
7  1
8
9  带线搜索牛顿法得到的函数极小值：
10 0
11
12 迭代次数为：
13 12

```

```

1  随机选定的初值：
2  -446.1540
3  -907.6572
4
5  带线搜索牛顿法得到的函数极小值点：
6  1.0000
7  1.0000
8
9  带线搜索牛顿法得到的函数极小值：
10 8.4926e-30
11
12 迭代次数为：
13 12

```

上面的运行结果说明 $x^* = (1, 1)^T$ 和 $x^* = (-1, 1)^T$ 均为 $f(x)$ 的全局最小值点，此时 $r_1(x^*) = r_2(x^*) = f(x^*) = 0$ ，故本方法在给定初值不同的情况下给出的极小值点可能不同。

(b) 由 (a) 知， $r_1(x^*) = r_2(x^*) = 0$ ，且 $r_i(x^*)$, $i = 1, 2$ 关于 x 连续，故 $x \rightarrow 0$ 时 $r(x) \rightarrow 0$ ，则有

$$\nabla^2 f(x) = J(x)^T J(x) + S(x) = J(x)^T J(x) + \begin{pmatrix} -2r_1(x) & 0 \\ 0 & 0 \end{pmatrix} \rightarrow J(x)^T J(x)$$

则有 $\nabla^2 f(x) \rightarrow \nabla r(x) \nabla r(x)^T$ ，即证。

Problem 2

2. Let x_1, x_2 are solutions to $(A^T A + \mu_i I)x = -A^T r$, $i = 1, 2$ with respect to μ_1 and μ_2 , where $\mu_1 > \mu_2 > 0$, $A \in R^{m \times n}$, $r \in R^m$. Try to prove $\|Ax_2 + r\|_2^2 < \|Ax_1 + r\|_2^2$.

解：对 $A^T A$ 应用 SVD 分解，则有正交矩阵 Q 和对角化矩阵 Λ ，使得 $A^T A = Q \Lambda Q^T$ ，其中 $Q = (q_1, q_2, \dots, q_n) \in R^{n \times n}$ ， $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) \in R^{n \times n}$ 。

根据第四次作业第三道题目的结论，我们有

$$x(\mu_i) = - \sum_{k=1}^n \frac{q_k^T A^T r}{\mu_i + \lambda_k} q_k$$

因此有 $\|Ax_i + r\|_2^2 = (Ax_i + r)^T (Ax_i + r) = x_i^T A^T A x_i + x_i^T A^T r + r^T A x_i + r^T r$ 。

$$\begin{aligned} x_i^T A^T A x_i &= \left(\sum_{k=1}^n \frac{q_k^T A^T r}{\mu_i + \lambda_k} q_k^T \right) A^T A \left(\sum_{k=1}^n \frac{q_k^T A^T r}{\mu_i + \lambda_k} q_k \right) \\ &= \sum_{l=1}^n \sum_{k=1}^n \left(\frac{q_k^T A^T r}{\mu_i + \lambda_k} \right) q_k^T A^T A q_l \left(\frac{q_l^T A^T r}{\mu_i + \lambda_l} \right) \end{aligned}$$

易知其中

$$q_k^T A^T A q_l = \begin{cases} \lambda_j, & k = l = \lambda_j \\ 0, & k \neq l \end{cases}$$

因此 $x_i^T A^T A x_i = \sum_{k=1}^n \left(\frac{q_k^T A^T r}{\mu_i + \lambda_k} \right)^2 \lambda_k$, $x_i^T A^T r = (r^T A x_i)^T = r^T A x_i = - \sum_{k=1}^n \frac{(r^T A q_k)(q_k^T A^T r)}{\mu_i + \lambda_k}$,

故 $\|A x_i + r\|_2^2 = \sum_{k=1}^n \left[\frac{\lambda_k (q_k^T A^T r)^2}{(\mu_i + \lambda_k)^2} - \frac{2(q_k^T A^T r)^2}{\mu_i + \lambda_k} \right] + r^T r$ 。

对 μ_i 求导, 有

$$\begin{aligned} \frac{d}{d\mu_i} \left[\frac{\lambda_k (q_k^T A^T r)^2}{(\mu_i + \lambda_k)^2} - \frac{2(q_k^T A^T r)^2}{\mu_i + \lambda_k} \right] &= (q_k^T A^T r)^2 \left[\frac{-2\lambda_k}{(\mu_i + \lambda_k)^3} + \frac{2}{(\mu_i + \lambda_k)^2} \right] \\ &= (q_k^T A^T r)^2 \frac{2\mu_i}{(\mu_i + \lambda_k)^3} > 0 \end{aligned}$$

因此 $\|A x(\mu_i) + r\|_2^2$ 随 μ_i 的增大而增大, 因此有 $\|A x_2 + r\|_2^2 < \|A x_1 + r\|_2^2$ 。