

# PRACTICAL OPTIMIZATION ALGORITHMS

## 实用优化算法

徐 翔

数学科学学院  
浙江大学

MAR 18, 2022

### 第三讲：最速下降法和牛顿法

# 最速下降法

- $f(x)$  在  $x_k$  处附近连续可微,  $g_k = \nabla f(x_k) \neq 0$ , Taylor 展开为

$$f(x) = f(x_k) + \nabla^T f(x_k)(x - x_k) + \mathcal{O}(\|x - x_k\|^2)$$

# 最速下降法

- $f(x)$  在  $x_k$  处附近连续可微,  $g_k = \nabla f(x_k) \neq 0$ , Taylor 展开为

$$f(x) = f(x_k) + \nabla^T f(x_k)(x - x_k) + \mathcal{O}(\|x - x_k\|^2)$$

- 记  $x - x_k = \alpha p_k$ , 满足  $g_k^T p_k < 0$  的方向是下降方向

# 最速下降法

- $f(x)$  在  $x_k$  处附近连续可微,  $g_k = \nabla f(x_k) \neq 0$ , Taylor 展开为

$$f(x) = f(x_k) + \nabla^T f(x_k)(x - x_k) + \mathcal{O}(\|x - x_k\|^2)$$

- 记  $x - x_k = \alpha p_k$ , 满足  $g_k^T p_k < 0$  的方向是下降方向
- 如果  $\alpha$  相同, 在  $p_k$  取到  $-g_k$  时,  $g_k^T p_k$  取到最小, 即使目标函数下降最多

# 最速下降法

## 算法1

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

# 最速下降法

## 算法1

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;  
**for**  $k = 0, 1, \dots$

# 最速下降法

## 算法1

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;



# 最速下降法

## 算法1

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

# 最速下降法

## 算法1

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

# 最速下降法

## 算法1

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

# 最速下降法

## 算法1

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

**stop**;

# 最速下降法

## 算法1

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

**stop**;

**end (if)**

**end (for)**

# 最速下降法

性质

# 最速下降法


## 性质

- 负梯度方向是下降最快的方向，但仅是局部性质。

# 最速下降法

## 性质

- 负梯度方向是下降最快的方向，但仅是局部性质。
- 如果采用精确线搜索方法，由于  $\varphi'(\alpha_k) = 0$ ，则会出现  $p_{k+1}^T p_k = 0$ 。（当目标函数的等值线是一个扁长椭圆时，会出现“锯齿现象”，下降十分缓慢）






# 最速下降法

## 性质

- 负梯度方向是下降最快的方向，但仅是局部性质。
- 如果采用精确线搜索方法，由于  $\varphi'(\alpha_k) = 0$ ，则会出现  $p_{k+1}^T p_k = 0$ 。（当目标函数的等值线是一个扁长椭圆时，会出现“锯齿现象”，下降十分缓慢）



- 总体是线性收敛的。

# 总体收敛性定理

## Theorem (Zoutendijk)

# 总体收敛性定理

## Theorem (Zoutendijk)

- 考虑任何一个线搜索算法, 如果  $p_k$  是一个下降方向, 步长因子  $\alpha_k$  满足 Wolfe 条件.

# 总体收敛性定理

## Theorem (Zoutendijk)

- 考虑任何一个线搜索算法, 如果 $p_k$ 是一个下降方向, 步长因子 $\alpha_k$ 满足 Wolfe 条件.
- 假设 $f(x)$  在  $\mathcal{N} \equiv \{x \mid f(x) \leq f(x_0)\}$  上连续可微并且有下界, 其中 $x_0$  是迭代起始点.

# 总体收敛性定理

## Theorem (Zoutendijk)

- 考虑任何一个线搜索算法, 如果  $p_k$  是一个下降方向, 步长因子  $\alpha_k$  满足 Wolfe 条件.
- 假设  $f(x)$  在  $\mathcal{N} \equiv \{x : f(x) \leq f(x_0)\}$  上连续可微并且有下界, 其中  $x_0$  是迭代起始点.
- 假设  $\nabla f$  在  $\mathcal{N}$  上 Lipschitz 连续, 即存在常数  $L > 0$  使得

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y \in \mathcal{N}. \quad (2.1)$$

# 总体收敛性定理

## Theorem (Zoutendijk)

- 考虑任何一个线搜索算法, 如果  $p_k$  是一个下降方向, 步长因子  $\alpha_k$  满足 Wolfe 条件.
- 假设  $f(x)$  在  $\mathcal{N} \equiv \{x : f(x) \leq f(x_0)\}$  上连续可微并且有下界, 其中  $x_0$  是迭代起始点.
- 假设  $\nabla f$  在  $\mathcal{N}$  上 Lipschitz 连续, 即存在常数  $L > 0$  使得

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y \in \mathcal{N}. \quad (2.1)$$

- Then**

$$\sum_{k \geq 0} \cos^2(\theta_k) \|\nabla f(x_k)\|^2 < \infty \quad (2.2)$$

which is called **Zoutendijk condition**.

# 线搜索法收敛性

REMARK

# 线搜索法收敛性

## REMARK

- 如果使用 Goldstein 条件 strong Wolfe 条件, 类似结果也成立



# 线搜索法收敛性

## REMARK

- 如果使用 Goldstein 条件 strong Wolfe 条件, 类似结果也成立
- The Zoutendijk condition (2.2) implies that

$$\cos^2(\theta_k) \|\nabla f(x_k)\|^2 \rightarrow 0. \quad (2.3)$$

# 线搜索法收敛性

## REMARK

- 如果使用 Goldstein 条件 strong Wolfe 条件, 类似结果也成立
- The Zoutendijk condition (2.2) implies that

$$\cos^2(\theta_k) \|\nabla f(x_k)\|^2 \rightarrow 0. \quad (2.3)$$

- 可以推导 global convergence 结果.

# 总体收敛性定理

REMARK

# 总体收敛性定理

## REMARK

- 如果  $p_k$  满足与  $-\nabla f(x_k)$  的夹角  $\theta_k < 90^\circ$ , 即存在正常数  $\delta > 0$ ,

$$\cos \theta_k \geq \delta > 0, \forall k \quad (2.4)$$

It follows immediately from (2.3) that

$$\lim_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0. \quad (2.5)$$

# 总体收敛性定理

## REMARK

- 如果  $p_k$  满足与  $-\nabla f(x_k)$  的夹角  $\theta_k < 90^\circ$ , 即存在正常数  $\delta > 0$ ,

$$\cos \theta_k \geq \delta > 0, \forall k \quad (2.4)$$

It follows immediately from (2.3) that

$$\lim_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0. \quad (2.5)$$

- 即  $\|\nabla f(x_k)\| \rightarrow 0$ , 只要  $p_k$  不靠近  $-\nabla f(x_k)$  的正交方向。

# 最速下降法收敛速度

首先考虑二次函数  $f(x) = x^T G x$ , 其中  $G$  对称正定。

## 二次函数最速下降法的收敛速度定理

假设  $\lambda_1$  和  $\lambda_n$  是  $G$  的最大和最小特征值. 设  $x^*$  是问题的解, 则最速下降法的收敛速度至少是线性的, 并且满足

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} \leq \frac{(\kappa - 1)^2}{(\kappa + 1)^2} = \frac{(\lambda_1 - \lambda_n)^2}{(\lambda_1 + \lambda_n)^2}, \quad (2.6)$$

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \leq \sqrt{\kappa} \frac{(\kappa - 1)}{(\kappa + 1)}, \quad (2.7)$$

其中  $\kappa = \lambda_1 / \lambda_n \geq 1$ .

# 最速下降法收敛速度

## 一般函数最速下降法的收敛速度定理

设  $f(x)$  在  $x^*$  附近二次连续可微,  $\nabla f(x^*) = 0$ ,  $\nabla^2 f(x^*)$  正定, 则

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} = \beta_k < 1, \quad (2.8)$$

$$\limsup_{k \rightarrow +\infty} \beta_k \leq \frac{M - m}{M} < 1, \quad (2.9)$$

其中  $M, m$  满足  $0 < m \leq \lambda_n \leq \lambda_1 \leq M$ ,  $\lambda_n$  和  $\lambda_1$  是  $\nabla^2 f(x)$  的最小和最大特征值.

# 梯度法推广

## 两点步长梯度法



# 梯度法推广

## 两点步长梯度法

- 基本思想:  $x_{k+1} = x_k - D_k \nabla f(x_k)$  其中  $D_k = \alpha_k I$ .

# 梯度法推广

## 两点步长梯度法

- 基本思想：  $x_{k+1} = x_k - D_k \nabla f(x_k)$  其中  $D_k = \alpha_k I$ .
- 可以使  $D_k$  具有拟牛顿性质，即计算  $\alpha_k$  使得

$$\min \|s_{k-1} - D_k y_{k-1}\| \text{ 或者 } \min \|D_k^{-1} s_{k-1} - y_{k-1}\| \quad (2.10)$$

其中  $s_{k-1} = x_k - x_{k-1}$ ,  $y_{k-1} = \nabla f(x_k) - \nabla f(x_{k-1})$

# 梯度法推广

## 两点步长梯度法

- 基本思想：  $x_{k+1} = x_k - D_k \nabla f(x_k)$  其中  $D_k = \alpha_k I$ .
- 可以使  $D_k$  具有拟牛顿性质，即计算  $\alpha_k$  使得

$$\min \|s_{k-1} - D_k y_{k-1}\| \text{ 或者 } \min \|D_k^{-1} s_{k-1} - y_{k-1}\| \quad (2.10)$$

其中  $s_{k-1} = x_k - x_{k-1}$ ,  $y_{k-1} = \nabla f(x_k) - \nabla f(x_{k-1})$

- 可以求出  $\alpha_k$ ,

$$\alpha_k = \frac{s_{k-1}^T y_{k-1}}{\|y_{k-1}\|^2}, \text{ 或者 } \alpha_k = \frac{\|s_{k-1}\|^2}{s_{k-1}^T y_{k-1}}$$

# 两点步长梯度法

The Barzilai-Borwein gradient method

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

# 两点步长梯度法

The Barzilai-Borwein gradient method

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

## 两点步长梯度法

The Barzilai-Borwein gradient method

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

## 两点步长梯度法

### The Barzilai-Borwein gradient method

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 如果  $k = 0$ , 进行线搜索,

    如果  $k \neq 0$ ,  $\alpha_k = \frac{s_{k-1}^T y_{k-1}}{\|y_{k-1}\|^2}$ , 或者  $\alpha_k = \frac{\|s_{k-1}\|^2}{s_{k-1}^T y_{k-1}}$ ;

## 两点步长梯度法

### The Barzilai-Borwein gradient method

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 如果  $k = 0$ , 进行线搜索,

    如果  $k \neq 0$ ,  $\alpha_k = \frac{s_{k-1}^T y_{k-1}}{\|y_{k-1}\|^2}$ , 或者  $\alpha_k = \frac{\|s_{k-1}\|^2}{s_{k-1}^T y_{k-1}}$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;



## 两点步长梯度法

### The Barzilai-Borwein gradient method

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 如果  $k = 0$ , 进行线搜索,

    如果  $k \neq 0$ ,  $\alpha_k = \frac{s_{k-1}^T y_{k-1}}{\|y_{k-1}\|^2}$ , 或者  $\alpha_k = \frac{\|s_{k-1}\|^2}{s_{k-1}^T y_{k-1}}$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

# 两点步长梯度法

## The Barzilai-Borwein gradient method

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 如果  $k = 0$ , 进行线搜索,

    如果  $k \neq 0$ ,  $\alpha_k = \frac{s_{k-1}^T y_{k-1}}{\|y_{k-1}\|^2}$ , 或者  $\alpha_k = \frac{\|s_{k-1}\|^2}{s_{k-1}^T y_{k-1}}$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

**stop**;

# 两点步长梯度法

## The Barzilai-Borwein gradient method

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -\nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 如果  $k = 0$ , 进行线搜索,

    如果  $k \neq 0$ ,  $\alpha_k = \frac{s_{k-1}^T y_{k-1}}{\|y_{k-1}\|^2}$ , 或者  $\alpha_k = \frac{\|s_{k-1}\|^2}{s_{k-1}^T y_{k-1}}$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

**stop**;

**end (if)**

**end (for)**

# 两点步长梯度法

性质

# 两点步长梯度法

## 性质

- 不需要做线搜索( $k=0$ 除外),

# 两点步长梯度法

## 性质

- 不需要做线搜索( $k=0$ 除外),
- 没有矩阵乘以向量运算, 因此计算量小,

# 两点步长梯度法

## 性质

- 不需要做线搜索( $k=0$ 除外),
- 没有矩阵乘以向量运算, 因此计算量小,
- 本质上是梯度法, 但是收敛速度要更快.

# 两点步长梯度法

## 性质

- 不需要做线搜索( $k=0$ 除外),
- 没有矩阵乘以向量运算, 因此计算量小,
- 本质上是梯度法, 但是收敛速度要更快.
- Barzilai and Borwein 证明了对于二次目标函数问题, 该算法是 R-superlinearly 收敛.



# 两点步长梯度法

## 性质

- 不需要做线搜索( $k=0$ 除外),
- 没有矩阵乘以向量运算, 因此计算量小,
- 本质上是梯度法, 但是收敛速度要更快.
- Barzilai and Borwein 证明了对于二次目标函数问题, 该算法是 R-superlinearly 收敛.
- 对于非二次目标函数,  $\alpha_k$  有可能很大或很小, 因此我们需要给  $\alpha_k$  设置上下界.

# 牛顿法

$f(x)$  二次可微,  $x_k \in R^n$ , Hessian  $\nabla^2 f(x_k)$  正定, 有二次Taylor展开

$$f(x_k + s) \approx f(x_k) + \nabla f(x_k)^T s + \frac{1}{2} s^T \nabla^2 f(x_k) s. \quad (2.11)$$

# 牛顿法

$f(x)$  二次可微,  $x_k \in R^n$ , Hessian  $\nabla^2 f(x_k)$  正定, 有二次Taylor展开

$$f(x_k + s) \approx f(x_k) + \nabla f(x_k)^T s + \frac{1}{2} s^T \nabla^2 f(x_k) s. \quad (2.11)$$

极小化二次近似函数, 可得到  $s = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ , 于是

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k) \quad (2.12)$$

记  $p_k = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ ,  $\alpha_k = 1$ , 则迭代格式可以写为  $x_{k+1} = x_k + p_k$ .

# 牛顿法

## REMARK

记  $\nabla^2 f(x_k) = G_k$ ,  $g_k = \nabla f(x_k)$ .  
迭代格式记为  $x_{k+1} = x_k - G_k^{-1} g_k$

# 牛顿法

## REMARK

记  $\nabla^2 f(x_k) = G_k$ ,  $g_k = \nabla f(x_k)$ .

迭代格式记为  $x_{k+1} = x_k - G_k^{-1} g_k$

- 牛顿法可以看作在椭球范数  $\|\cdot\|_{G_k}$  下的最速下降法.

# 牛顿法

## REMARK

记  $\nabla^2 f(x_k) = G_k$ ,  $g_k = \nabla f(x_k)$ .

迭代格式记为  $x_{k+1} = x_k - G_k^{-1} g_k$

- 牛顿法可以看作在椭球范数  $\|\cdot\|_{G_k}$  下的最速下降法.
- 对于  $f(x_k + s) \approx f(x_k) + g_k^T s$ ,  $s$  是如下极小化问题的解

$$\min_{s \in \mathbb{R}^n} \frac{g_k^T s}{\|s\|}$$

- 如果范数采用  $l_2$ , 则  $s_k = -g_k$ .
- 如果范数采用  $\|\cdot\|_{G_k}$ ,  
则原问题等价于  $\min_{s \in \mathbb{R}^n} g_k^T s$  where  $\|s\|_{G_k} \leq 1$ .  
由于  $(g_k^T s)^2 \leq (g_k^T G_k^{-1} g_k)(s^T G_k s)$ , 则  $s_k = -G_k^{-1} g_k$ .

# 牛顿法收敛性

如果 $f$ 是二次函数, 则牛顿迭代法一步就达到最优解.

# 牛顿法收敛性

如果 $f$ 是二次函数, 则牛顿迭代法一步就达到最优解.

## 牛顿法收敛定理

设 $f$ 二次连续可微,  $x^*$ 充分靠近 $x^*$ ,  $\nabla f(x^*) = 0$ , 如果 $\nabla^2 f(x^*)$ 正定, 且Hessian矩阵 $G(x)$ 满足Lipschitz条件, 即存在 $L > 0$ , 对所有的 $(i, j)$ ,

$$|G_{ij}(x) - G_{ij}(y)| \leq L\|x - y\|. \quad (2.13)$$

则对一切 $k$ , 牛顿迭代法得到的序列 $x_k$ 收敛到 $x^*$ , 并且具有二次收敛速度.



# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, \quad x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

## 算法2(带步长因子的牛顿法)

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, \quad x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

## 算法2(带步长因子的牛顿法)

给定  $x_0 \in R^n, 0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, \quad x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

## 算法2(带步长因子的牛顿法)

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -[\nabla^2 f(x_k)]^{-1} f(x_k)$ ;

# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, \quad x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

## 算法2(带步长因子的牛顿法)

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -[\nabla^2 f(x_k)]^{-1} f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, \quad x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

## 算法2(带步长因子的牛顿法)

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -[\nabla^2 f(x_k)]^{-1} f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, \quad x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

## 算法2(带步长因子的牛顿法)

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, \quad x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

## 算法2(带步长因子的牛顿法)

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

**stop**;



# 牛顿法

## REMARK $G_k$ 不正定

在牛顿法中可以增加步长因子的搜索过程, 使得当  $G_k$  不正定的时候也收敛.

$$p_k = -G_k^{-1} g_k, \quad x_{k+1} = x_k + \alpha_k p_k \quad (2.14)$$

## 算法2(带步长因子的牛顿法)

给定  $x_0 \in R^n$ ,  $0 \leq \varepsilon \ll 1$ ;

**for**  $k = 0, 1, \dots$

    计算搜索方向  $p_k = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ ;

    计算步长  $\alpha_k$ , 使得  $f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$ ;

$x_{k+1} = x_k + \alpha_k p_k$ ;

**if**  $\|\nabla f(x_{k+1})\| \leq \varepsilon$

**stop**;

**end (if)**

**end (for)**

# 带步长因子牛顿法收敛性

## 定理

设 $f$ 在开凸集 $D$ 中二阶连续可微, 又设对任意的 $x_0 \in D$ , 存在常数 $m > 0$ , 使得 $f(x)$ 在水平集 $L(x_0) = \{x | f(x) \leq f(x_0)\}$ 上满足

$$u^T \nabla^2 f(x) u \geq m \|u\|^2, \forall u \in R^n, x \in L(x_0). \quad (2.15)$$

则在精确一维搜索条件下, 带步长因子的牛顿法产生的迭代点列 $\{x_k\}$ 满足

- ① 当 $x_k$ 为有限点列, 则对某个 $k$ ,  $\nabla f(x_k) = 0$ .
- ② 当 $x_k$ 为无穷点列,  $\{x_k\}$ 收敛到 $f$ 的唯一极小值点.

# GOLDSTEIN-PRICE修正牛顿法

- 如果 $G_k$ 不正定, 可以用 $p_k = -\nabla f(x_k)$ 代替 $p_k^N = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ , 因此也会适当引入步长因子.

# GOLDSTEIN-PRICE修正牛顿法

- 如果 $G_k$ 不正定, 可以用 $p_k = -\nabla f(x_k)$ 代替 $p_k^N = -[\nabla^2 f(x_k)]^{-1}\nabla f(x_k)$ , 因此也会适当引入步长因子.
- 给定阈值 $\eta > 0$

$$p_k = \begin{cases} -G_k^{-1}g_k, & \text{if } \cos \theta \geq \eta \\ -g_k, & \text{otherwise.} \end{cases}$$

# GOLDFELD修正牛顿法

## ALGORITHM 3 (修正牛顿法)

给定初始猜测点  $x_0$ ;

# GOLDFELD修正牛顿法

## ALGORITHM 3 (修正牛顿法)

给定初始猜测点  $x_0$ ;

**For**  $k = 0, 1, 2, \dots$

    构造 矩阵  $\bar{G}_k = \nabla^2 f(x_k) + v_k I$ ,

    其中  $v_k = 0$  如  $\nabla^2 f(x_k)$  正定;

    otherwise, 选择  $v_k > 0$  使得  $\bar{G}_k$  正定;

# GOLDFELD修正牛顿法

## ALGORITHM 3 (修正牛顿法)

给定初始猜测点  $x_0$ ;

**For**  $k = 0, 1, 2, \dots$

    构造 矩阵  $\bar{G}_k = \nabla^2 f(x_k) + v_k I$ ,

    其中  $v_k = 0$  如  $\nabla^2 f(x_k)$  正定;

    otherwise, 选择  $v_k > 0$  使得  $\bar{G}_k$  正定;

    求解  $\bar{G}_k p_k = -\nabla f(x_k)$ ;

# GOLDFELD修正牛顿法

## ALGORITHM 3 (修正牛顿法)

给定初始猜测点  $x_0$ ;

**For**  $k = 0, 1, 2, \dots$

    构造 矩阵  $\bar{G}_k = \nabla^2 f(x_k) + v_k I$ ,

    其中  $v_k = 0$  如  $\nabla^2 f(x_k)$  正定;

    otherwise, 选择  $v_k > 0$  使得  $\bar{G}_k$  正定;

    求解  $\bar{G}_k p_k = -\nabla f(x_k)$ ;

    令  $x_{k+1} \leftarrow x_k + \alpha_k p_k$ ,

    其中  $\alpha_k$  满足 Wolfe, Goldstein, or strong Wolfe 条件;

**End**



# GOLDFELD修正牛顿法

当 $\nabla^2 f(x_k)$ 不定时, 如何选取 $v_k$ ?

# GOLDFELD修正牛顿法

当 $\nabla^2 f(x_k)$ 不定时, 如何选取 $v_k$ ?

- 应该大于 $G_k$ 的最负特征值的绝对值.

# GOLDFELD修正牛顿法

当 $\nabla^2 f(x_k)$ 不定时, 如何选取 $v_k$ ?

- 应该大于 $G_k$ 的最负特征值的绝对值.
- 按照Gill-Murray的修改Cholesky分解( $\bar{G}_k = \bar{L}_k \bar{D}_k \bar{L}_k^T$ )算法确定 $v_k$ .

# GOLDFELD修正牛顿法

当 $\nabla^2 f(x_k)$ 不定时, 如何选取 $v_k$ ?

- 应该大于 $G_k$ 的最负特征值的绝对值.
- 按照Gill-Murray的修改Cholesky分解( $\bar{G}_k = \bar{L}_k \bar{D}_k \bar{L}_k^T$ )算法确定 $v_k$ .
- $v_k = \min\{b_1, b_2\}$  其中

$$b_1 = \left| \min_{1 \leq i \leq n} \left\{ (G_k)_{ii} - \sum_{j \neq i} |(G_k)_{ij}| \right\} \right| \geq \left| \min_i \lambda_i \right| \quad (2.16)$$

$$b_2 = \max_i \{e_{ii}\}, \text{ 其中 } e_{ii} \text{ 是 } E \text{ 的第 } i \text{ 个对角元,} \quad (2.17)$$

$E$  是  $G_k$  Gill-Murray修正Cholesky分解:  $G_k + E = LDL^T$

# GOLDFELD修正牛顿法

当 $\nabla^2 f(x_k)$ 不定时, 如何选取 $v_k$ ?

- 应该大于 $G_k$ 的最负特征值的绝对值.
- 按照Gill-Murray的修改Cholesky分解( $\bar{G}_k = \bar{L}_k \bar{D}_k \bar{L}_k^T$ )算法确定 $v_k$ .
- $v_k = \min\{b_1, b_2\}$  其中

$$b_1 = \left| \min_{1 \leq i \leq n} \left\{ (G_k)_{ii} - \sum_{j \neq i} |(G_k)_{ij}| \right\} \right| \geq \left| \min_i \lambda_i \right| \quad (2.16)$$

$$b_2 = \max_i \{e_{ii}\}, \text{ 其中 } e_{ii} \text{ 是 } \mathbf{E} \text{ 的第 } i \text{ 个对角元}, \quad (2.17)$$

$\mathbf{E}$  是  $G_k$  Gill-Murray修正Cholesky分解:  $G_k + \mathbf{E} = LDL^T$

- 如何对 $G_k + \mathbf{E}$ 做Cholesky分解?

# GOLDFELD修正牛顿法

当 $\nabla^2 f(x_k)$ 不定时, 如何选取 $v_k$ ?

- 应该大于 $G_k$ 的最负特征值的绝对值.
- 按照Gill-Murray的修改Cholesky分解( $\bar{G}_k = \bar{L}_k \bar{D}_k \bar{L}_k^T$ )算法确定 $v_k$ .
- $v_k = \min\{b_1, b_2\}$  其中

$$b_1 = \left| \min_{1 \leq i \leq n} \left\{ (G_k)_{ii} - \sum_{j \neq i} |(G_k)_{ij}| \right\} \right| \geq \left| \min_i \lambda_i \right| \quad (2.16)$$

$$b_2 = \max_i \{e_{ii}\}, \text{ 其中 } e_{ii} \text{ 是 } E \text{ 的第 } i \text{ 个对角元}, \quad (2.17)$$

$E$  是  $G_k$  Gill-Murray修正Cholesky分解:  $G_k + E = LDL^T$

- 如何对 $G_k + E$ 做Cholesky分解?
  - 先做 $G_k$ 的Cholesky分解, 再做 $\bar{G}_k = G_k + E$ 的分解 (不实用)

# GOLDFELD修正牛顿法

当 $\nabla^2 f(x_k)$ 不定时, 如何选取 $v_k$ ?

- 应该大于 $G_k$ 的最负特征值的绝对值.
- 按照Gill-Murray的修改Cholesky分解( $\bar{G}_k = \bar{L}_k \bar{D}_k \bar{L}_k^T$ )算法确定 $v_k$ .
- $v_k = \min\{b_1, b_2\}$  其中

$$b_1 = \left| \min_{1 \leq i \leq n} \left\{ (G_k)_{ii} - \sum_{j \neq i} |(G_k)_{ij}| \right\} \right| \geq \left| \min_i \lambda_i \right| \quad (2.16)$$

$$b_2 = \max_i \{e_{ii}\}, \text{ 其中 } e_{ii} \text{ 是 } E \text{ 的第 } i \text{ 个对角元}, \quad (2.17)$$

$E$  是  $G_k$  Gill-Murray修正Cholesky分解:  $G_k + E = LDL^T$

- 如何对 $G_k + E$ 做Cholesky分解?
  - 先做 $G_k$ 的Cholesky分解, 再做 $\bar{G}_k = G_k + E$ 的分解 (不实用)
  - Gill-Murray修正Cholesky分解

# 修正牛顿法

## Theorem

- 如果  $f$  在开集  $\mathcal{D}$  上二次连续可微.



# 修正牛顿法

## Theorem

- 如果  $f$  在开集  $\mathcal{D}$  上二次连续可微.
- 如果起始点  $x_0$  使水平集  $\mathcal{L} = \{x \in \mathcal{D} : f(x) \leq f(x_0)\}$  是紧的

# 修正牛顿法

## Theorem

- 如果  $f$  在开集  $\mathcal{D}$  上二次连续可微.
- 如果起始点  $x_0$  使水平集  $\mathcal{L} = \{x \in \mathcal{D} : f(x) \leq f(x_0)\}$  是紧的
- 假设修正的Cholesky分解是有界的

$$\kappa(\bar{G}_k) = \|\bar{G}_k\| \|\bar{G}_k^{-1}\| \leq C, \text{ for some } C, \quad \forall k = 0, 1, \dots$$

# 修正牛顿法

## Theorem

- 如果  $f$  在开集  $\mathcal{D}$  上二次连续可微.
- 如果起始点  $x_0$  使水平集  $\mathcal{L} = \{x \in \mathcal{D} : f(x) \leq f(x_0)\}$  是紧的
- 假设修正的Cholesky分解是有界的

$$\kappa(\bar{G}_k) = \|\bar{G}_k\| \|\bar{G}_k^{-1}\| \leq C, \text{ for some } C, \quad \forall k = 0, 1, \dots$$

- 则有

$$\lim_{k \rightarrow \infty} \nabla f(x_k) = 0.$$

# 有限差分牛顿法

- 对于无约束优化问题, 如果已有导数 $\nabla f(x)$ , 那么可以通过前向差分或者中心差分来计算Hessian.

# 有限差分牛顿法

- 对于无约束优化问题, 如果已有导数 $\nabla f(x)$ , 那么可以通过前向差分或者中心差分来计算Hessian.
- 在迭代中的第 $k$ 步, 可以计算

$$(A)_{.j} = \frac{\nabla f(x_k + h_j e_j) - \nabla f(x_k)}{h_j}, j = 1, \dots, n,$$

$$A_k = \frac{A + A^T}{2},$$

$$x_{k+1} = x_k - A_k^{-1} \nabla f(x_k),$$

$$h_j = \sqrt{\eta} \max\{|x_j|, \tilde{x}_j\} \text{sign}(x_j).$$

其中 $\tilde{x}_j$ 通常是给定的估计值,  $\eta$ 大于机器精度的很小的数.

# 有限差分牛顿法

- 对于无约束优化问题, 如果已有导数 $\nabla f(x)$ , 那么可以通过前向差分或者中心差分来计算Hessian.
- 在迭代中的第 $k$ 步, 可以计算

$$(A)_{\cdot j} = \frac{\nabla f(x_k + h_j e_j) - \nabla f(x_k)}{h_j}, j = 1, \dots, n,$$

$$A_k = \frac{A + A^T}{2},$$

$$x_{k+1} = x_k - A_k^{-1} \nabla f(x_k),$$

$$h_j = \sqrt{\eta} \max\{|x_j|, \tilde{x}_j\} \text{sign}(x_j).$$

其中 $\tilde{x}_j$ 通常是给定的估计值,  $\eta$ 大于机器精度的很小的数.

- 有时候需要计算 $\nabla^2 f(x_k)d$ , 也可以用差分法来代替, 减少计算量

$$\nabla^2 f(x_k)d \approx \frac{\nabla f(x_k + hd) - \nabla f(x_k)}{h}$$

# 有限差分牛顿法

- 对于无约束优化问题, 如果已有导数  $\nabla f(x)$ , 那么可以通过前向差分或者中心差分来计算 Hessian.
- 在迭代中的第  $k$  步, 可以计算

$$(A)_{.j} = \frac{\nabla f(x_k + h_j e_j) - \nabla f(x_k)}{h_j}, j = 1, \dots, n,$$

$$A_k = \frac{A + A^T}{2},$$

$$x_{k+1} = x_k - A_k^{-1} \nabla f(x_k),$$

$$h_j = \sqrt{\eta} \max\{|x_j|, \tilde{x}_j\} \text{sign}(x_j).$$

其中  $\tilde{x}_j$  通常是给定的估计值,  $\eta$  大于机器精度的很小的数.

- 有时候需要计算  $\nabla^2 f(x_k) d$ , 也可以用差分法来代替, 减少计算量

$$\nabla^2 f(x_k) d \approx \frac{\nabla f(x_k + h d) - \nabla f(x_k)}{h}$$

- 在一定的条件下, 这种有限差分牛顿法 仍然是二阶收敛的.

# 有限差分牛顿法



# 有限差分牛顿法

- 如果导数 $\nabla f$ 未知, 需要用差分来逼近梯度 $\nabla f$ 以及Hessian  $\nabla^2 f$ .

# 有限差分牛顿法

- 如果导数  $\nabla f$  未知, 需要用差分来逼近梯度  $\nabla f$  以及 Hessian  $\nabla^2 f$ .
- 首先逼近梯度

$$(\hat{g}_k)_j = \frac{f(x_k + h_j e_j) - f(x_k)}{h_j}, \text{ or } (\hat{g}_k)_j = \frac{f(x_k + h_j e_j) - f(x_k - h_j e_j)}{2h_j}.$$

# 有限差分牛顿法

- 如果导数 $\nabla f$ 未知, 需要用差分来逼近梯度 $\nabla f$ 以及Hessian  $\nabla^2 f$ .
- 首先逼近梯度

$$(\hat{g}_k)_j = \frac{f(x_k + h_j e_j) - f(x_k)}{h_j}, \text{ or } (\hat{g}_k)_j = \frac{f(x_k + h_j e_j) - f(x_k - h_j e_j)}{2h_j}.$$

- 逼近Hessian

$$(A_k)_{ij} = \frac{[f(x_k + h_i e_i + h_j e_j) - f(x_k + h_i e_i)] - [f(x_k + h_j e_j) - f(x_k)]}{h_i h_j}$$

$$h_j = \sqrt[3]{\eta} \max\{|x_j|, \tilde{x}_j\} \text{sign}(x_j)$$

# 有限差分牛顿法

- 如果导数 $\nabla f$ 未知, 需要用差分来逼近梯度 $\nabla f$ 以及Hessian  $\nabla^2 f$ .
- 首先逼近梯度

$$(\hat{g}_k)_j = \frac{f(x_k + h_j e_j) - f(x_k)}{h_j}, \text{ or } (\hat{g}_k)_j = \frac{f(x_k + h_j e_j) - f(x_k - h_j e_j)}{2h_j}.$$

- 逼近Hessian

$$(A_k)_{ij} = \frac{[f(x_k + h_i e_i + h_j e_j) - f(x_k + h_i e_i)] - [f(x_k + h_j e_j) - f(x_k)]}{h_i h_j}$$

$$h_j = \sqrt[3]{\eta} \max\{|x_j|, \tilde{x}_j\} \text{sign}(x_j)$$

- 此时第 $k$ 步牛顿迭代法为

$$x_{k+1} = x_k - A_k^{-1} \hat{g}_k$$

# 有限差分牛顿法

- 如果导数  $\nabla f$  未知, 需要用差分来逼近梯度  $\nabla f$  以及 Hessian  $\nabla^2 f$ .

- 首先逼近梯度

$$(\hat{g}_k)_j = \frac{f(x_k + h_j e_j) - f(x_k)}{h_j}, \text{ or } (\hat{g}_k)_j = \frac{f(x_k + h_j e_j) - f(x_k - h_j e_j)}{2h_j}.$$

- 逼近 Hessian

$$(A_k)_{ij} = \frac{[f(x_k + h_i e_i + h_j e_j) - f(x_k + h_i e_i)] - [f(x_k + h_j e_j) - f(x_k)]}{h_i h_j}$$

$$h_j = \sqrt[3]{\eta} \max\{|x_j|, \tilde{x}_j\} \text{sign}(x_j)$$

- 此时第  $k$  步牛顿迭代法为

$$x_{k+1} = x_k - A_k^{-1} \hat{g}_k$$

- 可以推导出如下收敛性

$$\begin{aligned} \|x_{k+1} - x^*\| \leq & \|A_k^{-1}\| \left( \frac{v}{2} \|x_k - x^*\|^2 + \|A_k - \nabla^2 f(x_k)\| \|x_k - x^*\| \right. \\ & \left. + \|\hat{g}_k - \nabla f(x_k)\| \right). \end{aligned}$$

## 负曲率方向

负曲率方向属于修正牛顿法, 是处理在  $\nabla^2 f(x)$  不定时, 如何寻找搜索方向

定义

设  $f: R^n \rightarrow R$  在开集  $D$  上二次连续可微

## 负曲率方向

负曲率方向属于修正牛顿法, 是处理在  $\nabla^2 f(x)$  不定时, 如何寻找搜索方向

### 定义

设  $f: R^n \rightarrow R$  在开集  $D$  上二次连续可微

- 1 如果  $\nabla^2 f(x)$  至少有一个负特征值, 则称  $x$  为不定点

## 负曲率方向

负曲率方向属于修正牛顿法, 是处理在  $\nabla^2 f(x)$  不定时, 如何寻找搜索方向

### 定义

设  $f: R^n \rightarrow R$  在开集  $D$  上二次连续可微

- ① 如果  $\nabla^2 f(x)$  至少有一个负特征值, 则称  $x$  为不定点
- ② 如果  $x$  是一个不定点, 若方向  $p$  满足  $p^T \nabla^2 f(x) p < 0$ , 则称  $p$  为  $f(x)$  在  $x$  处的负曲率方向.



## 负曲率方向

负曲率方向属于修正牛顿法, 是处理在  $\nabla^2 f(x)$  不定时, 如何寻找搜索方向

### 定义

设  $f: R^n \rightarrow R$  在开集  $D$  上二次连续可微

- ① 如果  $\nabla^2 f(x)$  至少有一个负特征值, 则称  $x$  为不定点
- ② 如果  $x$  是一个不定点, 若方向  $p$  满足  $p^T \nabla^2 f(x) p < 0$ , 则称  $p$  为  $f(x)$  在  $x$  处的负曲率方向.
- ③ 如果  $x$  为不定点,

$$s^T \nabla f(x) \leq 0, p^T \nabla f(x) \leq 0, p^T \nabla^2 f(x) p < 0$$

则称  $(s, p)$  为不定点  $x$  处的下降对.

## 负曲率方向

负曲率方向属于修正牛顿法, 是处理在  $\nabla^2 f(x)$  不定时, 如何寻找搜索方向  
定义

设  $f: R^n \rightarrow R$  在开集  $D$  上二次连续可微

- 1 如果  $\nabla^2 f(x)$  至少有一个负特征值, 则称  $x$  为不定点
- 2 如果  $x$  是一个不定点, 若方向  $p$  满足  $p^T \nabla^2 f(x) p < 0$ , 则称  $p$  为  $f(x)$  在  $x$  处的负曲率方向.
- 3 如果  $x$  为不定点,

$$s^T \nabla f(x) \leq 0, p^T \nabla f(x) \leq 0, p^T \nabla^2 f(x) p < 0$$

则称  $(s, p)$  为不定点  $x$  处的下降对.

- 4 如果  $x$  不是一个不定点,  $(s, p)$  满足

$$s^T \nabla f(x) < 0, p^T \nabla f(x) \leq 0, p^T \nabla^2 f(x) p = 0$$

则称  $(s, p)$  为  $x$  处的下降对.

# 负曲率方向

## REMARK

- 一个下降对例子

$$s = -\nabla f(x), p = \begin{cases} 0, & \text{如果 } \nabla^2 f(x) \geq 0, \\ -\text{sign}(u^T \nabla f(x))u, & \text{otherwise,} \end{cases}$$

其中  $u$  是  $\nabla^2 f(x)$  的负特征值对应的特征向量.

# 负曲率方向

## REMARK

- 一个下降对例子

$$s = -\nabla f(x), p = \begin{cases} 0, & \text{如果 } \nabla^2 f(x) \geq 0, \\ -\text{sign}(u^T \nabla f(x))u, & \text{otherwise,} \end{cases}$$

其中  $u$  是  $\nabla^2 f(x)$  的负特征值对应的特征向量.

- 显然, 当且仅当  $\nabla f(x) = 0$  且  $\nabla^2 f(x)$  半正定时, 下降对不存在.

# 负曲率方向

## REMARK

- 一个下降对例子

$$s = -\nabla f(x), p = \begin{cases} 0, & \text{如果 } \nabla^2 f(x) \geq 0, \\ -\text{sign}(u^T \nabla f(x))u, & \text{otherwise,} \end{cases}$$

其中  $u$  是  $\nabla^2 f(x)$  的负特征值对应的特征向量.

- 显然, 当且仅当  $\nabla f(x) = 0$  且  $\nabla^2 f(x)$  半正定时, 下降对不存在.
- 如果  $\nabla f(x) = 0$ , 负曲率方向是下降方向.

# 负曲率方向

## REMARK

- 一个下降对例子

$$s = -\nabla f(x), p = \begin{cases} 0, & \text{如果 } \nabla^2 f(x) \geq 0, \\ -\text{sign}(u^T \nabla f(x))u, & \text{otherwise,} \end{cases}$$

其中  $u$  是  $\nabla^2 f(x)$  的负特征值对应的特征向量.

- 显然, 当且仅当  $\nabla f(x) = 0$  且  $\nabla^2 f(x)$  半正定时, 下降对不存在.
- 如果  $\nabla f(x) = 0$ , 负曲率方向是下降方向.
- 在一般点处 ( $\nabla f(x) \neq 0$ ),
  - 如果负曲率方向  $p$  满足  $p^T \nabla f = 0$ , 则  $p$  和  $-p$  都是下降方向.
  - 如果负曲率方向  $p$  满足  $p^T \nabla f \leq 0$ , 则  $p$  是下降方向.
  - 如果负曲率方向  $p$  满足  $p^T \nabla f \geq 0$ , 则  $-p$  是下降方向.

# FIACCO-MACORMICK 法

基本思想: 当  $G_k$  阵有负特征值时, 沿着负曲率方向, 可以使目标函数值下降.

$$f(x_k + p_k) \approx f(x_k) + g_k^T p_k + \frac{1}{2} p_k^T G_k p_k,$$

$$\text{如果 } g_k^T p_k \leq 0, \quad p_k^T G_k p_k < 0.$$

# FIACCO-MACORMICK 法

基本思想: 当  $G_k$  阵有负特征值时, 沿着负曲率方向, 可以使目标函数值下降.

$$f(x_k + p_k) \approx f(x_k) + g_k^T p_k + \frac{1}{2} p_k^T G_k p_k,$$

如果  $g_k^T p_k \leq 0$ ,  $p_k^T G_k p_k < 0$ .

- 首先对  $G_k$  做Cholesky分解  $G_k = LDL^T$ , 其中  $L$  是单位下三角矩阵,  $D$  为对角矩阵.



# FIACCO-MACORMICK 法

基本思想: 当  $G_k$  阵有负特征值时, 沿着负曲率方向, 可以使目标函数值下降.

$$f(x_k + p_k) \approx f(x_k) + g_k^T p_k + \frac{1}{2} p_k^T G_k p_k,$$

$$\text{如果 } g_k^T p_k \leq 0, \quad p_k^T G_k p_k < 0.$$

- 首先对  $G_k$  做Cholesky分解  $G_k = LDL^T$ , 其中  $L$  是单位下三角矩阵,  $D$  为对角矩阵.
- 如果  $d_{ii} < 0$ , 求解  $L^T t = a$ , 其中

$$a = \begin{cases} 1, & d_{ii} \leq 0, \\ 0, & d_{ii} > 0. \end{cases}$$

# FIACCO-MACORMICK 法

基本思想: 当  $G_k$  阵有负特征值时, 沿着负曲率方向, 可以使目标函数值下降.

$$f(x_k + p_k) \approx f(x_k) + g_k^T p_k + \frac{1}{2} p_k^T G_k p_k,$$

$$\text{如果 } g_k^T p_k \leq 0, \quad p_k^T G_k p_k < 0.$$

- 首先对  $G_k$  做Cholesky分解  $G_k = LDL^T$ , 其中  $L$  是单位下三角矩阵,  $D$  为对角矩阵.
- 如果  $d_{ii} < 0$ , 求解  $L^T t = a$ , 其中

$$a = \begin{cases} 1, & d_{ii} \leq 0, \\ 0, & d_{ii} > 0. \end{cases}$$

- 则如下的  $p_k$  是负曲率下降方向

$$p_k = \begin{cases} t, & g_k^T t \leq 0, \\ -t, & g_k^T t > 0. \end{cases}$$

# FIACCO-MAcCORMICK 法

基本思想: 当  $G_k$  阵有负特征值时, 沿着负曲率方向, 可以使目标函数值下降.

$$f(x_k + p_k) \approx f(x_k) + g_k^T p_k + \frac{1}{2} p_k^T G_k p_k,$$

$$\text{如果 } g_k^T p_k \leq 0, \quad p_k^T G_k p_k < 0.$$

- 首先对  $G_k$  做Cholesky分解  $G_k = LDL^T$ , 其中  $L$  是单位下三角矩阵,  $D$  为对角矩阵.
- 如果  $d_{ii} < 0$ , 求解  $L^T t = a$ , 其中

$$a = \begin{cases} 1, & d_{ii} \leq 0, \\ 0, & d_{ii} > 0. \end{cases}$$

- 则如下的  $p_k$  是负曲率下降方向

$$p_k = \begin{cases} t, & g_k^T t \leq 0, \\ -t, & g_k^T t > 0. \end{cases}$$

- 缺点:  $d_{ii} \approx 0$  或者  $d_{ii} = 0$ .

# FLETCHER-FREEMAN 方法

如何稳定地分解对称不定矩阵?

# FLETCHER-FREEMAN方法

如何稳定地分解对称不定矩阵?

- 对于任何对称矩阵, 存在排列矩阵 $P$ 使得,  $P^T G_k P = LDL^T$ , 其中 $L$ 是单位下三角矩阵,  $D$ 是块对角矩阵, 阶数是1或者2.

# FLETCHER-FREEMAN方法

如何稳定地分解对称不定矩阵?

- 对于任何对称矩阵, 存在排列矩阵 $P$ 使得,  $P^T G_k P = LDL^T$ , 其中 $L$ 是单位下三角矩阵,  $D$ 是块对角矩阵, 阶数是1或者2.

$$D = \begin{bmatrix} * & & & & & & \\ & * & * & & & & \\ & * & * & & & & \\ & & & * & * & & \\ & & & * & * & & \\ & & & & & & * \end{bmatrix}, L = \begin{bmatrix} 1 & & & & & & \\ * & 1 & & & & & \\ * & 0 & 1 & & & & \\ * & * & * & 1 & & & \\ * & * & * & 0 & 1 & & \\ * & * & * & * & * & 1 & \end{bmatrix}$$

# FLETCHER-FREEMAN方法

如何稳定地分解对称不定矩阵?

- 对于任何对称矩阵, 存在排列矩阵 $P$ 使得,  $P^T G_k P = LDL^T$ , 其中 $L$ 是单位下三角矩阵,  $D$ 是块对角矩阵, 阶数是1或者2.

$$D = \begin{bmatrix} * & & & & & \\ & * & * & & & \\ & * & * & & & \\ & & & * & * & \\ & & & * & * & \\ & & & & & * \end{bmatrix}, L = \begin{bmatrix} 1 & & & & & \\ * & 1 & & & & \\ * & 0 & 1 & & & \\ * & * & * & 1 & & \\ * & * & * & 0 & 1 & \\ * & * & * & * & * & 1 \end{bmatrix}$$

- 求解系统 $L^T t = a$ ,

$$a_i = \begin{cases} 1, & d_{ii} \leq 0, \\ 0, & d_{ii} > 0; \end{cases} \text{ 或者 } \begin{pmatrix} a_i \\ a_{i+1} \end{pmatrix} \text{ 是 } \begin{bmatrix} d_{ii}, & d_{i,i+1} \\ d_{i+1,i} & d_{i+1,i+1} \end{bmatrix} \text{ 的单位特征向量}$$

# FLETCHER-FREEMAN方法

如何稳定地分解对称不定矩阵?

- 对于任何对称矩阵, 存在排列矩阵 $P$ 使得,  $P^T G_k P = LDL^T$ , 其中 $L$ 是单位下三角矩阵,  $D$ 是块对角矩阵, 阶数是1或者2.

$$D = \begin{bmatrix} * & & & & & \\ & * & * & & & \\ & * & * & & & \\ & & & * & * & \\ & & & * & * & \\ & & & & & * \end{bmatrix}, L = \begin{bmatrix} 1 & & & & & \\ * & 1 & & & & \\ * & 0 & 1 & & & \\ * & * & * & 1 & & \\ * & * & * & 0 & 1 & \\ * & * & * & * & * & 1 \end{bmatrix}$$

- 求解系统 $L^T t = a$ ,

$$a_i = \begin{cases} 1, & d_{ii} \leq 0, \\ 0, & d_{ii} > 0; \end{cases} \text{ 或者 } \begin{pmatrix} a_i \\ a_{i+1} \end{pmatrix} \text{ 是 } \begin{bmatrix} d_{ii} & d_{i,i+1} \\ d_{i+1,i} & d_{i+1,i+1} \end{bmatrix} \text{ 的单位特征向量}$$

- 令 $p_k = \begin{cases} t, & \text{如果 } g_k^T t \leq 0; \\ -t, & \text{如果 } g_k^T t > 0. \end{cases}$  是下降的负曲率方向. 可以验证

$$p_k^T LDL^T p_k = a^T D a = \sum \lambda_i < 0, \text{ 且 } p_k^T g_k \leq 0.$$



# FLETCHER-FREEMAN 方法

- 当  $D$  有负特征值时, 搜索方向还可以由其广义逆矩阵构造

$$p_k = -L^{-T} \tilde{D}^\dagger L^{-1} g_k$$

$$\text{其中 } \tilde{D}^\dagger \text{ 是 } \tilde{D} \text{ 的广义逆, } \tilde{D}_i = \begin{cases} d_{ii}, & \text{当 } d_{ii} > 0, \\ 0, & \text{其他.} \end{cases}$$

## FLETCHER-FREEMAN 方法

- 当  $D$  有负特征值时, 搜索方向还可以由其广义逆矩阵构造

$$p_k = -L^{-T} \tilde{D}^\dagger L^{-1} g_k$$

$$\text{其中 } \tilde{D}^\dagger \text{ 是 } \tilde{D} \text{ 的广义逆, } \tilde{D}_i = \begin{cases} d_{ii}, & \text{当 } d_{ii} > 0, \\ 0, & \text{其他.} \end{cases}$$

- 当  $D$  有零特征值时, 搜索方向  $p_k$  可以由

$$LDL^T p_k = 0, \quad g_k^T p_k < 0.$$

## FLETCHER-FREEMAN 方法

- 当  $D$  有负特征值时, 搜索方向还可以由其广义逆矩阵构造

$$p_k = -L^{-T} \tilde{D}^\dagger L^{-1} g_k$$

$$\text{其中 } \tilde{D}^\dagger \text{ 是 } \tilde{D} \text{ 的广义逆, } \tilde{D}_i = \begin{cases} d_{ii}, & \text{当 } d_{ii} > 0, \\ 0, & \text{其他.} \end{cases}$$

- 当  $D$  有零特征值时, 搜索方向  $p_k$  可以由

$$LDL^T p_k = 0, \quad g_k^T p_k < 0.$$

- 当  $D$  的特征值为正数时,  $D$  中全是一阶块. 这时就是正常的牛顿法.

# GILL-MURRAY修正CHOLESKY分解

- 传统Cholesky分解 $G = LDL^T$ , 有缺点 $d_{jj} \approx 0$

$$d_{jj} = g_{jj} - \sum_{s=1}^{j-1} d_{ss} l_{js}^2, \quad l_{ij} = \frac{1}{d_{jj}} \left( g_{ij} - \sum_{s=1}^{j-1} d_{ss} l_{js} l_{is} \right), i \geq j + 1.$$

# GILL-MURRAY修正CHOLESKY分解

- 传统Cholesky分解  $G = LDL^T$ , 有缺点  $d_{jj} \approx 0$

$$d_{jj} = g_{jj} - \sum_{s=1}^{j-1} d_{ss} l_{js}^2, \quad l_{ij} = \frac{1}{d_{jj}} \left( g_{ij} - \sum_{s=1}^{j-1} d_{ss} l_{js} l_{is} \right), i \geq j+1.$$

- 额外要求: 存在某个正数  $\delta > 0$  and  $\beta > 0$ , 使得

$$d_{jj} \geq \delta, \quad |r_{ij} = l_{ij} \sqrt{d_{jj}}| \leq \beta, \quad i \geq j.$$

# GILL-MURRAY修正CHOLESKY分解

- 传统Cholesky分解  $G = LDL^T$ , 有缺点  $d_{jj} \approx 0$

$$d_{jj} = g_{jj} - \sum_{s=1}^{j-1} d_{ss} l_{js}^2, \quad l_{ij} = \frac{1}{d_{jj}} \left( g_{ij} - \sum_{s=1}^{j-1} d_{ss} l_{js} l_{is} \right), i \geq j+1.$$

- 额外要求: 存在某个正数  $\delta > 0$  and  $\beta > 0$ , 使得

$$d_{jj} \geq \delta, \quad |r_{ij} = l_{ij} \sqrt{d_{jj}}| \leq \beta, \quad i \geq j.$$

- 假设前  $j-1$  步都满足以上额外要求, 我们看第  $j$  步(分成两步)

第一步: 计算  $\gamma_j = \left| \xi_j - \sum_{s=1}^{j-1} d_{ss} l_{js}^2 \right|$ , 其中  $\xi_j = g_{jj}$ , 然后取  $\bar{d} = \max\{\gamma_j, \delta\}$ .

第二步: 计算  $|r_{ij} = l_{ij} \sqrt{\bar{d}}|$ , 如果  $|r_{ij}| < \beta$ , 接受  $\bar{d} = d_{jj}$ ,  $l_{ij} = r_{ij} / \sqrt{d_{jj}}$

否则  $d_{jj} = \left| d_{jj} + \textcolor{red}{e}_{jj} - \sum_{s=1}^{j-1} d_{ss} l_{js}^2 \right|$ , 选择正数  $\textcolor{red}{e}_{jj}$  使得  $\max |r_{ij}| = \beta$ .

# GILL-MURRAY修正CHOLESKY分解

- 传统Cholesky分解  $G = LDL^T$ , 有缺点  $d_{jj} \approx 0$

$$d_{jj} = g_{jj} - \sum_{s=1}^{j-1} d_{ss} l_{js}^2, \quad l_{ij} = \frac{1}{d_{jj}} \left( g_{ij} - \sum_{s=1}^{j-1} d_{ss} l_{js} l_{is} \right), i \geq j+1.$$

- 额外要求: 存在某个正数  $\delta > 0$  and  $\beta > 0$ , 使得

$$d_{jj} \geq \delta, \quad |r_{ij} = l_{ij} \sqrt{d_{jj}}| \leq \beta, \quad i \geq j.$$

- 假设前  $j-1$  步都满足以上额外要求, 我们看第  $j$  步(分成两步)

第一步: 计算  $\gamma_j = \left| \xi_j - \sum_{s=1}^{j-1} d_{ss} l_{js}^2 \right|$ , 其中  $\xi_j = g_{jj}$ , 然后取  $\bar{d} = \max\{\gamma_j, \delta\}$ .

第二步: 计算  $|r_{ij} = l_{ij} \sqrt{\bar{d}}|$ , 如果  $|r_{ij}| < \beta$ , 接受  $\bar{d} = d_{jj}$ ,  $l_{ij} = r_{ij} / \sqrt{d_{jj}}$

否则  $d_{jj} = \left| d_{jj} + \textcolor{red}{e}_{jj} - \sum_{s=1}^{j-1} d_{ss} l_{js}^2 \right|$ , 选择正数  $\textcolor{red}{e}_{jj}$  使得  $\max |r_{ij}| = \beta$ .

- 本质上完成了  $\bar{G}_k = G_k + E = LDL^T$  的Cholesky分解.

# GILL-MURRAY修正CHOLESKY分解

## REMARK

- $E$ 的选择与 $\beta$ 有关. Gill-Murray证明

$$\|E(\beta)\|_{\infty} \leq \left(\frac{\xi}{\beta} + (n-1)\beta\right)^2 + 2(\gamma + (n-1)\beta^2) + \delta$$

其中 $\xi$ 是 $G_k$ 的非对角元最大模,  $\gamma$ 是 $G_k$ 的对角元最大模.



# GILL-MURRAY修正CHOLESKY分解

## REMARK

- $E$ 的选择与 $\beta$ 有关. Gill-Murray证明

$$\|E(\beta)\|_{\infty} \leq \left(\frac{\xi}{\beta} + (n-1)\beta\right)^2 + 2(\gamma + (n-1)\beta^2) + \delta$$

其中 $\xi$ 是 $G_k$ 的非对角元最大模,  $\gamma$ 是 $G_k$ 的对角元最大模.

- 当 $\beta^2 = \xi/\sqrt{n^2 - 1}$ 时, 上面的界是最小的. 因此取 $\beta$ 满足

$$\beta^2 = \max\{\gamma, \xi/\sqrt{n^2 - 1}, \varepsilon_M(\text{机器精度})\}$$

# GILL-MURRAY修正CHOLESKY分解

## REMARK

- $E$ 的选择与 $\beta$ 有关. Gill-Murray证明

$$\|E(\beta)\|_{\infty} \leq \left(\frac{\xi}{\beta} + (n-1)\beta\right)^2 + 2(\gamma + (n-1)\beta^2) + \delta$$

其中 $\xi$ 是 $G_k$ 的非对角元最大模,  $\gamma$ 是 $G_k$ 的对角元最大模.

- 当 $\beta^2 = \xi/\sqrt{n^2 - 1}$ 时, 上面的界是最小的. 因此取 $\beta$ 满足

$$\beta^2 = \max\{\gamma, \xi/\sqrt{n^2 - 1}, \varepsilon_M(\text{机器精度})\}$$

- Gill-Murray修正Cholesky分解, 保证了 $d_{jj} \geq \delta$ ,  $\bar{G}_k$ 是正定的, 其条件数 $\|\bar{G}_k\| \|\bar{G}_k^{-1}\| \leq \kappa$ 有一致的上界.

# GILL-MURRAY修正CHOLESKY分解

## GILL-MURRAY修正CHOLESKY分解算法

第一步: 确定分解因子元素的界  $\beta^2 = \max\{\gamma, \xi/\sqrt{n^2 - 1}, \varepsilon_M\}$ ,  
这里  $\gamma$  和  $\xi$  分别是  $G_k$  的对角元和非对角元最大值.

第二步: 初始化. 令  $j = 1, c_{ii} = g_{ii}$  for  $i = 1, \dots, n$ .

第三步: 求最小指标  $q$ , 使得  $|c_{qq}| = \max_{j \leq i \leq n} |c_{ii}|$ ,  
交换  $G_k$  的  $q$  行和  $j$  行,  $q$  列和  $j$  列的信息.

第四步: 计算  $L$  的第  $j$  行, 并求出  $l_{ij}d_{jj}$  的最大值:

令  $l_{js} = c_{js}/d_{ss}, s = 1, \dots, j - 1$ ;

计算  $c_{ij} = g_{ij} - \sum_{s=1}^{j-1} l_{sj}c_{is}, i = j + 1, \dots, n$ ;

令  $\theta_j = \max_{j+1 \leq i \leq n} |c_{ij}|, (\theta_j = 0 \text{ 若 } j = n)$

第五步: 计算  $D$  的第  $j$  个对角元:  $d_{jj} = \max\{\delta, |c_{jj}|, \theta_j^2/\beta^2\}$ ;  
 $E$  的对角元修改为  $E_j = d_{jj} - c_{jj}$ , 如果  $j = n$ , 则停止.

第六步: 校正对角元和列指标:

令  $c_{ii} = c_{ii} - c_{ij}^2/d_{jj}, i = j + 1, \dots, n$ ;

令  $j = j + 1$ , 转第三步.

# GILL-MURRAY 稳定牛顿法

基本思想:

(i) 当  $G_k$  不定时, 采用 Gill-Murray 修正 Cholesky 分解 强制 Hessian 正定,

# GILL-MURRAY 稳定牛顿法

基本思想:

(i) 当  $G_k$  不定时, 采用 **Gill-Murray 修正 Cholesky 分解** 强制 Hessian 正定,

$$\text{设 } \bar{G}_k = G_k + E_k = L_k D_k L_k^T, \quad D_k = \text{diag}(d_{ii}), \quad E_k = \text{diag}(e_{ii}).$$

(ii) 当  $\nabla f \rightarrow 0$  时, 采用 **负曲率方向** 使目标函数值下降.

## 构造负曲率方向算法

第一步: 令  $\psi_j = d_{jj} - e_{jj}, j = 1, \dots, n$

第二步: 求下标  $t$ , 使得  $\psi_t = \min\{\psi_j | j = 1, \dots, n\}$ .

第三步: 如果  $\psi_t \geq 0$ , 则停止; 否则, 求解方程组  $L_k^T p = e_t$ ,  
得到负曲率方向  $p$ , 其中  $e_t$  为第  $t$  个元素为 1 的单位向量.

# GILL-MURRAY 稳定牛顿法

基本思想:

(i) 当  $G_k$  不定时, 采用 **Gill-Murray 修正 Cholesky 分解** 强制 Hessian 正定,

$$\text{设 } \bar{G}_k = G_k + E_k = L_k D_k L_k^T, \quad D_k = \text{diag}(d_{ii}), \quad E_k = \text{diag}(e_{ii}).$$

(ii) 当  $\nabla f \rightarrow 0$  时, 采用 **负曲率方向** 使目标函数值下降.

## 构造负曲率方向算法

第一步: 令  $\psi_j = d_{jj} - e_{jj}$ ,  $j = 1, \dots, n$

第二步: 求下标  $t$ , 使得  $\psi_t = \min\{\psi_j | j = 1, \dots, n\}$ .

第三步: 如果  $\psi_t \geq 0$ , 则停止; 否则, 求解方程组  $L_k^T p = e_t$ ,  
得到负曲率方向  $p$ , 其中  $e_t$  为第  $t$  个元素为 1 的单位向量.

## 定理

设  $G_k$  为  $f$  在  $x_k$  处的 Hessian 矩阵,  $\bar{G}_k = G_k + E_k = L_k D_k L_k^T$ . 则上述算法产生的  $p_k$  是在  $x_k$  处的负曲率方向, 并且  $p_k$  和  $-p_k$  中至少有一个是  $x_k$  处的下降方向.

# GILL-MURRAY稳定牛顿法

## GILL-MURRAY稳定牛顿法

第一步：给定初始点 $x_0$ ,  $\varepsilon > 0$ ,  $k = 1$

第二步：计算 $g_k$ 和 $G_k$ .

第三步：使用Gill-Murray修正Cholesky分解, 得到 $L_k D_k L_k^T = G_k + E_k$

第四步：如果 $\|g_k\| \geq \varepsilon$ ,

求解方程 $L_k D_k L_k^T p_k = -g_k$ , 得到搜索方向 $p_k$ , 转第六步;

否则(即 $\|g_k\| \leq \varepsilon$ )转第五步

第五步：调用构造负曲率方向算法, 如果无负曲率方向, 则停止;

否则, 求出负曲率方向 $p_k$ 满足,

$$p_k = \begin{cases} -p_k, & g_k^T p_k > 0, \\ p_k, & \text{otherwise.} \end{cases}$$

第六步：一维搜索求 $\alpha_k$ 满足

$$f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k)$$

令 $x_{k+1} = x_k + \alpha_k p_k$ ;

第七步：若 $f(x_{k+1}) \geq f(x_k)$ , 则停止计算, 否则 $k = k + 1$ , 转第二步.

# GILL-MURRAY稳定牛顿法收敛性

## 定理：GILL-MURRAY稳定牛顿法收敛性

- 设 $f$ 二次连续可微
- 存在 $\bar{x} \in R^n$ , 使得 $L(\bar{x}) = \{x | f(x) \leq f(\bar{x})\}$  为有界闭凸集
- 以上算法中 $\varepsilon = 0$
- 则序列 $\{x_k\}$ 满足
  - ① 当 $\{x_k\}$ 为有限序列, 最后一个点是稳定点
  - ② 当 $\{x_k\}$ 为无限序列, 则必有聚点, 且所有聚点都是稳定点.



# 不精确的牛顿法

考虑非线性方程组  $F(x) = 0$ , 其中  $F: R^n \rightarrow R^n$ , 满足

- (1) 存在解  $x^*$ ,  $F(x^*) = 0$ ,
- (2)  $F$  在  $x^*$  的领域中连续可微,
- (3)  $F'(x^*)$  非奇异.

# 不精确的牛顿法

考虑非线性方程组  $F(x) = 0$ , 其中  $F: R^n \rightarrow R^n$ , 满足

- (1) 存在解  $x^*$ ,  $F(x^*) = 0$ ,
- (2)  $F$  在  $x^*$  的领域中连续可微,
- (3)  $F'(x^*)$  非奇异.
- 经典牛顿法:  $F(x_k + s) \approx F(x_k) + F'(x_k)s = 0$ ,  $s = -(F'(x_k))^{-1}F(x_k)$

# 不精确的牛顿法

考虑非线性方程组  $F(x) = 0$ , 其中  $F: R^n \rightarrow R^n$ , 满足

- (1) 存在解  $x^*$ ,  $F(x^*) = 0$ ,
- (2)  $F$  在  $x^*$  的领域中连续可微,
- (3)  $F'(x^*)$  非奇异.
- 经典牛顿法:  $F(x_k + s) \approx F(x_k) + F'(x_k)s = 0$ ,  $s = -(F'(x_k))^{-1}F(x_k)$
- 不精确牛顿法:  $F'(x_k)s = -F(x_k) + r_k$ , 其中  $\frac{\|r_k\|}{\|F(x_k)\|} \leq \eta_k$ .  
 $r_k = F'(x_k)s + F(x_k)$  表示残量,  $\eta_k$  是一个控制不精确程度的序列.

引理:  $F'$  在  $x^*$  附近非奇异

设  $F: R^n \rightarrow R^n$  在  $x^* \in D$  连续可微,  $F'(x^*)$  非奇异, 则存在  $\delta > 0, \gamma > 0, \epsilon > 0$ , 使得当  $\|y - x^*\| < \delta, y \in D$  时,  $F'$  非奇异, 且

$$\|F'(y)^{-1}\| \leq \gamma, \quad \|F'(y)^{-1} - F'(x^*)^{-1}\| \leq \epsilon.$$

# 不精确的牛顿法收敛性

## 定理：线性收敛

设  $F: R^n \rightarrow R^n$  满足假设条件(1)(2)(3). 设  $\eta_k$  满足  $0 \leq \eta_k \leq \eta_{\max} < t < 1$ . 那么, 对于某个  $\epsilon > 0$ , 如果  $\|x_0 - x^*\| < \epsilon$ , 则有不精确牛顿法产生的迭代序列  $\{x_k\}$  线性收敛到  $x^*$ ,

$$\|x_{k+1} - x^*\|_* \leq t \|x_k - x^*\|_*,$$

其中  $\|y\|_* = \|F'(x^*)^{-1}y\|$ .

# 不精确的牛顿法收敛性

## 定理：线性收敛

设  $F: R^n \rightarrow R^n$  满足假设条件(1)(2)(3). 设  $\eta_k$  满足  $0 \leq \eta_k \leq \eta_{\max} < t < 1$ . 那么, 对于某个  $\epsilon > 0$ , 如果  $\|x_0 - x^*\| < \epsilon$ , 则有不精确牛顿法产生的迭代序列  $\{x_k\}$  线性收敛到  $x^*$ ,

$$\|x_{k+1} - x^*\|_* \leq t \|x_k - x^*\|_*,$$

其中  $\|y\|_* = \|F'(x^*)^{-1}y\|$ .

## 引理

设  $\alpha = \max\{\|F'(x^*) + \frac{1}{2\beta}\|, 2\beta\}$ ,  $\beta = \|F'(x^*)^{-1}\|$ , 则当  $\|y - x^*\|$  充分小时,

$$\frac{1}{\alpha} \|y - x^*\| \leq \|F(y)\| \leq \alpha \|y - x^*\|.$$

# 不精确的牛顿法收敛性

## 定理：线性收敛

设  $F: R^n \rightarrow R^n$  满足假设条件(1)(2)(3). 设  $\eta_k$  满足  $0 \leq \eta_k \leq \eta_{\max} < t < 1$ . 那么, 对于某个  $\epsilon > 0$ , 如果  $\|x_0 - x^*\| < \epsilon$ , 则有不精确牛顿法产生的迭代序列  $\{x_k\}$  线性收敛到  $x^*$ ,

$$\|x_{k+1} - x^*\|_* \leq t \|x_k - x^*\|_*,$$

其中  $\|y\|_* = \|F'(x^*)^{-1}y\|$ .

## 引理

设  $\alpha = \max\{\|F'(x^*) + \frac{1}{2\beta}\|, 2\beta\}$ ,  $\beta = \|F'(x^*)^{-1}\|$ , 则当  $\|y - x^*\|$  充分小时,

$$\frac{1}{\alpha} \|y - x^*\| \leq \|F(y)\| \leq \alpha \|y - x^*\|.$$

## 定理：超线性收敛

假设上述定理条件都成立, 不精确牛顿法产生的序列  $\{x_k\}$  是收敛到  $x^*$ , 那么当且仅当  $\|r_k\| = o(\|F(x_k)\|)$ ,  $k \rightarrow \infty$  时,  $\{x_k\}$  超线性收敛到  $x^*$ .

THANKS FOR YOUR ATTENTION