

# PRACTICAL OPTIMIZATION ALGORITHMS

徐 翔

数学科学学院  
浙江大学

MAY 6, 2022

## CHAPTER VII: 约束优化理论

---

# 简介(INTRODUCTION)

# 简介

- 一般形式:

$$\min_{x \in R^n} f(x), \quad (7.1)$$

$$s.t. \quad \begin{cases} c_i(x) = 0, & i \in \mathcal{E} \\ c_i(x) \geq 0, & i \in \mathcal{I}. \end{cases} \quad (7.2)$$

# 简介

- 一般形式:

$$\min_{x \in R^n} f(x), \quad (7.1)$$

$$s.t. \quad \begin{cases} c_i(x) = 0, & i \in \mathcal{E} \\ c_i(x) \geq 0, & i \in \mathcal{I}. \end{cases} \quad (7.2)$$

- 可行集(feasible set)

$$\Omega = \left\{ x \mid c_i(x) = 0, x \in \mathcal{E}; c_i(x) \geq 0, x \in \mathcal{I} \right\} \quad (7.3)$$

## 简介

- 一般形式：

$$\min_{x \in R^n} f(x), \quad (7.1)$$

$$s.t. \quad \begin{cases} c_i(x) = 0, & i \in \mathcal{E} \\ c_i(x) \geq 0, & i \in \mathcal{J}. \end{cases} \quad (7.2)$$

- 可行集(feasible set)

$$\Omega = \left\{ x \mid c_i(x) = 0, x \in \mathcal{E}; c_i(x) \geq 0, x \in \mathcal{J} \right\} \quad (7.3)$$

- 写成紧凑形式

$$\min_{x \in \Omega} f(x) \quad (7.4)$$

# 局部解和全局解

- 例1

# 局部解和全局解

- 例1

$$\min_{x \in R^n} \sum_{i=1}^n x_i^2 + 2, \quad s.t. \quad \|x\|_2^2 \geq 1$$



# 局部解和全局解

- 例1

$$\min_{x \in R^n} \sum_{i=1}^n x_i^2 + 2, \quad s.t. \quad \|x\|_2^2 \geq 1$$

如果不考虑约束，显然该问题有全局最优解 $x = 0$ 。

# 局部解和全局解

## ● 例1

$$\min_{x \in R^n} \sum_{i=1}^n x_i^2 + 2, \quad s.t. \quad \|x\|_2^2 \geq 1$$

如果不考虑约束，显然该问题有全局最优解 $x = 0$ 。当考虑了约束之后，所有 $\|x\|_2^2 = 1$ 上的点都是全局最优解。当 $n \geq 2$ 时，这样的解有无穷多个。

# 局部解和全局解

- 例1

$$\min_{x \in R^n} \sum_{i=1}^n x_i^2 + 2, \quad s.t. \quad \|x\|_2^2 \geq 1$$

如果不考虑约束，显然该问题有全局最优解 $x = 0$ 。当考虑了约束之后，所有 $\|x\|_2^2 = 1$ 上的点都是全局最优解。当 $n \geq 2$ 时，这样的解有无穷多个。

- 例2

# 局部解和全局解

## ● 例1

$$\min_{x \in R^n} \sum_{i=1}^n x_i^2 + 2, \quad s.t. \quad \|x\|_2^2 \geq 1$$

如果不考虑约束，显然该问题有全局最优解  $x = 0$ 。当考虑了约束之后，所有  $\|x\|_2^2 = 1$  上的点都是全局最优解。当  $n \geq 2$  时，这样的解有无穷多个。

## ● 例2

$$\min (x_2 + 100)^2 + 0.01x_1^2, \quad s.t. \quad x_2 - \cos x_1 \geq 0.$$

# 局部解和全局解

## ● 例1

$$\min_{x \in R^n} \sum_{i=1}^n x_i^2 + 2, \quad s.t. \quad \|x\|_2^2 \geq 1$$

如果不考虑约束，显然该问题有全局最优解 $x = 0$ 。当考虑了约束之后，所有 $\|x\|_2^2 = 1$ 上的点都是全局最优解。当 $n \geq 2$ 时，这样的解有无穷多个。

## ● 例2

$$\min (x_2 + 100)^2 + 0.01x_1^2, \quad s.t. \quad x_2 - \cos x_1 \geq 0.$$

如果不考虑约束，显然该问题有全局最优解 $x = (0, -100)^T$ 。

# 局部解和全局解

## ● 例1

$$\min_{x \in R^n} \sum_{i=1}^n x_i^2 + 2, \quad s.t. \quad \|x\|_2^2 \geq 1$$

如果不考虑约束，显然该问题有全局最优解 $x = 0$ 。当考虑了约束之后，所有 $\|x\|_2^2 = 1$ 上的点都是全局最优解。当 $n \geq 2$ 时，这样的解有无穷多个。

## ● 例2

$$\min (x_2 + 100)^2 + 0.01x_1^2, \quad s.t. \quad x_2 - \cos x_1 \geq 0.$$

如果不考虑约束，显然该问题有全局最优解 $x = (0, -100)^T$ 。当考虑了约束之后，在 $x^{(k)} = (k\pi, -1)^T$ ,  $k = \pm 1, \pm 3, \dots$ 附近都是局部最小值点。

# 局部解和全局解

## ● 例1


$$\min_{x \in \mathbb{R}^n} \sum_{i=1}^n x_i^2 + 2, \quad s.t. \quad \|x\|_2^2 \geq 1$$

如果不考虑约束，显然该问题有全局最优解  $x = 0$ 。当考虑了约束之后，所有  $\|x\|_2^2 = 1$  上的点都是全局最优解。当  $n \geq 2$  时，这样的解有无穷多个。

## ● 例2

$$\min (x_2 + 100)^2 + 0.01x_1^2, \quad s.t. \quad x_2 - \cos x_1 \geq 0.$$

如果不考虑约束，显然该问题有全局最优解  $x = (0, -100)^T$ 。当考虑了约束之后，在  $x^{(k)} = (k\pi, -1)^T$ ,  $k = \pm 1, \pm 3, \dots$  附近都是局部最小值点。



# 局部解和全局解

## 定义

- ① 向量 $x^*$ 被称为是(7.4)的一个局部最优解：



# 局部解和全局解

## 定义

- ① 向量 $x^*$ 被称为是(7.4)的一个局部最优解：若  $x \in \Omega$ ，且存在 $x^*$ 的邻域 $\mathcal{N}$ ，满足 $x \in \mathcal{N} \cap \Omega$ 时，有 $f(x) \geq f(x^*)$ 。

# 局部解和全局解

## 定义

- ① 向量 $x^*$ 被称为是(7.4)的一个局部最优解：若  $x \in \Omega$ ，且存在 $x^*$ 的邻域 $\mathcal{N}$ ，满足 $x \in \mathcal{N} \cap \Omega$ 时，有 $f(x) \geq f(x^*)$ 。
- ② 向量 $x^*$ 被称为是(7.4)的一个严格局部最优解：

# 局部解和全局解

## 定义

- ① 向量 $x^*$ 被称为是(7.4)的一个局部最优解: 若  $x \in \Omega$ , 且存在 $x^*$ 的邻域 $\mathcal{N}$ , 满足 $x \in \mathcal{N} \cap \Omega$ 时, 有 $f(x) \geq f(x^*)$ 。
- ② 向量 $x^*$ 被称为是(7.4)的一个严格局部最优解: 若  $x \in \Omega$ , 且存在 $x^*$ 的邻域 $\mathcal{N}$ , 满足 $x \in \mathcal{N} \cap \Omega$ 且 $x \neq x^*$ 时, 有 $f(x) > f(x^*)$ 。

# 局部解和全局解

## 定义

- ① 向量 $x^*$ 被称为是(7.4)的一个局部最优解: 若  $x \in \Omega$ , 且存在 $x^*$ 的邻域 $\mathcal{N}$ , 满足 $x \in \mathcal{N} \cap \Omega$ 时, 有 $f(x) \geq f(x^*)$ 。
- ② 向量 $x^*$ 被称为是(7.4)的一个严格局部最优解: 若  $x \in \Omega$ , 且存在 $x^*$ 的邻域 $\mathcal{N}$ , 满足 $x \in \mathcal{N} \cap \Omega$ 且 $x \neq x^*$ 时, 有 $f(x) > f(x^*)$ 。
- ③ 向量 $x^*$ 被称为是(7.4)的一个孤立局部最优解:

# 局部解和全局解

## 定义

- ① 向量 $x^*$ 被称为是(7.4)的一个局部最优解: 若  $x \in \Omega$ , 且存在 $x^*$ 的邻域 $\mathcal{N}$ , 满足 $x \in \mathcal{N} \cap \Omega$ 时, 有 $f(x) \geq f(x^*)$ 。
- ② 向量 $x^*$ 被称为是(7.4)的一个严格局部最优解: 若  $x \in \Omega$ , 且存在 $x^*$ 的邻域 $\mathcal{N}$ , 满足 $x \in \mathcal{N} \cap \Omega$ 且 $x \neq x^*$ 时, 有 $f(x) > f(x^*)$ 。
- ③ 向量 $x^*$ 被称为是(7.4)的一个孤立局部最优解: 若  $x \in \Omega$ , 且存在 $x^*$ 的邻域 $\mathcal{N}$ , 满足 $x^*$ 是 $\mathcal{N} \cap \Omega$ 中唯一的局部最优解。

# 光滑性

- 光滑性可以保证目标函数和约束条件具有合理的可预测性，可以在算法中选取好的搜索方向。

# 光滑性

- 光滑性可以保证 **目标函数** 和 **约束条件** 具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

# 光滑性

- 光滑性可以保证 **目标函数** 和 **约束条件** 具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$



# 光滑性

- 光滑性可以保证 **目标函数** 和 **约束条件** 具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$

$$x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, -x_1 + x_2 \leq 1, -x_1 - x_2 \leq 1.$$

# 光滑性

- 光滑性可以保证目标函数和约束条件具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$

$$x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, -x_1 + x_2 \leq 1, -x_1 - x_2 \leq 1.$$

显然，以上约束函数每一个都是光滑的，但是它们构成的可行域实际是一个菱形。

# 光滑性

- 光滑性可以保证 **目标函数**和**约束条件**具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$

$$x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, -x_1 + x_2 \leq 1, -x_1 - x_2 \leq 1.$$

显然，以上约束函数每一个都是光滑的，但是它们构成的可行域实际是一个菱形。

- 不光滑的无约束优化问题，有时可以转为等价的光滑约束问题。

# 光滑性

- 光滑性可以保证 **目标函数** 和 **约束条件** 具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$

$$x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, -x_1 + x_2 \leq 1, -x_1 - x_2 \leq 1.$$

显然，以上约束函数每一个都是光滑的，但是它们构成的可行域实际是一个菱形。

- 不光滑的无约束优化问题，有时可以转为等价的光滑约束问题。

$$\min f(x) = \max(x^2, x).$$

# 光滑性

- 光滑性可以保证目标函数和约束条件具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$

$$x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, -x_1 + x_2 \leq 1, -x_1 - x_2 \leq 1.$$

显然，以上约束函数每一个都是光滑的，但是它们构成的可行域实际是一个菱形。

- 不光滑的无约束优化问题，有时可以转为等价的光滑约束问题。

$$\min f(x) = \max(x^2, x).$$

它的目标函数有两个尖点，位置在 $x = 0$ 和 $x = 1$ ，

# 光滑性

- 光滑性可以保证 **目标函数** 和 **约束条件** 具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$

$$x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, -x_1 + x_2 \leq 1, -x_1 - x_2 \leq 1.$$

显然，以上约束函数每一个都是光滑的，但是它们构成的可行域实际是一个菱形。

- 不光滑的无约束优化问题，有时可以转为等价的光滑约束问题。

$$\min f(x) = \max(x^2, x).$$

它的目标函数有两个尖点，位置在  $x = 0$  和  $x = 1$ ，而  $x^* = 0$  是全局最优解。

# 光滑性

- 光滑性可以保证目标函数和约束条件具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$

$$x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, -x_1 + x_2 \leq 1, -x_1 - x_2 \leq 1.$$

显然，以上约束函数每一个都是光滑的，但是它们构成的可行域实际是一个菱形。

- 不光滑的无约束优化问题，有时可以转为等价的光滑约束问题。

$$\min f(x) = \max(x^2, x).$$

它的目标函数有两个尖点，位置在 $x = 0$ 和 $x = 1$ ，而 $x^* = 0$ 是全局最优解。等价地，可以将其转为光滑的约束优化问题：

# 光滑性

- 光滑性可以保证目标函数和约束条件具有合理的可预测性，可以在算法中选取好的搜索方向。
- 即便全部约束函数都是光滑的，也不表示可行域一定有光滑的边界。

$$\|x\|_1 = |x_1| + |x_2| \leq 1.$$

$$x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, -x_1 + x_2 \leq 1, -x_1 - x_2 \leq 1.$$

显然，以上约束函数每一个都是光滑的，但是它们构成的可行域实际是一个菱形。

- 不光滑的无约束优化问题，有时可以转为等价的光滑约束问题。

$$\min f(x) = \max(x^2, x).$$

它的目标函数有两个尖点，位置在 $x = 0$ 和 $x = 1$ ，而 $x^* = 0$ 是全局最优解。等价地，可以将其转为光滑的约束优化问题：

$$\begin{aligned} \min \quad & t, \\ \text{s.t.} \quad & t \geq x, t \geq x^2. \end{aligned}$$



# 第一个例子


例1：一个等值约束

$$\begin{array}{ll}\min & x_1 + x_2 \\ s.t. & x_1^2 + x_2^2 - 2 = 0.\end{array}$$

# 第一个例子

例1：一个等值约束


$$\begin{array}{ll}\min & x_1 + x_2 \\ s.t. & x_1^2 + x_2^2 - 2 = 0.\end{array}$$



# 第一个例子

例1：一个等值约束

$$\begin{array}{ll}\min & x_1 + x_2 \\ s.t. & x_1^2 + x_2^2 - 2 = 0.\end{array}$$




- 全局最优解  $(-1, -1)^T$

# 第一个例子

例1：一个等值约束

$$\begin{array}{ll} \min & x_1 + x_2 \\ \text{s.t.} & x_1^2 + x_2^2 - 2 = 0. \end{array}$$




- 全局最优解  $(-1, -1)^T$
- $x^*$ 的一个性质是  $\nabla f$  和  $\nabla c_1$  平行，但方向相反，这一点是必要条件吗？

# 第一个例子

例1：一个等值约束

$$\begin{array}{ll}\min & x_1 + x_2 \\ \text{s.t.} & x_1^2 + x_2^2 - 2 = 0.\end{array}$$




- 全局最优解  $(-1, -1)^T$
- $x^*$  的一个性质是  $\nabla f$  和  $\nabla c_1$  平行，但方向相反，这一点是必要条件吗？
- 我们在  $c_1$  上取任何非  $x^*$  的点，让  $x$  保持在可行域内部的线性方向都有两个，一个顺时针，一个逆时针。这两个方向中，总有一个是和  $-\nabla f$  成锐角的，也即是  $f$  的下降方向。直到  $x^*$  点， $\nabla c_1$  和  $f$  平行，这时沿  $c_1$  的任何移动方向，都和  $\nabla f$  成直角，即  $f$  不会下降。

# 第一个例子

例1：一个等值约束

$$\begin{array}{ll}\min & x_1 + x_2 \\ \text{s.t.} & x_1^2 + x_2^2 - 2 = 0.\end{array}$$



- 全局最优解  $(-1, -1)^T$
- $x^*$ 的一个性质是  $\nabla f$  和  $\nabla c_1$  平行，但方向相反，这一点是必要条件吗？
- 我们在  $c_1$  上取任何非  $x^*$  的点，让  $x$  保持在可行域内部的线性方向都有两个，一个顺时针，一个逆时针。这两个方向中，总有一个是和  $-\nabla f$  成锐角的，也即是  $f$  的下降方向。直到  $x^*$  点， $\nabla c_1$  和  $f$  平行，这时沿  $c_1$  的任何移动方向，都和  $\nabla f$  成直角，即  $f$  不会下降。
- $x^*$  真正满足的条件是：

$$\left\{ x^* \text{ 处的可行方向} \right\} \cap \left\{ f \text{ 在 } x^* \text{ 处的下降方向} \right\} = \emptyset$$

# 第一个例子

## 严格化分析

- $\forall x \in \Omega$ , 保持 $x$ 停留在 $\Omega$ 内部的可行方向 $d$ , 满足  $c_1(x + d) = 0$ .

# 第一个例子

## 严格化分析

- $\forall x \in \Omega$ , 保持 $x$ 停留在 $\Omega$ 内部的可行方向 $d$ , 满足  $c_1(x + d) = 0$ .
- 由泰勒展开知道, 有  $0 = c_1(x + d) \approx c_1(x) + \nabla c_1(x)^T d = \nabla c_1(x)^T d$



# 第一个例子

## 严格化分析

- $\forall x \in \Omega$ , 保持 $x$ 停留在 $\Omega$ 内部的可行方向 $d$ , 满足  $c_1(x+d) = 0$ .
- 由泰勒展开知道, 有  $0 = c_1(x+d) \approx c_1(x) + \nabla c_1(x)^T d = \nabla c_1(x)^T d$
- 若 $x$ 不是 $f$ 的局部最小值点, 则从 $x$ 出发, 在可行域内部必有 $f$ 的下降方向, 同样在Taylor展开下, 有

$$0 > f(x+d) - f(x) \approx \nabla f(x)^T d \rightarrow \nabla f(x)^T d < 0.$$

# 第一个例子

## 严格化分析

- $\forall x \in \Omega$ , 保持 $x$ 停留在 $\Omega$ 内部的可行方向 $d$ , 满足  $c_1(x+d) = 0$ .
- 由泰勒展开知道, 有  $0 = c_1(x+d) \approx c_1(x) + \nabla c_1(x)^T d = \nabla c_1(x)^T d$
- 若 $x$ 不是 $f$ 的局部最小值点, 则从 $x$ 出发, 在可行域内部必有 $f$ 的下降方向, 同样在Taylor展开下, 有

$$0 > f(x+d) - f(x) \approx \nabla f(x)^T d \rightarrow \nabla f(x)^T d < 0.$$

- 于是, 如果以上两个同时成立, 我们就可以找到一个从 $x$ 出发的方向 $d$ , 沿此方向: (1)  $x+d$ 停留在 $\Omega$ 内部; (2)  $f(x)$ 继续下降。

# 第一个例子

## 严格化分析

- $\forall x \in \Omega$ , 保持 $x$ 停留在 $\Omega$ 内部的可行方向 $d$ , 满足  $c_1(x+d) = 0$ .
- 由泰勒展开知道, 有  $0 = c_1(x+d) \approx c_1(x) + \nabla c_1(x)^T d = \nabla c_1(x)^T d$
- 若 $x$ 不是 $f$ 的局部最小值点, 则从 $x$ 出发, 在可行域内部必有 $f$ 的下降方向, 同样在Taylor展开下, 有

$$0 > f(x+d) - f(x) \approx \nabla f(x)^T d \rightarrow \nabla f(x)^T d < 0.$$

- 于是, 如果以上两个同时成立, 我们就可以找到一个从 $x$ 出发的方向 $d$ , 沿此方向: (1)  $x+d$ 停留在 $\Omega$ 内部; (2)  $f(x)$ 继续下降。
- 如果 $x$ 是问题的解, 那么上述两点一定不能同时成立。这其实已经给了我们一阶必要性条件: 唯有 $\nabla c_1$ 和  $\nabla f$  平行, 才不会出现既可行又下降的方向, 即

$$\nabla f(x) = \lambda \nabla c_1(x), \lambda \in R.$$

。

# 第一个例子

## 严格化分析

- $\forall x \in \Omega$ , 保持 $x$ 停留在 $\Omega$ 内部的可行方向 $d$ , 满足  $c_1(x+d) = 0$ .
- 由泰勒展开知道, 有  $0 = c_1(x+d) \approx c_1(x) + \nabla c_1(x)^T d = \nabla c_1(x)^T d$
- 若 $x$ 不是 $f$ 的局部最小值点, 则从 $x$ 出发, 在可行域内部必有 $f$ 的下降方向, 同样在Taylor展开下, 有

$$0 > f(x+d) - f(x) \approx \nabla f(x)^T d \rightarrow \nabla f(x)^T d < 0.$$

- 于是, 如果以上两个同时成立, 我们就可以找到一个从 $x$ 出发的方向 $d$ , 沿此方向: (1)  $x+d$ 停留在 $\Omega$ 内部; (2)  $f(x)$ 继续下降。
- 如果 $x$ 是问题的解, 那么上述两点一定不能同时成立。这其实已经给了我们一阶必要性条件: 唯有 $\nabla c_1$ 和  $\nabla f$  平行, 才不会出现既可行又下降的方向, 即

$$\nabla f(x) = \lambda \nabla c_1(x), \lambda \in R.$$

。

# 第一个例子

## 严格化分析

- 引入Lagrange乘子函数

$$L(x, \lambda_1) := f(x) - \lambda_1 c_1(x)$$

# 第一个例子

## 严格化分析

- 引入Lagrange乘子函数

$$L(x, \lambda_1) := f(x) - \lambda_1 c_1(x)$$

- 则平行条件等价于

$$\nabla_x L(x, \lambda_1) = \nabla f(x) - \lambda_1 \nabla c_1(x) = 0$$

# 第一个例子

## 严格化分析

- 引入Lagrange乘子函数

$$L(x, \lambda_1) := f(x) - \lambda_1 c_1(x)$$

- 则平行条件等价于

$$\nabla_x L(x, \lambda_1) = \nabla f(x) - \lambda_1 \nabla c_1(x) = 0$$

- 于是，非约束优化问题的解的**必要条件**可以表述为：

$$\text{存在 } \lambda_1^* \in R, \text{ 使得 } \nabla_x L(x^*, \lambda_1^*) = 0$$

这里 $\lambda_1$ 称为约束条件 $c_1(x) = 0$ 对应的**Lagrange乘子**(Lagrange Multiplier)。

# 第一个例子

## 严格化分析

- 引入Lagrange乘子函数

$$L(x, \lambda_1) := f(x) - \lambda_1 c_1(x)$$

- 则平行条件等价于

$$\nabla_x L(x, \lambda_1) = \nabla f(x) - \lambda_1 \nabla c_1(x) = 0$$

- 于是，非约束优化问题的解的**必要条件**可以表述为：

$$\text{存在 } \lambda_1^* \in R, \text{ 使得 } \nabla_x L(x^*, \lambda_1^*) = 0$$

这里 $\lambda_1$ 称为约束条件 $c_1(x) = 0$ 对应的**Lagrange乘子**(Lagrange Multiplier)。

- 显然，这个条件是**非充分**的。



# 第一个例子

## 严格化分析

- 引入Lagrange乘子函数

$$L(x, \lambda_1) := f(x) - \lambda_1 c_1(x)$$

- 则平行条件等价于

$$\nabla_x L(x, \lambda_1) = \nabla f(x) - \lambda_1 \nabla c_1(x) = 0$$

- 于是，非约束优化问题的解的**必要条件**可以表述为：

$$\text{存在 } \lambda_1^* \in R, \text{ 使得 } \nabla_x L(x^*, \lambda_1^*) = 0$$

这里 $\lambda_1$ 称为约束条件 $c_1(x) = 0$ 对应的**Lagrange乘子**(Lagrange Multiplier)。

- 显然，这个条件是**非充分的**。比如该例子还有一个可行点 $(1, 1)^T$ 也满足这个条件，但是它是极大值点。

# 第一个例子

## 严格化分析

- 引入Lagrange乘子函数

$$L(x, \lambda_1) := f(x) - \lambda_1 c_1(x)$$

- 则平行条件等价于

$$\nabla_x L(x, \lambda_1) = \nabla f(x) - \lambda_1 \nabla c_1(x) = 0$$

- 于是，非约束优化问题的解的**必要条件**可以表述为：

$$\text{存在 } \lambda_1^* \in R, \text{ 使得 } \nabla_x L(x^*, \lambda_1^*) = 0$$


这里 $\lambda_1$ 称为约束条件 $c_1(x) = 0$ 对应的**Lagrange乘子**(Lagrange Multiplier)。

- 显然，这个条件是**非充分的**。比如该例子还有一个可行点 $(1, 1)^T$ 也满足这个条件，但是它是极大值点。而且 $\lambda_1^*$ 的符号并不能说明 $x^*$ 的极值性质，因为 $c_1(x) = x_1^2 + x_2^2 - 2 = 0$  或者  $c_1(x) = 2 - x_1^2 - x_2^2 = 0$ 。从而 $x^* = (-1, -1)^T$ 处的 $\lambda_1^*$ 值从 $-\frac{1}{2}$ 变为 $\frac{1}{2}$ 。

## 第二个例子

例2：一个不等值约束的优化


$$\begin{array}{ll}\min & x_1 + x_2 \\ \text{s.t.} & 2 - x_1^2 - x_2^2 \geq 0\end{array}$$



## 第二个例子

例2：一个不等值约束的优化

$$\begin{array}{ll}\min & x_1 + x_2 \\ \text{s.t.} & 2 - x_1^2 - x_2^2 \geq 0\end{array}$$




- 可行域变为圆的内部和边界，最优解还是 $(-1, -1)^T$ 。

## 第二个例子

例2：一个不等值约束的优化

$$\begin{array}{ll}\min & x_1 + x_2 \\ \text{s.t.} & 2 - x_1^2 - x_2^2 \geq 0\end{array}$$




- 可行域变为圆的内部和边界，最优解还是 $(-1, -1)^T$ 。

## 第二个例子

例2：一个不等值约束的优化

$$\begin{aligned} \min \quad & x_1 + x_2 \\ \text{s.t.} \quad & 2 - x_1^2 - x_2^2 \geq 0 \end{aligned}$$




- 可行域变为圆的内部和边界，最优解还是 $(-1, -1)^T$ 。
- $\forall x \in \Omega$ ，现在确保 $x + d$ 留在 $\Omega$ 内的搜索方向在泰勒展开中：

$$0 \leq c_1(x + d) \approx c_1(x) + \nabla c_1(x)^T d$$

## 第二个例子

例2：一个不等值约束的优化

$$\begin{aligned} \min \quad & x_1 + x_2 \\ \text{s.t.} \quad & 2 - x_1^2 - x_2^2 \geq 0 \end{aligned}$$



- 可行域变为圆的内部和边界，最优解还是 $(-1, -1)^T$ 。
- $\forall x \in \Omega$ ，现在确保 $x + d$ 留在 $\Omega$ 内的搜索方向在泰勒展开中：

$$0 \leq c_1(x + d) \approx c_1(x) + \nabla c_1(x)^T d$$


- 现在无法消去第一项 $c_1(x)$ ，完整的一阶可行方向条件是

$$c_1(x) + \nabla c_1(x)^T d \geq 0$$

## 第二个例子

例2： 一个不等值约束的优化

$$\begin{array}{ll}\min & x_1 + x_2 \\ \text{s.t.} & 2 - x_1^2 - x_2^2 \geq 0\end{array}$$



- 可行域变为圆的内部和边界，最优解还是 $(-1, -1)^T$ 。
- $\forall x \in \Omega$ ，现在确保 $x + d$ 留在 $\Omega$ 内的搜索方向在泰勒展开中：

$$0 \leq c_1(x + d) \approx c_1(x) + \nabla c_1(x)^T d$$

- 现在无法消去第一项 $c_1(x)$ ，完整的一阶可行方向条件是

$$c_1(x) + \nabla c_1(x)^T d \geq 0$$

- 使得 $f$ 下降的方向仍然是

$$\nabla f(x)^T d < 0.$$



## 第二个例子

例2：分两种情况讨论

## 第二个例子

例2：分两种情况讨论

- $x$ 在 $\Omega$ 内部，即 $c_1(x) > 0$ 。

## 第二个例子

例2: 分两种情况讨论

- $x$  在  $\Omega$  内部, 即  $c_1(x) > 0$ 。此时任何  $d$  都是可行方向,

## 第二个例子

例2：分两种情况讨论

- $x$ 在 $\Omega$ 内部，即 $c_1(x) > 0$ 。此时任何 $d$ 都是可行方向，如果从 $x^*$ 出发的方向都不能同时满足两个条件（即交集是空集），那么只剩下唯一的可能

## 第二个例子

例2：分两种情况讨论

- $x$ 在 $\Omega$ 内部，即 $c_1(x) > 0$ 。此时任何 $d$ 都是可行方向，如果从 $x^*$ 出发的方向都不能同时满足两个条件（即交集是空集），那么只剩下唯一的可能

$$\nabla f(x^*) = 0$$

## 第二个例子

例2：分两种情况讨论

- $x$ 在 $\Omega$ 内部，即 $c_1(x) > 0$ 。此时任何 $d$ 都是可行方向，如果从 $x^*$ 出发的方向都**不能同时满足两个条件**（即交集是空集），那么只剩下唯一的可能

$$\nabla f(x^*) = 0$$

这是无约束问题下对应的必要条件。

## 第二个例子

### 例2：分两种情况讨论

- $x$ 在 $\Omega$ 内部，即 $c_1(x) > 0$ 。此时任何 $d$ 都是可行方向，如果从 $x^*$ 出发的方向都**不能同时满足两个条件**（即交集是空集），那么只剩下唯一的可能

$$\nabla f(x^*) = 0$$

这是无约束问题下对应的必要条件。

- $x$ 在 $\Omega$ 边界，也就是 $c_1(x) = 0$ 。此时又回到第一例子的情形，如果 $x$ 出发还存在优化的可能方向 $d$ ，必须满足

$$\nabla f(x)^T d < 0, \nabla c_1(x)^T d \geq 0.$$

## 第二个例子

### 例2：分两种情况讨论

- $x$ 在 $\Omega$ 内部，即 $c_1(x) > 0$ 。此时任何 $d$ 都是可行方向，如果从 $x^*$ 出发的方向都**不能同时满足两个条件**（即交集是空集），那么只剩下唯一的可能

$$\nabla f(x^*) = 0$$

这是无约束问题下对应的必要条件。

- $x$ 在 $\Omega$ 边界，也就是 $c_1(x) = 0$ 。此时又回到第一例子的情形，如果 $x$ 出发还存在优化的可能方向 $d$ ，必须满足

$$\nabla f(x)^T d < 0, \nabla c_1(x)^T d \geq 0.$$

此时第一不等式限定了半个平面，



## 第二个例子

### 例2：分两种情况讨论

- $x$ 在 $\Omega$ 内部，即 $c_1(x) > 0$ 。此时任何 $d$ 都是可行方向，如果从 $x^*$ 出发的方向都**不能同时满足两个条件**（即交集是空集），那么只剩下唯一的可能

$$\nabla f(x^*) = 0$$

这是无约束问题下对应的必要条件。

- $x$ 在 $\Omega$ 边界，也就是 $c_1(x) = 0$ 。此时又回到第一例子的情形，如果 $x$ 出发还存在优化的可能方向 $d$ ，必须满足

$$\nabla f(x)^T d < 0, \nabla c_1(x)^T d \geq 0.$$

此时第一不等式限定了半个平面，第二个不等式限定了另外半个平面（包含边界）。

## 第二个例子

### 例2：分两种情况讨论

- $x$ 在 $\Omega$ 内部，即 $c_1(x) > 0$ 。此时任何 $d$ 都是可行方向，如果从 $x^*$ 出发的方向都**不能同时满足两个条件**（即交集是空集），那么只剩下唯一的可能

$$\nabla f(x^*) = 0$$

这是无约束问题下对应的必要条件。

- $x$ 在 $\Omega$ 边界，也就是 $c_1(x) = 0$ 。此时又回到第一例子的情形，如果 $x$ 出发还存在优化的可能方向 $d$ ，必须满足

$$\nabla f(x)^T d < 0, \nabla c_1(x)^T d \geq 0.$$

此时第一不等式限定了半个平面，第二个不等式限定了另外半个平面（包含边界）。要使得两个半平面相交为**空集**，唯有 $\nabla f$ 和 $\nabla c_1(x)$ 是同一个方向(比平行更严格)，即

$$\nabla f(x) = \lambda_1 \nabla c_1(x), \lambda_1 \geq 0$$

## 第二个例子

总结以上两种情况，可以统一地表示为：

- 当 $x^*$ 没有可行的下降方向时，存在 $\lambda_1^*$ ，使得

$$\nabla_x L(x^*, \lambda_1^*) = 0, \lambda_1^* \geq 0$$

并且

$$\lambda_1^* c_1(x) = 0$$

- 这个条件被称为 **互补性条件(complementarity condition)**。

## 第二个例子

总结以上两种情况，可以统一地表示为：

- 当 $x^*$ 没有可行的下降方向时，存在 $\lambda_1^*$ ，使得

$$\nabla_x L(x^*, \lambda_1^*) = 0, \lambda_1^* \geq 0$$

并且

$$\lambda_1^* c_1(x) = 0$$

- 这个条件被称为**互补性条件(complementarity condition)**。它要求 $\lambda_1^*$ 和 $c_1(x^*)$ 至少有一个为零。前者对应情况 $x^*$ 落在 $\Omega$ 内，后者对应情况 $x^*$ 落在 $\Omega$ 边界上。
- 如果对于一个可行点 $x$ ，其对应的不等值约束 $c_i(x) \neq 0$ ，那么实际上这个约束对 $x$ 是无效的。

## 第二个例子

总结以上两种情况，可以统一地表示为：

- 当 $x^*$ 没有可行的下降方向时，存在 $\lambda_1^*$ ，使得

$$\nabla_x L(x^*, \lambda_1^*) = 0, \lambda_1^* \geq 0$$

并且

$$\lambda_1^* c_1(x) = 0$$

- 这个条件被称为**互补性条件(complementarity condition)**。它要求 $\lambda_1^*$ 和 $c_1(x^*)$ 至少有一个为零。前者对应情况 $x^*$ 落在 $\Omega$ 内，后者对应情况 $x^*$ 落在 $\Omega$ 边界上。
- 如果对于一个可行点 $x$ ，其对应的不等值约束 $c_i(x) \neq 0$ ，那么实际上这个约束对 $x$ 是无效的。只有正好处在边界的约束，对一个点是否是最优值点的判定才会有意义。

# 活跃集

定义: 活跃集(active set, 也称为有效集、积极集)

下标集合 $\mathcal{A}(x)$ 称为点 $x$ 的活跃集(也被称为积极集), 是有全部等值约束的下标、在 $x$ 点满足 $c_i(x) = 0$ 的不等值约束的下标组成。即

$$\mathcal{A}(x) = \mathcal{E} \cup \{i \in \mathcal{I} | c_i(x) = 0\}.$$

## 第三个例子


例3: 两个不等式约束

$$\begin{array}{ll}\min & x_1 + x_2 \\ \text{s.t.} & 2 - x_1^2 - x_2^2 \geq 0 \\ & x_2 \geq 0.\end{array}$$

# 第三个例子

例3：两个不等式约束

$$\begin{aligned} \min \quad & x_1 + x_2 \\ \text{s.t.} \quad & 2 - x_1^2 - x_2^2 \geq 0 \\ & x_2 \geq 0. \end{aligned}$$






# 第三个例子

例3：两个不等式约束

$$\begin{aligned} \min \quad & x_1 + x_2 \\ \text{s.t.} \quad & 2 - x_1^2 - x_2^2 \geq 0 \\ & x_2 \geq 0. \end{aligned}$$




- 显然最优解  $x^* = (-\sqrt{2}, 0)^T$ 。

## 第三个例子

例3：两个不等式约束

$$\begin{aligned} \min \quad & x_1 + x_2 \\ \text{s.t.} \quad & 2 - x_1^2 - x_2^2 \geq 0 \\ & x_2 \geq 0. \end{aligned}$$




- 显然最优解  $x^* = (-\sqrt{2}, 0)^T$ 。
- 两个约束都是活跃的。

## 第三个例子

例3：两个不等式约束

$$\begin{aligned} \min \quad & x_1 + x_2 \\ \text{s.t.} \quad & 2 - x_1^2 - x_2^2 \geq 0 \\ & x_2 \geq 0. \end{aligned}$$




- 显然最优解  $x^* = (-\sqrt{2}, 0)^T$ 。
- 两个约束都是活跃的。
- 如果它不是一个最优值点（意味着从它出发还有进一步可以下降的方向），那么必然有  $d$  方向满足

$$\nabla c_i(x)^T d \geq 0, \quad \nabla f(x)^T d < 0.$$

## 第三个例子

例3：两个不等式约束

$$\begin{aligned} \min \quad & x_1 + x_2 \\ \text{s.t.} \quad & 2 - x_1^2 - x_2^2 \geq 0 \\ & x_2 \geq 0. \end{aligned}$$



- 显然最优解  $x^* = (-\sqrt{2}, 0)^T$ 。
- 两个约束都是活跃的。
- 如果它不是一个最优值点（意味着从它出发还有进一步可以下降的方向），那么必然有  $d$  方向满足

$$\nabla c_i(x)^T d \geq 0, \quad \nabla f(x)^T d < 0.$$

- 显然最优解  $x^* = (-\sqrt{2}, 0)^T$  是不存在这个方向的。因为满足条件的方向必须在  $\nabla c_1(x^*)$  和  $\nabla c_2(x^*)$  的夹角内，但是在此范围内的所有方向满足  $\nabla f(x^*)^T d > 0$ ，都是严格上升方向。

## 第三个例子

- 定义Lagrange乘子函数

$$L(x, \lambda) = f(x) - \lambda_1 c_1(x) - \lambda_2 c_2(x)$$

这里 $\lambda = (\lambda_1, \lambda_2)^T$ 是Lagrange乘子。

## 第三个例子

- 定义Lagrange乘子函数

$$L(x, \lambda) = f(x) - \lambda_1 c_1(x) - \lambda_2 c_2(x)$$

这里 $\lambda = (\lambda_1, \lambda_2)^T$ 是Lagrange乘子。

- $\nabla f(x)$ 和 $c_i(x)$ 的关系可以表示为：存在 $\lambda^* \geq 0$ ，使得

$$\nabla_x L(x^*, \lambda^*) = 0$$

并且满足互补性条件

$$\lambda_1 c_1(x^*) = 0, \quad \lambda_2^* c_2(x^*) = 0.$$

- 互补性条件:

一个约束要么是活跃的( $c_i(x) = 0$ )，因此会在 $\nabla_x L(x, \lambda) = 0$ 中参与；要么是不活跃的，此时它在 $\nabla_x L(x, \lambda) = 0$ 中实际上是不存在的。

## 约束条件“资格”(Constration Qualification)

# 约束条件“资格”(Constration Qualification)



# 约束条件“资格”(Constration Qualification)

- 在前面的分析中，我们在考虑是否存在可行的下降方向时，是用一阶泰勒展开分析的。

# 约束条件“资格”(Constration Qualification)

- 在前面的分析中，我们在考虑是否存在可行的下降方向时，是用一阶泰勒展开分析的。
- 这需要假设一阶线性展开能够捕捉可行域的几何性质。

# 约束条件“资格”(Constration Qualification)

- 在前面的分析中，我们在考虑是否存在可行的下降方向时，是用一阶泰勒展开分析的。
- 这需要假设一阶线性展开能够捕捉可行域的几何性质。如果在 $x$ 附近，一阶泰勒展开式与可行域相差巨大，那么我们不可能期望一阶线性逼近能够很好地近似原问题。

# 约束条件“资格”(Constration Qualification)

- 在前面的分析中，我们在考虑是否存在可行的下降方向时，是用一阶泰勒展开分析的。
- 这需要假设一阶线性展开能够捕捉可行域的几何性质。如果在 $x$ 附近，一阶泰勒展开式与可行域相差巨大，那么我们不可能期望一阶线性逼近能够很好地近似原问题。
- 因此我们需要对活跃的约束条件 $c_i$ 在 $x$ 处的性质，保证线性逼近能够很好地近似真实的可行域。

# 约束条件“资格”(Constration Qualification)

- 在前面的分析中，我们在考虑是否存在可行的下降方向时，是用一阶泰勒展开分析的。
- 这需要假设一阶线性展开能够捕捉可行域的几何性质。如果在 $x$ 附近，一阶泰勒展开式与可行域相差巨大，那么我们不可能期望一阶线性逼近能够很好地近似原问题。
- 因此我们需要对活跃的约束条件 $c_i$ 在 $x$ 处的性质，保证线性逼近能够很好地近似真实的可行域。
- 约束条件“资格”：是一些假设条件，使得可行集 $\Omega$ 和一阶线性逼近在 $x^*$ 的领域内很接近。

# 切锥(Tangent Cone)

定义：切锥

# 切锥(Tangent Cone)

定义：切锥

- 给定一个可行点  $x \in \Omega$ ，我们称  $\{z_k\}$  是一列逼近  $x$  的可行序列，如果对任意的充分大的  $k$ ，满足  $z_k \in \Omega$  且  $z_k \rightarrow x$ 。

# 切锥(Tangent Cone)

定义：切锥

- 给定一个可行点  $x \in \Omega$ ，我们称  $\{z_k\}$  是一列逼近  $x$  的可行序列，如果对任意的充分大的  $k$ ，满足  $z_k \in \Omega$  且  $z_k \rightarrow x$ 。
- “切向”是可行序列的极限方向。



# 切锥(Tangent Cone)

定义：切锥

- 给定一个可行点  $x \in \Omega$ , 我们称  $\{z_k\}$  是一列逼近  $x$  的可行序列, 如果对任意的充分大的  $k$ , 满足  $z_k \in \Omega$  且  $z_k \rightarrow x$ 。
- “切向”是可行序列的极限方向。
- 严格的数学定义：

# 切锥(Tangent Cone)

定义：切锥

- 给定一个可行点  $x \in \Omega$ ，我们称  $\{z_k\}$  是一列逼近  $x$  的可行序列，如果对任意的充分大的  $k$ ，满足  $z_k \in \Omega$  且  $z_k \rightarrow x$ 。
- “切向”是可行序列的极限方向。
- 严格的数学定义：设  $x^* \in \Omega$ ， $d \neq 0$  且  $d \in R^n$ ，如果存在  $\delta > 0$  使得

$$x^* + t d \in \Omega, \forall t \in [0, \delta]$$

则称  $d$  是  $\Omega$  在  $x^*$  处的线性化方向。

# 切锥(Tangent Cone)

## 定义：切锥

- 给定一个可行点  $x \in \Omega$ ，我们称  $\{z_k\}$  是一列逼近  $x$  的可行序列，如果对任意的充分大的  $k$ ，满足  $z_k \in \Omega$  且  $z_k \rightarrow x$ 。
- “切向”是可行序列的极限方向。
- 严格的数学定义：设  $x^* \in \Omega$ ， $d \neq 0$  且  $d \in R^n$ ，如果存在  $\delta > 0$  使得

$$x^* + t d \in \Omega, \forall t \in [0, \delta]$$

则称  $d$  是  $\Omega$  在  $x^*$  处的线性化方向。

- 在  $x^*$  处所有的切向组成的集合称为切锥(Tangent Cone)，记为  $T_{\Omega}(x^*)$ 。

# 切锥(Tangent Cone)

## 定义：切锥

- 给定一个可行点  $x \in \Omega$ ，我们称  $\{z_k\}$  是一列逼近  $x$  的可行序列，如果对任意的充分大的  $k$ ，满足  $z_k \in \Omega$  且  $z_k \rightarrow x$ 。
- “切向”是可行序列的极限方向。
- 严格的数学定义：设  $x^* \in \Omega$ ， $d \neq 0$  且  $d \in R^n$ ，如果存在  $\delta > 0$  使得

$$x^* + t d \in \Omega, \forall t \in [0, \delta]$$

则称  $d$  是  $\Omega$  在  $x^*$  处的线性化方向。

- 在  $x^*$  处所有的切向组成的集合称为切锥(Tangent Cone)，记为  $T_{\Omega}(x^*)$ 。

# 切锥(Tangent Cone)

## 定义：切锥

- 给定一个可行点  $x \in \Omega$ ，我们称  $\{z_k\}$  是一列逼近  $x$  的可行序列，如果对任意的充分大的  $k$ ，满足  $z_k \in \Omega$  且  $z_k \rightarrow x$ 。
- “切向”是可行序列的极限方向。
- 严格的数学定义：设  $x^* \in \Omega$ ， $d \neq 0$  且  $d \in R^n$ ，如果存在  $\delta > 0$  使得

$$x^* + t d \in \Omega, \forall t \in [0, \delta]$$

则称  $d$  是  $\Omega$  在  $x^*$  处的线性化方向。

- 在  $x^*$  处所有的切向组成的集合称为切锥(Tangent Cone)，记为  $T_{\Omega}(x^*)$ 。
- 从切锥的定义可以看出，这个定义跟  $\Omega$  的代数形式无关，只能  $\Omega$  的几何性质有关。

# 线性化可行方向

定义：线性化可行方向

给定一个可行点  $x \in \Omega$  以及活跃集  $\mathcal{A}$ ，线性可行方向集

$$\mathcal{F}(x) = \{d \mid d^T \nabla c_i(x) = 0, \forall i \in \mathcal{E}; \quad d^T \nabla c_i(x) \geq 0, \forall i \in \mathcal{A}(x) \cap \mathcal{J}\}.$$

显然，线性化可行方向集仅依赖于约束条件  $c_i$ ,  $i \in \mathcal{E} \cup \mathcal{J}$ 。

# 约束条件限制

- 约束条件限制是一些假设，能够保证“切锥” $T_{\Omega}(x)$ 和“线性可行方向集” $\mathcal{F}(x)$ 是相似的。

# 约束条件限制

- 约束条件限制是一些假设，能够保证“切锥” $T_{\Omega}(x)$ 和“线性可行方向集” $\mathcal{F}(x)$ 是相似的。
- 这些限制条件，可以保证 $\mathcal{F}(x)$ (由 $c_i(x)$ 一阶线性化构造)能够很好地捕捉到 $\Omega$ 在 $x$ 处的本质几何性质(essential geometric features)。



# 约束条件限制

- 约束条件限制是一些假设，能够保证“切锥” $T_{\Omega}(x)$ 和“线性可行方向集” $\mathcal{F}(x)$ 是相似的。
- 这些限制条件，可以保证 $\mathcal{F}(x)$ (由 $c_i(x)$ 一阶线性化构造)能够很好地捕捉到 $\Omega$ 在 $x$ 处的本质几何性质(essential geometric features)。
- 绝大多数约束条件限制都可以保证  $\mathcal{F}(x) = T_{\Omega}(x)$ 。

# 约束条件限制

## 两种限制

- **线性无关约束限制(LICQ)**: 给定一个可行点  $x \in \Omega$  以及活跃集  $\mathcal{A}(x)$ , 如果活跃的约束条件的梯度  $\nabla c_i(x)$ ,  $i \in \mathcal{A}(x)$  是线性无关的。

# 约束条件限制

## 两种限制

- **线性无关约束限制(LICQ)**: 给定一个可行点  $x \in \Omega$  以及活跃集  $\mathcal{A}(x)$ , 如果活跃的约束条件的梯度  $\nabla c_i(x)$ ,  $i \in \mathcal{A}(x)$  是线性无关的。
- **Mangasarian-Fromovitz约束限制(MFCQ)**: 存在一个向量  $w \in \mathbb{R}^n$  使得

$$\begin{aligned}\nabla c_i(x^*)^T w &= 0, \quad \forall i \in \mathcal{E}, \\ \nabla c_i(x^*)^T w &> 0, \quad \forall i \in \mathcal{A}(x^*) \cap \mathcal{I},\end{aligned}$$

并且所有的等值约束条件的梯度  $\{\nabla c_i(x^*), i \in \mathcal{E}\}$  是线性无关的。

# 约束条件限制

## 两种限制

- **线性无关约束限制(LICQ)**: 给定一个可行点  $x \in \Omega$  以及活跃集  $\mathcal{A}(x)$ , 如果活跃的约束条件的梯度  $\nabla c_i(x)$ ,  $i \in \mathcal{A}(x)$  是线性无关的。
- **Mangasarian-Fromovitz约束限制(MFCQ)**: 存在一个向量  $w \in \mathbb{R}^n$  使得

$$\begin{aligned}\nabla c_i(x^*)^T w &= 0, \quad \forall i \in \mathcal{E}, \\ \nabla c_i(x^*)^T w &> 0, \quad \forall i \in \mathcal{A}(x^*) \cap \mathcal{I},\end{aligned}$$

并且所有的等值约束条件的梯度  $\{\nabla c_i(x^*), i \in \mathcal{E}\}$  是线性无关的。

- **特殊情况**: 如果所有的活跃约束  $c_i(\cdot)$ ,  $i \in \mathcal{A}(x^*)$  都是线性函数, 那么显然有  $\mathcal{F}(x^*) = T_\Omega(x^*)$ 。

## 一阶最优性条件(First-Order Necessary Conditions)

# 拉格朗日函数

## 定义 Lagrangian Function

拉格朗日函数

$$\mathcal{L}(x, \lambda) = f(x) - \sum_{i \in \mathcal{E} \cup \mathcal{J}} \lambda_i c_i(x)$$

这里 $\lambda_i$ 称为 $c_i(x)$ 的拉格朗日乘子(Lagrange Multiplier)。

# 一阶最优性条件(First-Order Necessary Conditions)

## 定理 (KKT条件, Karush-Kuhn-Tucker)

假设 $x^*$ 是一个局部最优解并且在 $x^*$ 处满足LICQ条件。则存在一个拉格朗日乘子向量 $\lambda^*$ ，每个分量是 $\lambda_i$ ， $i \in \mathcal{E} \cup \mathcal{J}$ ，使得如下条件满足

$$\begin{aligned}\nabla_x \mathcal{L}(x^*, \lambda^*) &= 0, \\ c_i(x^*) &= 0, & \forall i \in \mathcal{E}, \\ c_i(x^*) &\geq 0, & \forall i \in \mathcal{J}, \\ \lambda_i^* &\geq 0, & \forall i \in \mathcal{J}, \\ \lambda_i^* c_i(x^*) &= 0, & \forall i \in \mathcal{E} \cup \mathcal{J}.\end{aligned}$$

**Remark:** 通常来说，对于给定的优化问题及局部最优解 $x^*$ ，可能存在很多个 $\lambda^*$ 满足上述KKT条件。但是当LICQ满足时，最优的 $\lambda^*$ 是唯一的。

## 互补性条件(Complementary Condition)

- KKT条件中最后一个条件 $\lambda_i^* c_i(x^*) = 0$ 称为互补性条件。这表明要么约束条件是活跃的，要么 $\lambda_i^* = 0$ ，或者两者同时成立。



# 互补性条件(Complementary Condition)

- KKT条件中最后一个条件 $\lambda_i^* c_i(x^*) = 0$ 称为互补性条件。这表明要么约束条件是活跃的，要么 $\lambda_i^* = 0$ ，或者两者同时成立。
- 如果约束条件不是活跃的，那么对应的Lagrange乘子为0，也就是对应的Lagrangian函数可以简化为：

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = \nabla f(x^*) - \sum_{i \in \mathcal{A}(x^*)} \lambda_i^* \nabla c_i(x^*).$$

## 互补性条件(Complementary Condition)

- KKT条件中最后一个条件 $\lambda_i^* c_i(x^*) = 0$ 称为互补性条件。这表明要么约束条件是活跃的，要么 $\lambda_i^* = 0$ ，或者两者同时成立。
- 如果约束条件不是活跃的，那么对应的Lagrange乘子为0，也就是对应的Lagrangian函数可以简化为：

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = \nabla f(x^*) - \sum_{i \in \mathcal{A}(x^*)} \lambda_i^* \nabla c_i(x^*).$$

- **严格互补条件** 给定一个局部最优解 $x^*$ 和相应的 $\lambda^*$ 满足KKT条件，如果对所有的不等式约束里 $\lambda_i^*$ 和 $c_i(x^*)$ 中只有一个为0，即对于 $i \in \mathcal{I} \cap \mathcal{A}(x^*)$ 有 $\lambda_i^* > 0$ ，这样的情况，我们称为满足严格互补条件。

## 互补性条件(Complementary Condition)

- KKT条件中最后一个条件 $\lambda_i^* c_i(x^*) = 0$ 称为互补性条件。这表明要么约束条件是活跃的，要么 $\lambda_i^* = 0$ ，或者两者同时成立。
- 如果约束条件不是活跃的，那么对应的Lagrange乘子为0，也就是对应的Lagrangian函数可以简化为：

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = \nabla f(x^*) - \sum_{i \in \mathcal{A}(x^*)} \lambda_i^* \nabla c_i(x^*).$$

- **严格互补条件** 给定一个局部最优解 $x^*$ 和相应的 $\lambda^*$ 满足KKT条件，如果对所有的不等式约束里 $\lambda_i^*$ 和 $c_i(x^*)$ 中只有一个为0，即对于 $i \in \mathcal{I} \cap \mathcal{A}(x^*)$ 有 $\lambda_i^* > 0$ ，这样的情况，我们称为满足严格互补条件。
- 显然，如果满足严格互补条件，可以使得算法比较容易确定活跃集 $\mathcal{A}(x^*)$ ，而且算法收敛比较快。

# 拉格朗日乘子 $\lambda_i$ 的意义

KKT条件中第一个条件:  $\nabla f(x^*) = \sum \lambda_i^* \nabla c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$

可以看出 $\lambda_i^*$ 的实际意义是 $\nabla c_i(x^*)$ 在 $\nabla f(x^*)$ 中的权重。

# 拉格朗日乘子 $\lambda_i$ 的意义

KKT条件中第一个条件:  $\nabla f(x^*) = \sum \lambda_i^* \nabla c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$

可以看出 $\lambda_i^*$ 的实际意义是 $\nabla c_i(x^*)$ 在 $\nabla f(x^*)$ 中的权重。

- $\lambda_i^*$ 越大, 说明第 $i$ 个约束在 $f$ 无法下降中起的作用也越大, 对算法也越敏感。

# 拉格朗日乘子 $\lambda_i$ 的意义

KKT条件中第一个条件:  $\nabla f(x^*) = \sum \lambda_i^* \nabla c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$

可以看出 $\lambda_i^*$ 的实际意义是 $\nabla c_i(x^*)$ 在 $\nabla f(x^*)$ 中的权重。

- $\lambda_i^*$ 越大, 说明第 $i$ 个约束在 $f$ 无法下降中起的作用也越大, 对算法也越敏感。极端情况 $\lambda_i^* = 0$ , 说明约束没起作用。

# 拉格朗日乘子 $\lambda_i$ 的意义

KKT条件中第一个条件:  $\nabla f(x^*) = \sum \lambda_i^* \nabla c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$

可以看出 $\lambda_i^*$ 的实际意义是 $\nabla c_i(x^*)$ 在 $\nabla f(x^*)$ 中的权重。

- $\lambda_i^*$ 越大, 说明第 $i$ 个约束在 $f$ 无法下降中起的作用也越大, 对算法也越敏感。极端情况 $\lambda_i^* = 0$ , 说明约束没起作用。
- 如果对 $c_i(x) \geq 0$ 施加小扰动, 变为 $c_i(x) \geq -\varepsilon \|\nabla c_i(x^*)\|$ , 那么活跃的约束变为

# 拉格朗日乘子 $\lambda_i$ 的意义

KKT条件中第一个条件:  $\nabla f(x^*) = \sum \lambda_i^* \nabla c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$

可以看出 $\lambda_i^*$ 的实际意义是 $\nabla c_i(x^*)$ 在 $\nabla f(x^*)$ 中的权重。

- $\lambda_i^*$ 越大, 说明第 $i$ 个约束在 $f$ 无法下降中起的作用也越大, 对算法也越敏感。极端情况 $\lambda_i^* = 0$ , 说明约束没起作用。
- 如果对 $c_i(x) \geq 0$ 施加小扰动, 变为 $c_i(x) \geq -\varepsilon \|\nabla c_i(x^*)\|$ , 那么活跃的约束变为

$$\frac{c_i(x^*(\varepsilon) - x^*)}{x^*(\varepsilon) - x^*} = \nabla c_i(x^*), \text{ 即: } c_i(x^* + \varepsilon) - c_i(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla c_i(x^*)$$

这里 $x^*(\varepsilon)$ 对应扰动后的新解。



# 拉格朗日乘子 $\lambda_i$ 的意义

KKT条件中第一个条件:  $\nabla f(x^*) = \sum \lambda_i^* \nabla c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$

可以看出 $\lambda_i^*$ 的实际意义是 $\nabla c_i(x^*)$ 在 $\nabla f(x^*)$ 中的权重。

- $\lambda_i^*$ 越大, 说明第 $i$ 个约束在 $f$ 无法下降中起的作用也越大, 对算法也越敏感。极端情况 $\lambda_i^* = 0$ , 说明约束没起作用。
- 如果对 $c_i(x) \geq 0$ 施加小扰动, 变为 $c_i(x) \geq -\varepsilon \|\nabla c_i(x^*)\|$ , 那么活跃的约束变为

$$\frac{c_i(x^*(\varepsilon) - x^*)}{x^*(\varepsilon) - x^*} = \nabla c_i(x^*), \text{ 即: } c_i(x^* + \varepsilon) - c_i(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla c_i(x^*)$$

这里 $x^*(\varepsilon)$ 对应扰动后的新解。

- 对于 $j \neq i$ , 扰动后 $c_j$ 不变, 有 $0 = c_j(x^*(\varepsilon)) - c_j(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla c_j(x^*)$ .

# 拉格朗日乘子 $\lambda_i$ 的意义

KKT条件中第一个条件:  $\nabla f(x^*) = \sum \lambda_i^* \nabla c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$

可以看出 $\lambda_i^*$ 的实际意义是 $\nabla c_i(x^*)$ 在 $\nabla f(x^*)$ 中的权重。

- $\lambda_i^*$ 越大, 说明第 $i$ 个约束在 $f$ 无法下降中起的作用也越大, 对算法也越敏感。极端情况 $\lambda_i^* = 0$ , 说明约束没起作用。
- 如果对 $c_i(x) \geq 0$ 施加小扰动, 变为 $c_i(x) \geq -\varepsilon \|\nabla c_i(x^*)\|$ , 那么活跃的约束变为

$$\frac{c_i(x^*(\varepsilon) - x^*)}{x^*(\varepsilon) - x^*} = \nabla c_i(x^*), \text{ 即: } c_i(x^* + \varepsilon) - c_i(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla c_i(x^*)$$

这里 $x^*(\varepsilon)$ 对应扰动后的新解。

- 对于 $j \neq i$ , 扰动后 $c_j$ 不变, 有

$$0 = c_j(x^*(\varepsilon)) - c_j(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla c_j(x^*). \text{ 于是对 } f(x^*(\varepsilon)), \text{ 有}$$

$$f(x^*(\varepsilon)) - f(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla f(x^*) = \sum \lambda_j^* (x^*(\varepsilon) - x^*)^T \nabla c_j(x^*) \approx -\varepsilon \lambda_i^* \|\nabla c_i(x^*)\|$$

# 拉格朗日乘子 $\lambda_i$ 的意义

KKT条件中第一个条件:  $\nabla f(x^*) = \sum \lambda_i^* \nabla c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$

可以看出 $\lambda_i^*$ 的实际意义是 $\nabla c_i(x^*)$ 在 $\nabla f(x^*)$ 中的权重。

- $\lambda_i^*$ 越大, 说明第 $i$ 个约束在 $f$ 无法下降中起的作用也越大, 对算法也越敏感。极端情况 $\lambda_i^* = 0$ , 说明约束没起作用。
- 如果对 $c_i(x) \geq 0$ 施加小扰动, 变为 $c_i(x) \geq -\varepsilon \|\nabla c_i(x^*)\|$ , 那么活跃的约束变为

$$\frac{c_i(x^*(\varepsilon) - x^*)}{x^*(\varepsilon) - x^*} = \nabla c_i(x^*), \text{ 即: } c_i(x^* + \varepsilon) - c_i(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla c_i(x^*)$$

这里 $x^*(\varepsilon)$ 对应扰动后的新解。

- 对于 $j \neq i$ , 扰动后 $c_j$ 不变, 有

$$0 = c_j(x^*(\varepsilon)) - c_j(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla c_j(x^*). \text{ 于是对 } f(x^*(\varepsilon)), \text{ 有}$$


$$f(x^*(\varepsilon)) - f(x^*) \approx (x^*(\varepsilon) - x^*)^T \nabla f(x^*) = \sum \lambda_j^* (x^*(\varepsilon) - x^*)^T \nabla c_j(x^*) \approx -\varepsilon \lambda_i^* \|\nabla c_i(x^*)\|$$

进而 $\frac{df(x^*(\varepsilon))}{d\varepsilon} = -\lambda_i^* \|\nabla c_i(x^*)\|$ 。因此,  $\lambda_i^* \|\nabla c_i(x^*)\|$ 是第 $i$ 个约束对解目标值的敏感影响因子。

# 一个例子

例4：考虑如下的优化问题


$$\begin{aligned}
 \min \quad & (x_1 - \frac{3}{2})^2 + (x_2 - \frac{1}{2})^4 \\
 \text{s.t.} \quad & 1 - x_1 - x_2 \geq 0 \\
 & 1 - x_1 + x_2 \geq 0 \\
 & 1 + x_1 - x_2 \geq 0 \\
 & 1 + x_1 + x_2 \geq 0.
 \end{aligned}$$



# 一个例子

例4：考虑如下的优化问题

$$\begin{aligned}
 \min \quad & (x_1 - \frac{3}{2})^2 + (x_2 - \frac{1}{2})^4 \\
 \text{s.t.} \quad & 1 - x_1 - x_2 \geq 0 \\
 & 1 - x_1 + x_2 \geq 0 \\
 & 1 + x_1 - x_2 \geq 0 \\
 & 1 + x_1 + x_2 \geq 0.
 \end{aligned}$$




- 最优解是  $(1,0)^T$ 。第一个和第二个约束条件是活跃的，记为  $c_1$ ,  $c_2$ 。

## 一个例子

例4：考虑如下的优化问题

$$\begin{aligned}
 \min \quad & (x_1 - \frac{3}{2})^2 + (x_2 - \frac{1}{2})^4 \\
 \text{s.t.} \quad & 1 - x_1 - x_2 \geq 0 \\
 & 1 - x_1 + x_2 \geq 0 \\
 & 1 + x_1 - x_2 \geq 0 \\
 & 1 + x_1 + x_2 \geq 0.
 \end{aligned}$$



- 最优解是  $(1, 0)^T$ 。第一个和第二个约束条件是活跃的，记为  $c_1$ ,  $c_2$ 。
- 

$$\begin{aligned}
 \nabla f(x^*) &= \begin{bmatrix} -1 \\ -\frac{1}{2} \end{bmatrix}, \quad \nabla c_1(x^*) = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \quad \nabla c_2(x^*) = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \\
 \lambda^* &= (\frac{3}{4}, \frac{1}{4}, 0, 0)^T
 \end{aligned}$$

# 证明一阶最优性条件(KKT)

证明主要分为三步。第一步是“切锥”和“一阶可行方向集”之间的关系，

# 证明一阶最优性条件(KKT)

证明主要分为三步。第一步是“切锥”和“一阶可行方向集”之间的关系，第二步是基本必要条件，



# 证明一阶最优性条件(KKT)

证明主要分为三步。第一步是“切锥”和“一阶可行方向集”之间的关系，第二步是基本必要条件，第三步是Farkas引理，如何判断一个方向落在一个锥里。

# 证明一阶最优性条件(KKT)

证明主要分为三步。第一步是“切锥”和“一阶可行方向集”之间的关系，第二步是基本必要条件，第三步是Farkas引理，如何判断一个方向落在一个锥里。

## 引理1

假定 $x^*$ 是一个可行点，则有

- ①  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$ ;
- ② 若在 $x^*$ 点有LICQ成立，则 $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

# 证明一阶最优性条件(KKT)

证明主要分为三步。第一步是“切锥”和“一阶可行方向集”之间的关系，第二步是基本必要条件，第三步是Farkas引理，如何判断一个方向落在一个锥里。

## 引理1

假定 $x^*$ 是一个可行点，则有

- ①  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$ ;
- ② 若在 $x^*$ 点有LICQ成立，则 $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

## 引理2

假定 $x^*$ 是一个局部最优解，则有

$$\nabla f(x^*)^T d \geq 0, \text{ 对于任意的 } d \in T_{\Omega}(x^*)$$

即：切锥里所有的方向都不是下降方向。

# 引理1的证明

先证明第一个结论  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$

- 假设  $c_i$  是活跃的约束条件,  $i = 1, \dots, m$ 。对于任意的  $d \in T_{\Omega}(x^*)$ , 令序列  $\{z_k\}$  和  $\{t_k > 0\}$  满足

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d, \quad \text{即} \quad z_k = x^* + t_k d + o(t_k).$$

# 引理1的证明

先证明第一个结论  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$

- 假设  $c_i$  是活跃的约束条件,  $i = 1, \dots, m$ 。对于任意的  $d \in T_{\Omega}(x^*)$ , 令序列  $\{z_k\}$  和  $\{t_k > 0\}$  满足

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d, \quad \text{即} \quad z_k = x^* + t_k d + o(t_k).$$

- 对于等式约束  $i \in \mathcal{E}$ , 有

# 引理1的证明

先证明第一个结论  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$

- 假设  $c_i$  是活跃的约束条件,  $i = 1, \dots, m$ 。对于任意的  $d \in T_{\Omega}(x^*)$ , 令序列  $\{z_k\}$  和  $\{t_k > 0\}$  满足

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d, \quad \text{即 } z_k = x^* + t_k d + o(t_k).$$

- 对于等式约束  $i \in \mathcal{E}$ , 有

$$0 = \frac{c_i(z_k)}{t_k} = \frac{c_i(x^*) + t_k \nabla c_i(x^*)^T d + (t_k)}{t_k} = \nabla c_i(x^*)^T d + \frac{o(t_k)}{t_k}$$

# 引理1的证明

先证明第一个结论  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$

- 假设  $c_i$  是活跃的约束条件,  $i = 1, \dots, m$ 。对于任意的  $d \in T_{\Omega}(x^*)$ , 令序列  $\{z_k\}$  和  $\{t_k > 0\}$  满足

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d, \quad \text{即 } z_k = x^* + t_k d + o(t_k).$$

- 对于等式约束  $i \in \mathcal{E}$ , 有

$$0 = \frac{c_i(z_k)}{t_k} = \frac{c_i(x^*) + t_k \nabla c_i(x^*)^T d + o(t_k)}{t_k} = \nabla c_i(x^*)^T d + \frac{o(t_k)}{t_k}$$

两边同取极限可以得到  $\nabla c_i(x^*)^T d = 0$ .

## 引理1的证明

先证明第一个结论  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$

- 假设  $c_i$  是活跃的约束条件,  $i = 1, \dots, m$ 。对于任意的  $d \in T_{\Omega}(x^*)$ , 令序列  $\{z_k\}$  和  $\{t_k > 0\}$  满足

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d, \quad \text{即 } z_k = x^* + t_k d + o(t_k).$$

- 对于等式约束  $i \in \mathcal{E}$ , 有

$$0 = \frac{c_i(z_k)}{t_k} = \frac{c_i(x^*) + t_k \nabla c_i(x^*)^T d + (t_k)}{t_k} = \nabla c_i(x^*)^T d + \frac{o(t_k)}{t_k}$$

两边同取极限可以得到  $\nabla c_i(x^*)^T d = 0$ .

- 对于不等式约束  $i \in \mathcal{I} \cap \mathcal{A}(x^*)$ , 有

$$0 \leq \frac{c_i(z_k)}{t_k} = \frac{c_i(x^*) + t_k \nabla c_i(x^*)^T d + (t_k)}{t_k} = \nabla c_i(x^*)^T d + \frac{o(t_k)}{t_k}$$

两边同取极限可以得到  $\nabla c_i(x^*)^T d \geq 0$ .



# 引理1的证明

先证明第一个结论  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$

- 假设  $c_i$  是活跃的约束条件,  $i = 1, \dots, m$ 。对于任意的  $d \in T_{\Omega}(x^*)$ , 令序列  $\{z_k\}$  和  $\{t_k > 0\}$  满足

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d, \quad \text{即 } z_k = x^* + t_k d + o(t_k).$$

- 对于等式约束  $i \in \mathcal{E}$ , 有

$$0 = \frac{c_i(z_k)}{t_k} = \frac{c_i(x^*) + t_k \nabla c_i(x^*)^T d + (t_k)}{t_k} = \nabla c_i(x^*)^T d + \frac{o(t_k)}{t_k}$$

两边同取极限可以得到  $\nabla c_i(x^*)^T d = 0$ .

- 对于不等式约束  $i \in \mathcal{I} \cap \mathcal{A}(x^*)$ , 有

$$0 \leq \frac{c_i(z_k)}{t_k} = \frac{c_i(x^*) + t_k \nabla c_i(x^*)^T d + (t_k)}{t_k} = \nabla c_i(x^*)^T d + \frac{o(t_k)}{t_k}$$

两边同取极限可以得到  $\nabla c_i(x^*)^T d \geq 0$ .

综上所述,  $d \in \mathcal{F}(x^*)$

## 引理1的证明

先证明第一个结论  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$

- 假设  $c_i$  是活跃的约束条件,  $i = 1, \dots, m$ 。对于任意的  $d \in T_{\Omega}(x^*)$ , 令序列  $\{z_k\}$  和  $\{t_k > 0\}$  满足

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d, \quad \text{即 } z_k = x^* + t_k d + o(t_k).$$

- 对于等式约束  $i \in \mathcal{E}$ , 有

$$0 = \frac{c_i(z_k)}{t_k} = \frac{c_i(x^*) + t_k \nabla c_i(x^*)^T d + (t_k)}{t_k} = \nabla c_i(x^*)^T d + \frac{o(t_k)}{t_k}$$

两边同取极限可以得到  $\nabla c_i(x^*)^T d = 0$ .

- 对于不等式约束  $i \in \mathcal{I} \cap \mathcal{A}(x^*)$ , 有

$$0 \leq \frac{c_i(z_k)}{t_k} = \frac{c_i(x^*) + t_k \nabla c_i(x^*)^T d + (t_k)}{t_k} = \nabla c_i(x^*)^T d + \frac{o(t_k)}{t_k}$$

两边同取极限可以得到  $\nabla c_i(x^*)^T d \geq 0$ .

综上所述,  $d \in \mathcal{F}(x^*)$  即:  $T_{\Omega}(x^*) \subset \mathcal{F}(x^*)$ 。

# 引理1的证明

再证明引理1的第二个结论：如果满足LICQ，则  $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

# 引理1的证明

再证明引理1的第二个结论：如果满足LICQ，则  $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

- 所有的活跃约束的梯度向量  $\nabla c_i(x^*)$  可以组成一个矩阵，记为  $A(x^*) := [\nabla c_i(x^*)]^T, i \in \mathcal{A}(x^*)$ 。这最多是一个  $m \times n$  的矩阵。

# 引理1的证明

再证明引理1的第二个结论：如果满足LICQ，则  $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

- 所有的活跃约束的梯度向量  $\nabla c_i(x^*)$  可以组成一个矩阵，记为  $A(x^*) := [\nabla c_i(x^*)]^T, i \in \mathcal{A}(x^*)$ 。这最多是一个  $m \times n$  的矩阵。
- 由于满足LICQ，则  $A(x^*)$  行满秩。

# 引理1的证明

再证明引理1的第二个结论：如果满足LICQ，则  $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

- 所有的活跃约束的梯度向量  $\nabla c_i(x^*)$  可以组成一个矩阵，记为  $A(x^*) := [\nabla c_i(x^*)]^T, i \in \mathcal{A}(x^*)$ 。这最多是一个  $m \times n$  的矩阵。
- 由于满足LICQ，则  $A(x^*)$  行满秩。可以找到  $A(x^*)$  的核空间的一组基函数  $Z \in \mathbb{R}^{n \times (n-m)}$ ,

## 引理1的证明

再证明引理1的第二个结论：如果满足LICQ，则  $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

- 所有的活跃约束的梯度向量  $\nabla c_i(x^*)$  可以组成一个矩阵，记为  $A(x^*) := [\nabla c_i(x^*)]^T, i \in \mathcal{A}(x^*)$ 。这最多是一个  $m \times n$  的矩阵。
- 由于满足LICQ，则  $A(x^*)$  行满秩。可以找到  $A(x^*)$  的核空间的一组基函数  $Z \in \mathbb{R}^{n \times (n-m)}$ ，即  $A(x^*)Z = 0$ 。
- 对于  $\mathcal{F}(x^*)$  中的任意方向  $d$ ，定义如下的映射  $R: \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}^n$

$$R(z, t) = \begin{bmatrix} c(z) - tA(x^*)d \\ Z^T(z - x^* - td) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

# 引理1的证明

再证明引理1的第二个结论：如果满足LICQ，则  $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

- 所有的活跃约束的梯度向量  $\nabla c_i(x^*)$  可以组成一个矩阵，记为  $A(x^*) := [\nabla c_i(x^*)]^T, i \in \mathcal{A}(x^*)$ 。这最多是一个  $m \times n$  的矩阵。
- 由于满足LICQ，则  $A(x^*)$  行满秩。可以找到  $A(x^*)$  的核空间的一组基函数  $Z \in \mathbb{R}^{n \times (n-m)}$ ，即  $A(x^*)Z = 0$ 。
- 对于  $\mathcal{F}(x^*)$  中的任意方向  $d$ ，定义如下的映射  $R: \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}^n$

$$R(z, t) = \begin{bmatrix} c(z) - tA(x^*)d \\ Z^T(z - x^* - td) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

- 这里断言，当  $t_k > 0$  趋于0，上述方程解存在记为  $z_k$ ，则  $z_k$  和  $t_k$  满足渐进可行序列的要求，



## 引理1的证明

再证明引理1的第二个结论：如果满足LICQ，则  $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

- 所有的活跃约束的梯度向量  $\nabla c_i(x^*)$  可以组成一个矩阵，记为  $A(x^*) := [\nabla c_i(x^*)]^T, i \in \mathcal{A}(x^*)$ 。这最多是一个  $m \times n$  的矩阵。
- 由于满足LICQ，则  $A(x^*)$  行满秩。可以找到  $A(x^*)$  的核空间的一组基函数  $Z \in \mathbb{R}^{n \times (n-m)}$ ，即  $A(x^*)Z = 0$ 。
- 对于  $\mathcal{F}(x^*)$  中的任意方向  $d$ ，定义如下的映射  $R: \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}^n$

$$R(z, t) = \begin{bmatrix} c(z) - tA(x^*)d \\ Z^T(z - x^* - td) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

- 这里断言，当  $t_k > 0$  趋于0，上述方程解存在记为  $z_k$ ，则  $z_k$  和  $t_k$  满足渐进可行序列的要求，即  $\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$ 。(下面分两小步说明)

## 引理1的证明

再证明引理1的第二个结论：如果满足LICQ，则  $T_{\Omega}(x^*) = \mathcal{F}(x^*)$

- 所有的活跃约束的梯度向量  $\nabla c_i(x^*)$  可以组成一个矩阵，记为  $A(x^*) := [\nabla c_i(x^*)]^T, i \in \mathcal{A}(x^*)$ 。这最多是一个  $m \times n$  的矩阵。
- 由于满足LICQ，则  $A(x^*)$  行满秩。可以找到  $A(x^*)$  的核空间的一组基函数  $Z \in \mathbb{R}^{n \times (n-m)}$ ，即  $A(x^*)Z = 0$ 。
- 对于  $\mathcal{F}(x^*)$  中的任意方向  $d$ ，定义如下的映射  $R: \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}^n$

$$R(z, t) = \begin{bmatrix} c(z) - tA(x^*)d \\ Z^T(z - x^* - td) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

- 这里断言，当  $t_k > 0$  趋于0，上述方程解存在记为  $z_k$ ，则  $z_k$  和  $t_k$  满足渐进可行序列的要求，即  $\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$ 。(下面分两小步说明)

# 引理1的证明

- 第一小步, 即 $z_k$ 是可行的。当 $t = 0$ ,  $z = x^*$ 时,  $R$ 对 $z$ 的Jacobi矩阵为 $[A(x^*)^T; Z]^T$ 是非奇异的,

# 引理1的证明

- 第一小步，即 $z_k$ 是可行的。当 $t = 0$ ， $z = x^*$ 时， $R$ 对 $z$ 的Jacobi矩阵为 $[A(x^*)^T; Z]^T$ 是非奇异的，所以根据隐函数存在定理，对于充分小的 $t_k$ ，方程组存在唯一的解 $z_k$ 。

# 引理1的证明

- 第一小步，即 $z_k$ 是可行的。当 $t = 0$ ， $z = x^*$ 时， $R$ 对 $z$ 的Jacobi矩阵为 $[A(x^*)^T; Z]^T$ 是非奇异的，所以根据隐函数存在定理，对于充分小的 $t_k$ ，方程组存在唯一的解 $z_k$ 。这些解 $z_k$ 满足 $c_i(z_k) = t_k A(x^*)d$ 。

# 引理1的证明

- 第一小步，即 $z_k$ 是可行的。当 $t = 0$ ， $z = x^*$ 时， $R$ 对 $z$ 的Jacobi矩阵为 $[A(x^*)^T; Z]^T$ 是非奇异的，所以根据隐函数存在定理，对于充分小的 $t_k$ ，方程组存在唯一的解 $z_k$ 。这些解 $z_k$ 满足 $c_i(z_k) = t_k A(x^*)d$ 。当 $i \in \mathcal{E}$ 时，即 $c_i(z_k) = t_k \nabla c_i(x^*)^T d = 0$ 。

## 引理1的证明

- 第一小步，即  $z_k$  是可行的。当  $t = 0$ ,  $z = x^*$  时,  $R$  对  $z$  的 Jacobi 矩阵为  $[A(x^*)^T; Z]^T$  是非奇异的, 所以根据隐函数存在定理, 对于充分小的  $t_k$ , 方程组存在唯一的解  $z_k$ 。这些解  $z_k$  满足  $c_i(z_k) = t_k A(x^*)d$ 。  
 当  $i \in \mathcal{E}$  时, 即  $c_i(z_k) = t_k \nabla c_i(x^*)^T d = 0$ 。  
 当  $i \in \mathcal{A}(x^*) \cap \mathcal{J}$  时,  $c_i(z_k) = t_k \nabla c_i(x^I)^T d \geq 0$ 。
- 第二小步: 对于可行的  $z_k$ , 满足  $\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$ 。

## 引理1的证明

- 第一小步，即 $z_k$ 是可行的。当 $t = 0$ ， $z = x^*$ 时， $R$ 对 $z$ 的Jacobi矩阵为 $[A(x^*)^T; Z]^T$ 是非奇异的，所以根据隐函数存在定理，对于充分小的 $t_k$ ，方程组存在唯一的解 $z_k$ 。这些解 $z_k$ 满足 $c_i(z_k) = t_k A(x^*)d$ 。  
 当 $i \in \mathcal{E}$ 时，即 $c_i(z_k) = t_k \nabla c_i(x^*)^T d = 0$ 。  
 当 $i \in \mathcal{A}(x^*) \cap \mathcal{J}$ 时， $c_i(z_k) = t_k \nabla c_i(x^*)^T d \geq 0$ 。
- 第二小步：对于可行的 $z_k$ ，满足 $\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$ 。对于 $R(z_k, t_k)$ 应用泰勒展开可以得到：



## 引理1的证明

- 第一小步, 即  $z_k$  是可行的。当  $t = 0$ ,  $z = x^*$  时,  $R$  对  $z$  的 Jacobi 矩阵为  $[A(x^*)^T; Z]^T$  是非奇异的, 所以根据隐函数存在定理, 对于充分小的  $t_k$ , 方程组存在唯一的解  $z_k$ 。这些解  $z_k$  满足  $c_i(z_k) = t_k A(x^*)d$ 。  
 当  $i \in \mathcal{E}$  时, 即  $c_i(z_k) = t_k \nabla c_i(x^*)^T d = 0$ 。  
 当  $i \in \mathcal{A}(x^*) \cap \mathcal{J}$  时,  $c_i(z_k) = t_k \nabla c_i(x^*)^T d \geq 0$ 。
- 第二小步: 对于可行的  $z_k$ , 满足  $\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$ 。对于  $R(z_k, t_k)$  应用泰勒展开可以得到:

$$\begin{aligned}
 0 = R(z_k, t_k) &= \begin{bmatrix} c(z_k) - t_k A(x^*)d \\ z^T(z_k - x^* - t_k d) \end{bmatrix} \\
 &= \begin{bmatrix} c(x^*) + \nabla c(x^*)^T(z_k - x^*) + o(\|z_k - x^*\|) - t_k A(x^*)d \\ z^T(z_k - x^* - t_k d) \end{bmatrix} \\
 &= \begin{bmatrix} A(x^*) \\ Z^T \end{bmatrix} (z_k - x^* - t_k d) + o(\|z_k - x^*\|)
 \end{aligned}$$

## 引理1的证明

- 第一小步, 即 $z_k$ 是可行的。当 $t = 0$ ,  $z = x^*$ 时,  $R$ 对 $z$ 的Jacobi矩阵为 $[A(x^*)^T; Z]^T$ 是非奇异的, 所以根据隐函数存在定理, 对于充分小的 $t_k$ , 方程组存在唯一的解 $z_k$ 。这些解 $z_k$ 满足 $c_i(z_k) = t_k A(x^*)d$ 。  
 当 $i \in \mathcal{E}$ 时, 即 $c_i(z_k) = t_k \nabla c_i(x^*)^T d = 0$ 。  
 当 $i \in \mathcal{A}(x^*) \cap \mathcal{J}$ 时,  $c_i(z_k) = t_k \nabla c_i(x^*)^T d \geq 0$ 。
- 第二小步: 对于可行的 $z_k$ , 满足 $\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$ 。对于 $R(z_k, t_k)$ 应用泰勒展开可以得到:

$$\begin{aligned}
 0 = R(z_k, t_k) &= \begin{bmatrix} c(z_k) - t_k A(x^*)d \\ z^T(z_k - x^* - t_k d) \end{bmatrix} \\
 &= \begin{bmatrix} c(x^*) + \nabla c(x^*)^T(z_k - x^*) + o(\|z_k - x^*\|) - t_k A(x^*)d \\ z^T(z_k - x^* - t_k d) \end{bmatrix} \\
 &= \begin{bmatrix} A(x^*) \\ Z^T \end{bmatrix} (z_k - x^* - t_k d) + o(\|z_k - x^*\|)
 \end{aligned}$$

两边同除以 $t_k$ , 并求极限可得:

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$$

## 引理1的证明

- 第一小步, 即 $z_k$ 是可行的。当 $t = 0$ ,  $z = x^*$ 时,  $R$ 对 $z$ 的Jacobi矩阵为 $[A(x^*)^T; Z]^T$ 是非奇异的, 所以根据隐函数存在定理, 对于充分小的 $t_k$ , 方程组存在唯一的解 $z_k$ 。这些解 $z_k$ 满足 $c_i(z_k) = t_k A(x^*)d$ 。  
 当 $i \in \mathcal{E}$ 时, 即 $c_i(z_k) = t_k \nabla c_i(x^*)^T d = 0$ 。  
 当 $i \in \mathcal{A}(x^*) \cap \mathcal{J}$ 时,  $c_i(z_k) = t_k \nabla c_i(x^*)^T d \geq 0$ 。
- 第二小步: 对于可行的 $z_k$ , 满足 $\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$ 。对于 $R(z_k, t_k)$ 应用泰勒展开可以得到:

$$\begin{aligned}
 0 = R(z_k, t_k) &= \begin{bmatrix} c(z_k) - t_k A(x^*)d \\ z^T(z_k - x^* - t_k d) \end{bmatrix} \\
 &= \begin{bmatrix} c(x^*) + \nabla c(x^*)^T(z_k - x^*) + o(\|z_k - x^*\|) - t_k A(x^*)d \\ z^T(z_k - x^* - t_k d) \end{bmatrix} \\
 &= \begin{bmatrix} A(x^*) \\ Z^T \end{bmatrix} (z_k - x^* - t_k d) + o(\|z_k - x^*\|)
 \end{aligned}$$

两边同除以 $t_k$ , 并求极限可得:

$$\lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d$$

# 引理2的证明

## 引理2

假定 $x^*$ 是一个局部最优解, 则有

$$\nabla f(x^*)^T d \geq 0, \text{ 对于任意的 } d \in T_{\Omega}(x^*)$$

## 引理2的证明

### 引理2

假定 $x^*$ 是一个局部最优解，则有

$$\nabla f(x^*)^T d \geq 0, \text{ 对于任意的 } d \in T_{\Omega}(x^*)$$

证明：（使用反证法）。

- 假设存在 $d \in T_{\Omega}(x^*)$ 满足 $\nabla f(x^*)^T d < 0$ ，则可以构造序列 $t_k \rightarrow 0^+$ ， $z_k - x^* = t_k d + o(t_k)$ ，满足

## 引理2的证明

### 引理2

假定 $x^*$ 是一个局部最优解，则有

$$\nabla f(x^*)^T d \geq 0, \text{ 对于任意的 } d \in T_{\Omega}(x^*)$$

证明：（使用反证法）。

- 假设存在 $d \in T_{\Omega}(x^*)$ 满足 $\nabla f(x^*)^T d < 0$ ，则可以构造序列 $t_k \rightarrow 0^+$ ， $z_k - x^* = t_k d + o(t_k)$ ，满足

$$f(z_k) - f(x^*) = \nabla f(x^*)^T (z_k - x^*) + o(\|z_k - x^*\|) = t_k \nabla f(x^*)^T d + o(t_k)$$

## 引理2的证明

## 引理2

假定 $x^*$ 是一个局部最优解，则有

$$\nabla f(x^*)^T d \geq 0, \text{ 对于任意的 } d \in T_{\Omega}(x^*)$$

证明：（使用反证法）。

- 假设存在 $d \in T_{\Omega}(x^*)$ 满足 $\nabla f(x^*)^T d < 0$ ，则可以构造序列 $t_k \rightarrow 0^+$ ， $z_k - x^* = t_k d + o(t_k)$ ，满足

$$f(z_k) - f(x^*) = \nabla f(x^*)^T (z_k - x^*) + o(\|z_k - x^*\|) = t_k \nabla f(x^*)^T d + o(t_k)$$

如果 $\nabla f(x^*)^T d < 0$ ，那么 $f(z_k) - f(x^*) < 0$ ，这与 $x^*$ 是局部最小值点是矛盾的。

## 第三个引理：Farkas引理

我们先定义一般意义下的几何锥

$$K = \{By + Cw \mid y \geq 0\}$$

其中 $B$ 和 $C$ 分别是 $n \times m$ 和 $n \times p$ 阶矩阵， $y \in \mathbb{R}^m$ 和 $w \in \mathbb{R}^p$ 是对应维数的向量。(如何判断一个向量不在锥 $K$ 里?)



## 第三个引理：Farkas引理

我们先定义一般意义下的几何锥

$$K = \{By + Cw \mid y \geq 0\}$$

其中 $B$ 和 $C$ 分别是 $n \times m$ 和 $n \times p$ 阶矩阵， $y \in \mathbb{R}^m$ 和 $w \in \mathbb{R}^p$ 是对应维数的向量。**(如何判断一个向量不在锥 $K$ 里?)**

### Farkas引理

如上定义锥 $K$ 。对于任意的一个向量 $g \in \mathbb{R}^n$ ，要么 $g \in K$ ，否则必定可以存在一个向量 $d \in \mathbb{R}^n$ 满足

$$g^T d < 0, \quad B^T d \geq 0, \quad C^T d = 0.$$

## 第三个引理：Farkas引理

我们先定义一般意义下的几何锥

$$K = \{By + Cw \mid y \geq 0\}$$

其中 $B$ 和 $C$ 分别是 $n \times m$ 和 $n \times p$ 阶矩阵， $y \in \mathbb{R}^m$ 和 $w \in \mathbb{R}^p$ 是对应维数的向量。  
(如何判断一个向量不在锥 $K$ 里?)

### Farkas引理

如上定义锥 $K$ 。对于任意的一个向量 $g \in \mathbb{R}^n$ ，要么 $g \in K$ ，否则必定可以存在一个向量 $d \in \mathbb{R}^n$ 满足

$$g^T d < 0, \quad B^T d \geq 0, \quad C^T d = 0.$$

我们首先说明两种情况不能同时成立(反证法)。

如果能同时成立，那么 $g \in K$ ，即存在 $y \geq 0$ 和 $w$ 满足  $g = By + Cw$ 。

## 第三个引理：Farkas引理

我们先定义一般意义下的几何锥

$$K = \{By + Cw \mid y \geq 0\}$$

其中 $B$ 和 $C$ 分别是 $n \times m$ 和 $n \times p$ 阶矩阵， $y \in \mathbb{R}^m$ 和 $w \in \mathbb{R}^p$ 是对应维数的向量。**(如何判断一个向量不在锥 $K$ 里?)**

### Farkas引理

如上定义锥 $K$ 。对于任意的一个向量 $g \in \mathbb{R}^n$ ，要么 $g \in K$ ，否则必定可以存在一个向量 $d \in \mathbb{R}^n$ 满足

$$g^T d < 0, \quad B^T d \geq 0, \quad C^T d = 0.$$

我们首先说明两种情况不能同时成立(反证法)。

如果能同时成立，那么 $g \in K$ ，即存在 $y \geq 0$ 和 $w$ 满足 $g = By + Cw$ 。同时又存在 $d \in \mathbb{R}^n$ ，满足 $g^T d < 0$ ， $B^T d \geq 0$ ， $C^T d = 0$ ，

## 第三个引理：Farkas引理

我们先定义一般意义下的几何锥

$$K = \{By + Cw \mid y \geq 0\}$$

其中 $B$ 和 $C$ 分别是 $n \times m$ 和 $n \times p$ 阶矩阵， $y \in \mathbb{R}^m$ 和 $w \in \mathbb{R}^p$ 是对应维数的向量。  
(如何判断一个向量不在锥 $K$ 里?)

### Farkas引理

如上定义锥 $K$ 。对于任意的一个向量 $g \in \mathbb{R}^n$ ，要么 $g \in K$ ，否则必定可以存在一个向量 $d \in \mathbb{R}^n$ 满足

$$g^T d < 0, \quad B^T d \geq 0, \quad C^T d = 0.$$

我们首先说明两种情况不能同时成立(反证法)。

如果能同时成立，那么 $g \in K$ ，即存在 $y \geq 0$ 和 $w$ 满足 $g = By + Cw$ 。同时又存在 $d \in \mathbb{R}^n$ ，满足 $g^T d < 0$ ， $B^T d \geq 0$ ， $C^T d = 0$ ，则容易计算 $d^T g$ 得到如下的矛盾：

## 第三个引理：Farkas引理

我们先定义一般意义下的几何锥

$$K = \{By + Cw \mid y \geq 0\}$$

其中 $B$ 和 $C$ 分别是 $n \times m$ 和 $n \times p$ 阶矩阵， $y \in \mathbb{R}^m$ 和 $w \in \mathbb{R}^p$ 是对应维数的向量。**(如何判断一个向量不在锥 $K$ 里?)**

### Farkas引理

如上定义锥 $K$ 。对于任意的一个向量 $g \in \mathbb{R}^n$ ，要么 $g \in K$ ，否则必定可以存在一个向量 $d \in \mathbb{R}^n$ 满足

$$g^T d < 0, \quad B^T d \geq 0, \quad C^T d = 0.$$

我们首先说明两种情况不能同时成立(反证法)。

如果能同时成立，那么 $g \in K$ ，即存在 $y \geq 0$ 和 $w$ 满足 $g = By + Cw$ 。同时又存在 $d \in \mathbb{R}^n$ ，满足 $g^T d < 0$ ， $B^T d \geq 0$ ， $C^T d = 0$ ，则容易计算 $d^T g$ 得到如下的矛盾：

$$0 > d^T g = d^T (By + Cw) = (B^T d)^T y + (C^T d)^T w \geq 0$$

## 第三个引理：Farkas引理

我们先定义一般意义下的几何锥

$$K = \{By + Cw \mid y \geq 0\}$$

其中 $B$ 和 $C$ 分别是 $n \times m$ 和 $n \times p$ 阶矩阵， $y \in \mathbb{R}^m$ 和 $w \in \mathbb{R}^p$ 是对应维数的向量。**(如何判断一个向量不在锥 $K$ 里?)**

### Farkas引理

如上定义锥 $K$ 。对于任意的一个向量 $g \in \mathbb{R}^n$ ，要么 $g \in K$ ，否则必定可以存在一个向量 $d \in \mathbb{R}^n$ 满足

$$g^T d < 0, \quad B^T d \geq 0, \quad C^T d = 0.$$

我们首先说明两种情况不能同时成立(反证法)。

如果能同时成立，那么 $g \in K$ ，即存在 $y \geq 0$ 和 $w$ 满足 $g = By + Cw$ 。同时又存在 $d \in \mathbb{R}^n$ ，满足 $g^T d < 0$ ， $B^T d \geq 0$ ， $C^T d = 0$ ，则容易计算 $d^T g$ 得到如下的矛盾：

$$0 > d^T g = d^T (By + Cw) = (B^T d)^T y + (C^T d)w \geq 0$$

下面接着**构造性**地证明如果 $g \notin K$ ，必须要存在 $d$ 满足 $g^T d < 0$ ， $B^T d \geq 0$ ， $C^T d = 0$ 。

## 第三个引理：Farkas引理

下面接着构造性地证明如果  $g \notin K$ ，必须要存在  $d$  满足  $g^T d < 0$ ,  $B^T d \geq 0$ ,  $C^T d = 0$ 。

## 第三个引理：Farkas引理

下面接着构造性地证明如果  $g \notin K$ ，必须要存在  $d$  满足  $g^T d < 0$ ,  $B^T d \geq 0$ ,  $C^T d = 0$ 。

- 令  $\hat{s} = \arg \min_{s \in K} \|s - g\|_2^2$  是  $g$  在  $K$  中的最佳逼近元，则  $\hat{s}$  和  $\hat{s} - g$  是垂直的，即  $\hat{s}^T (\hat{s} - g) = 0$ 。
- 构造  $d = \hat{s} - g$ ，验证引理中的结论。



## 第三个引理：Farkas引理

下面接着构造性地证明如果  $g \notin K$ ，必须要存在  $d$  满足  $g^T d < 0$ ,  $B^T d \geq 0$ ,  $C^T d = 0$ 。

- 令  $\hat{s} = \arg \min_{s \in K} \|s - g\|_2^2$  是  $g$  在  $K$  中的最佳逼近元，则  $\hat{s}$  和  $\hat{s} - g$  是垂直的，即  $\hat{s}^T(\hat{s} - g) = 0$ 。
- 构造  $d = \hat{s} - g$ ，验证引理中的结论。  
 (1)  $g^T d = (\hat{s} - d)^T d = \hat{s}^T d - d^T d = \hat{s}(\hat{s} - g) - d^T d = -\|d\|^2 < 0$

## 第三个引理：Farkas引理

下面接着构造性地证明如果  $g \notin K$ ，必须要存在  $d$  满足  $g^T d < 0$ ,  $B^T d \geq 0$ ,  $C^T d = 0$ 。

- 令  $\hat{s} = \arg \min_{s \in K} \|s - g\|_2^2$  是  $g$  在  $K$  中的最佳逼近元，则  $\hat{s}$  和  $\hat{s} - g$  是垂直的，即  $\hat{s}^T(\hat{s} - g) = 0$ 。
- 构造  $d = \hat{s} - g$ ，验证引理中的结论。
  - $g^T d = (\hat{s} - d)^T d = \hat{s}^T d - d^T d = \hat{s}(\hat{s} - g) - d^T d = -\|d\|^2 < 0$
  - 由于  $K$  是一个凸集，假定  $s \in K$ ,  $\theta \in [0, 1]$ ，则  $\hat{s} + \theta(s - \hat{s})$  是凸组合也属于  $K$ ，因此  $g$  与该向量的距离肯定比  $g$  与  $\hat{s}$  的距离要大。即

$$\|(\hat{s} + \theta(s - \hat{s})) - g\|_2^2 \geq \|\hat{s} - g\|_2^2$$

由此可以推出  $s^T(\hat{s} - g) \geq 0$ ，即  $s^T d \geq 0$

## 第三个引理：Farkas引理

下面接着构造性地证明如果  $g \notin K$ ，必须要存在  $d$  满足  $g^T d < 0$ ,  $B^T d \geq 0$ ,  $C^T d = 0$ 。

- 令  $\hat{s} = \arg \min_{s \in K} \|s - g\|_2^2$  是  $g$  在  $K$  中的最佳逼近元，则  $\hat{s}$  和  $\hat{s} - g$  是垂直的，即  $\hat{s}^T(\hat{s} - g) = 0$ 。
- 构造  $d = \hat{s} - g$ ，验证引理中的结论。
  - $g^T d = (\hat{s} - d)^T d = \hat{s}^T d - d^T d = \hat{s}(\hat{s} - g) - d^T d = -\|d\|^2 < 0$
  - 由于  $K$  是一个凸集，假定  $s \in K$ ,  $\theta \in [0, 1]$ ，则  $\hat{s} + \theta(s - \hat{s})$  是凸组合也属于  $K$ ，因此  $g$  与该向量的距离肯定比  $g$  与  $\hat{s}$  的距离要大。即

$$\|(\hat{s} + \theta(s - \hat{s})) - g\|_2^2 \geq \|\hat{s} - g\|_2^2$$

由此可以推出  $s^T(\hat{s} - g) \geq 0$ ，即  $s^T d \geq 0$  于是  $d^T(By + Cw) \geq 0$ ,  $\forall y \geq 0, w \in \mathbb{R}^n$ 。

## 第三个引理：Farkas引理

下面接着构造性地证明如果  $g \notin K$ ，必须要存在  $d$  满足  $g^T d < 0$ ,  $B^T d \geq 0$ ,  $C^T d = 0$ 。

- 令  $\hat{s} = \arg \min_{s \in K} \|s - g\|_2^2$  是  $g$  在  $K$  中的最佳逼近元，则  $\hat{s}$  和  $\hat{s} - g$  是垂直的，即  $\hat{s}^T(\hat{s} - g) = 0$ 。
- 构造  $d = \hat{s} - g$ ，验证引理中的结论。
  - $g^T d = (\hat{s} - d)^T d = \hat{s}^T d - d^T d = \hat{s}(\hat{s} - g) - d^T d = -\|d\|^2 < 0$
  - 由于  $K$  是一个凸集，假定  $s \in K$ ,  $\theta \in [0, 1]$ ，则  $\hat{s} + \theta(s - \hat{s})$  是凸组合也属于  $K$ ，因此  $g$  与该向量的距离肯定比  $g$  与  $\hat{s}$  的距离要大。即

$$\|(\hat{s} + \theta(s - \hat{s})) - g\|_2^2 \geq \|\hat{s} - g\|_2^2$$

由此可以推出  $s^T(\hat{s} - g) \geq 0$ ，即  $s^T d \geq 0$  于是  $d^T(B^T y + C^T w) \geq 0$ ,  $\forall y \geq 0, w \in \mathbb{R}^n$ 。取  $y = 0$ ，有  $(C^T d)^T w \geq 0$ ，由  $w$  的任意性，只有  $C^T d = 0$ 。

(3) 再令  $w = 0$ ，则可以得到  $(B^T d)^T y \geq 0, \forall y \geq 0$ ，可以推出  $B^T d \geq 0$ 。

# 证明KKT条件

我们定义如下的锥 $N$ ,

$$K = \left\{ \sum_{i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i \geq 0} \lambda_i \nabla c_i(x^*) + \sum_{i \in \mathcal{E}} \lambda_i \nabla c_i(x^*) \right\}$$

$$g = \nabla f(x^*)$$

# 证明KKT条件

我们定义如下的锥 $N$ ,

$$K = \left\{ \sum_{i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i \geq 0} \lambda_i \nabla c_i(x^*) + \sum_{i \in \mathcal{E}} \lambda_i \nabla c_i(x^*) \right\}$$

$$g = \nabla f(x^*)$$

显然, 对于 $g$ , 要么 $g \in K$ , 即

$$\nabla f(x^*) = \sum_{i \in \mathcal{A}(x^*)} \lambda_i \nabla c_i(x^*) = A(x^*)^T \lambda^*, \text{ 其中 } \lambda_i \geq 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}$$

# 证明KKT条件

我们定义如下的锥 $N$ ,

$$K = \left\{ \sum_{i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i \geq 0} \lambda_i \nabla c_i(x^*) + \sum_{i \in \mathcal{E}} \lambda_i \nabla c_i(x^*) \right\}$$

$$g = \nabla f(x^*)$$

显然, 对于 $g$ , 要么 $g \in K$ , 即

$$\nabla f(x^*) = \sum_{i \in \mathcal{A}(x^*)} \lambda_i \nabla c_i(x^*) = A(x^*)^T \lambda^*, \text{ 其中 } \lambda_i \geq 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}$$

要么 $g \notin K$ , 即存在某个方向满足

$$\nabla f(x^*)^T d < 0, \quad \nabla c_i^T d \geq 0, i \in \mathcal{A}(x^*) \cap \mathcal{J}, \quad \nabla c_i^T d = 0, i \in \mathcal{E}.$$

也就是 $d \in \mathcal{F}(x^*)$ , 而且 $d$ 是 $f$ 的上升方向。

# 证明KKT条件

我们定义如下的锥 $N$ ,

$$K = \left\{ \sum_{i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i \geq 0} \lambda_i \nabla c_i(x^*) + \sum_{i \in \mathcal{E}} \lambda_i \nabla c_i(x^*) \right\}$$

$$g = \nabla f(x^*)$$

显然, 对于 $g$ , 要么 $g \in K$ , 即

$$\nabla f(x^*) = \sum_{i \in \mathcal{A}(x^*)} \lambda_i \nabla c_i(x^*) = A(x^*)^T \lambda^*, \text{ 其中 } \lambda_i \geq 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}$$

要么 $g \notin K$ , 即存在某个方向满足

$$\nabla f(x^*)^T d < 0, \quad \nabla c_i^T d \geq 0, i \in \mathcal{A}(x^*) \cap \mathcal{J}, \quad \nabla c_i^T d = 0, i \in \mathcal{E}.$$

也就是 $d \in \mathcal{F}(x^*)$ , 而且 $d$ 是 $f$ 的上升方向。

最后, 根据引理2, 我们知道当 $x^*$ 是局部最优解时, 第二种情况是不能出现的, 所以只能出现第一种情况, 即证明了KKT条件。



## 二阶最优性条件(Second Order Optimality Conditions)

## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。

## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。
- 如果在 $x^*$ 处的切锥里存在这样的方向 $w \in \mathcal{F}(x^*)$ , 满足 $w^T \nabla f(x^*) = 0$ , 如何判断 $x^*$ 是不是一个局部最优解?

## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。
- 如果在 $x^*$ 处的切锥里存在这样的方向 $w \in \mathcal{F}(x^*)$ , 满足 $w^T \nabla f(x^*) = 0$ , 如何判断 $x^*$ 是不是一个局部最优解? 此时要判断 $f(x)$ 沿着 $w$ 到底是不是可以继续下降, 要看 $f$ 的二阶导数(tiebreaking)!
- 定义一个关键锥(critical cone)

$$\mathcal{C}(x^*, \lambda^*) = \left\{ w \in \mathcal{F}(x^*) \mid \nabla c_i^T w = 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i > 0 \right\}.$$

## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。
- 如果在 $x^*$ 处的切锥里存在这样的方向 $w \in \mathcal{F}(x^*)$ , 满足 $w^T \nabla f(x^*) = 0$ , 如何判断 $x^*$ 是不是一个局部最优解? 此时要判断 $f(x)$ 沿着 $w$ 到底是不是可以继续下降, 要看 $f$ 的二阶导数(tiebreaking)!
- 定义一个关键锥(critical cone)

$$\mathcal{C}(x^*, \lambda^*) = \left\{ w \in \mathcal{F}(x^*) \mid \nabla c_i^T w = 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i > 0 \right\}.$$

- 注: 为什么 $\mathcal{C}(x^*, \lambda^*)$ 中只需要考虑 $\lambda_i > 0$ 的部分?

## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。
- 如果在 $x^*$ 处的切锥里存在这样的方向 $w \in \mathcal{F}(x^*)$ , 满足 $w^T \nabla f(x^*) = 0$ , 如何判断 $x^*$ 是不是一个局部最优解? 此时要判断 $f(x)$ 沿着 $w$ 到底是不是可以继续下降, 要看 $f$ 的二阶导数(tiebreaking)!
- 定义一个关键锥(critical cone)

$$\mathcal{C}(x^*, \lambda^*) = \left\{ w \in \mathcal{F}(x^*) \mid \nabla c_i^T w = 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i > 0 \right\}.$$

- 注: 为什么 $\mathcal{C}(x^*, \lambda^*)$ 中只需要考虑 $\lambda_i > 0$ 的部分? 这是因为当考虑 $w^T \nabla f(x^*) = w^T \sum_{i \in \mathcal{A}(x^*)} w^T \lambda_i \nabla c_i(x)$ 等于0时, 有很多部分已经自动为0, 比如

## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。
- 如果在 $x^*$ 处的切锥里存在这样的方向 $w \in \mathcal{F}(x^*)$ , 满足 $w^T \nabla f(x^*) = 0$ , 如何判断 $x^*$ 是不是一个局部最优解? 此时要判断 $f(x)$ 沿着 $w$ 到底是不是可以继续下降, 要看 $f$ 的二阶导数(tiebreaking)!
- 定义一个关键锥(critical cone)

$$\mathcal{C}(x^*, \lambda^*) = \left\{ w \in \mathcal{F}(x^*) \mid \nabla c_i^T w = 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i > 0 \right\}.$$

- 注: 为什么 $\mathcal{C}(x^*, \lambda^*)$ 中只需要考虑 $\lambda_i > 0$ 的部分? 这是因为当考虑 $w^T \nabla f(x^*) = w^T \sum_{i \in \mathcal{A}(x^*)} w^T \lambda_i \nabla c_i(x)$ 等于0时, 有很多部分已经自动为0, 比如  
(1) 当 $\forall i \in \mathcal{E}$ 时,  $\nabla c_i(x^*)^T w = 0$ .

## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。
- 如果在 $x^*$ 处的切锥里存在这样的方向 $w \in \mathcal{F}(x^*)$ , 满足 $w^T \nabla f(x^*) = 0$ , 如何判断 $x^*$ 是不是一个局部最优解? 此时要判断 $f(x)$ 沿着 $w$ 到底是不是可以继续下降, 要看 $f$ 的二阶导数(tiebreaking)!
- 定义一个关键锥(critical cone)

$$\mathcal{C}(x^*, \lambda^*) = \left\{ w \in \mathcal{F}(x^*) \mid \nabla c_i^T w = 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i > 0 \right\}.$$

- 注: 为什么 $\mathcal{C}(x^*, \lambda^*)$ 中只需要考虑 $\lambda_i > 0$ 的部分? 这是因为当考虑 $w^T \nabla f(x^*) = w^T \sum_{i \in \mathcal{A}(x^*)} w^T \lambda_i \nabla c_i(x)$ 等于0时, 有很多部分已经自动为0, 比如
  - (1) 当 $\forall i \in \mathcal{E}$ 时,  $\nabla c_i(x^*)^T w = 0$ .
  - (2) 当 $\forall i \in \mathcal{A}(x^*) \cap \mathcal{J}$ 而且 $\lambda_i = 0$ 时,  $\nabla c_i(x^*)^T w$ 可以  $\geq 0$ .



## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。
- 如果在 $x^*$ 处的切锥里存在这样的方向 $w \in \mathcal{F}(x^*)$ , 满足 $w^T \nabla f(x^*) = 0$ , 如何判断 $x^*$ 是不是一个局部最优解? 此时要判断 $f(x)$ 沿着 $w$ 到底是不是可以继续下降, 要看 $f$ 的二阶导数(tiebreaking)!
- 定义一个关键锥(critical cone)

$$\mathcal{C}(x^*, \lambda^*) = \left\{ w \in \mathcal{F}(x^*) \mid \nabla c_i^T w = 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i > 0 \right\}.$$

- 注: 为什么 $\mathcal{C}(x^*, \lambda^*)$ 中只需要考虑 $\lambda_i > 0$ 的部分? 这是因为当考虑 $w^T \nabla f(x^*) = w^T \sum_{i \in \mathcal{A}(x^*)} w^T \lambda_i \nabla c_i(x)$ 等于0时, 有很多部分已经自动为0, 比如
  - (1) 当 $\forall i \in \mathcal{E}$ 时,  $\nabla c_i(x^*)^T w = 0$ .
  - (2) 当 $\forall i \in \mathcal{A}(x^*) \cap \mathcal{J}$ 而且 $\lambda_i = 0$ 时,  $\nabla c_i(x^*)^T w$ 可以  $\geq 0$ .
  - (3) 当 $\forall i \in \mathcal{A}(x^*) \cap \mathcal{J}$ 而且 $\lambda_i > 0$ 时,  $\nabla c_i(x^*)^T w$ 必须  $= 0$ .

## 二阶条件

- KKT条件中仅考虑了 $\nabla c_i$ 和 $\nabla f$ 的性质。
- 如果在 $x^*$ 处的切锥里存在这样的方向 $w \in \mathcal{F}(x^*)$ , 满足 $w^T \nabla f(x^*) = 0$ , 如何判断 $x^*$ 是不是一个局部最优解? 此时要判断 $f(x)$ 沿着 $w$ 到底是不是可以继续下降, 要看 $f$ 的二阶导数(tiebreaking)!
- 定义一个关键锥(critical cone)


$$\mathcal{C}(x^*, \lambda^*) = \left\{ w \in \mathcal{F}(x^*) \mid \nabla c_i^T w = 0, \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}, \lambda_i > 0 \right\}.$$

- 注: 为什么 $\mathcal{C}(x^*, \lambda^*)$ 中只需要考虑 $\lambda_i > 0$ 的部分? 这是因为当考虑 $w^T \nabla f(x^*) = w^T \sum_{i \in \mathcal{A}(x^*)} w^T \lambda_i \nabla c_i(x)$ 等于0时, 有很多部分已经自动为0, 比如
  - (1) 当 $\forall i \in \mathcal{E}$ 时,  $\nabla c_i(x^*)^T w = 0$ .
  - (2) 当 $\forall i \in \mathcal{A}(x^*) \cap \mathcal{J}$ 而且 $\lambda_i = 0$ 时,  $\nabla c_i(x^*)^T w$ 可以  $\geq 0$ .
  - (3) 当 $\forall i \in \mathcal{A}(x^*) \cap \mathcal{J}$ 而且 $\lambda_i > 0$ 时,  $\nabla c_i(x^*)^T w$ 必须  $= 0$ .
 也就是说  $w^T \nabla f(x^*) = 0$ , 不确定的方向就是关键锥里的方向。

## 二阶条件

例5：考虑如下的优化问题

$$\begin{aligned} \min \quad & x_1 \\ \text{s.t.} \quad & x_2 \geq 0 \\ & 1 - (x_1 - 1)^2 - x_2^2 \geq 0 \end{aligned}$$




- 全局最优解是  $x^* = (0, 0)^T$ ,  $\mathcal{A}(x^*) = \{1, 2\}$ ,  $\lambda^* = (0, 0.5)^T$ 。

## 二阶条件

例5：考虑如下的优化问题

$$\begin{aligned} \min \quad & x_1 \\ \text{s.t.} \quad & x_2 \geq 0 \\ & 1 - (x_1 - 1)^2 - x_2^2 \geq 0 \end{aligned}$$




- 全局最优解是  $x^* = (0, 0)^T$ ,  $\mathcal{A}(x^*) = \{1, 2\}$ ,  $\lambda^* = (0, 0.5)^T$ 。
- 注意到，在  $x^*$  点处，活跃集中的梯度分别是  $\nabla c_1(x^*) = (0, 1)^T$ ,  $\nabla c_2(x^*) = (2, 0)^T$ ，满足LICQ条件。

## 二阶条件

例5：考虑如下的优化问题

$$\begin{aligned} \min \quad & x_1 \\ \text{s.t.} \quad & x_2 \geq 0 \\ & 1 - (x_1 - 1)^2 - x_2^2 \geq 0 \end{aligned}$$




- 全局最优解是  $x^* = (0, 0)^T$ ,  $\mathcal{A}(x^*) = \{1, 2\}$ ,  $\lambda^* = (0, 0.5)^T$ 。
- 注意到，在  $x^*$  点处，活跃集中的梯度分别是  $\nabla c_1(x^*) = (0, 1)^T$ ,  $\nabla c_2(x^*) = (2, 0)^T$ ，满足LICQ条件。
- $\mathcal{F}(x^*) = \{d | d \geq 0\}$ 。注意到在  $\mathcal{F}$  中，都是  $f$  非减的方向，这与  $x^*$  是局部最优解并不矛盾。但是要判定  $x^*$  就是最优解，还不够。

## 二阶条件

例5：考虑如下的优化问题

$$\begin{aligned} \min \quad & x_1 \\ \text{s.t.} \quad & x_2 \geq 0 \\ & 1 - (x_1 - 1)^2 - x_2^2 \geq 0 \end{aligned}$$



- 全局最优解是  $x^* = (0, 0)^T$ ,  $\mathcal{A}(x^*) = \{1, 2\}$ ,  $\lambda^* = (0, 0.5)^T$ 。
- 注意到，在  $x^*$  点处，活跃集中的梯度分别是  $\nabla c_1(x^*) = (0, 1)^T$ ,  $\nabla c_2(x^*) = (2, 0)^T$ ，满足LICQ条件。
- $\mathcal{F}(x^*) = \{d | d \geq 0\}$ 。注意到在  $\mathcal{F}$  中，都是  $f$  非减的方向，这与  $x^*$  是局部最优解并不矛盾。但是要判定  $x^*$  就是最优解，还不够。
- 因为在关键锥内的方向上，也就是  $\mathcal{C}(x^*, \lambda^*) = \{(0, w_2) | w_2 \geq 0\}$  上， $\nabla f(x^*) = 0$ ， $f$  到底是增还是减，不好判断。

## 二阶必要性条件

### 定理(二阶必要性条件)

假设 $x^*$ 是局部最优解, 且LICQ成立,  $\lambda^*$ 是对应的拉格朗日乘子, 则

$$w^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) w \geq 0, \quad \forall w \in \mathcal{C}(x^*, \lambda^*).$$

## 二阶必要性条件

### 定理(二阶必要性条件)

假设 $x^*$ 是局部最优解，且LICQ成立， $\lambda^*$ 是对应的拉格朗日乘子，则

$$w^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) w \geq 0, \quad \forall w \in \mathcal{C}(x^*, \lambda^*).$$

证明：令 $z_k = x^* + t_k w + o(t_k^2)$ ,  $w \in \mathcal{C}(x^*, \lambda^*)$ ，主要使用泰勒展开到第二阶

$$\begin{aligned} \mathcal{L}(z_k, \lambda^*) &= \mathcal{L}(x^*, \lambda^*) + (z_k - x^*)^T \nabla_x \mathcal{L}(x^*, \lambda^*) \\ &\quad + \frac{1}{2} (z_k - x^*)^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) (z_k - x^*) + o(\|z_k - x^*\|^2) \\ &= f(x^*) + \frac{1}{2} t_k^2 w^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) w + o(t_k^2) \end{aligned}$$

如果  $w^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) w < 0$ ，则  $f(z_k) < f(x^*)$  产生矛盾。



## 二阶充分性条件

### 定理(二阶充分性条件)

假设对于可行点 $x^*$ 处存在 $\lambda^*$ 使得KKT条件成立，并且对于

$$w^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) w > 0, \quad \forall w \in \mathcal{C}(x^*, \lambda^*), w \neq 0.$$

则 $x^*$ 是严格的局部最优解。证明：略。

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= x_1 + x_2 \\ \text{s.t.} \quad c_1(x) &= 2 - x_1^2 - 2x_2^2 \geq 0, \end{aligned}$$

- Lagrange函数  $\mathcal{L}(x_1, x_2; \lambda_1) = (x_1 + x_2) - \lambda_1(2 - x_1^2 - x_2^2)$

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= x_1 + x_2 \\ \text{s.t.} \quad c_1(x) &= 2 - x_1^2 - 2x_2^2 \geq 0, \end{aligned}$$

- Lagrange函数  $\mathcal{L}(x_1, x_2; \lambda_1) = (x_1 + x_2) - \lambda_1(2 - x_1^2 - x_2^2)$
- 由一阶最优性条件得到

$$\nabla_x \mathcal{L} = \begin{bmatrix} 1 + 2\lambda_1 x_1 \\ 1 + 2\lambda_2 x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, x_1^2 + x_2^2 = 2, \lambda_1 > 0$$

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= x_1 + x_2 \\ \text{s.t.} \quad c_1(x) &= 2 - x_1^2 - 2x_2^2 \geq 0, \end{aligned}$$

- Lagrange函数  $\mathcal{L}(x_1, x_2; \lambda_1) = (x_1 + x_2) - \lambda_1(2 - x_1^2 - x_2^2)$
- 由一阶最优性条件得到

$$\nabla_x \mathcal{L} = \begin{bmatrix} 1 + 2\lambda_1 x_1 \\ 1 + 2\lambda_2 x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, x_1^2 + x_2^2 = 2, \lambda_1 > 0$$

得到  $x^* = (-1, -1)^T$ ,  $\lambda_1^* = \frac{1}{2}$ 。

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= x_1 + x_2 \\ \text{s.t.} \quad c_1(x) &= 2 - x_1^2 - 2x_2^2 \geq 0, \end{aligned}$$

- Lagrange函数  $\mathcal{L}(x_1, x_2; \lambda_1) = (x_1 + x_2) - \lambda_1(2 - x_1^2 - x_2^2)$
- 由一阶最优性条件得到

$$\nabla_x \mathcal{L} = \begin{bmatrix} 1 + 2\lambda_1 x_1 \\ 1 + 2\lambda_2 x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, x_1^2 + x_2^2 = 2, \lambda_1 > 0$$

得到  $x^* = (-1, -1)^T$ ,  $\lambda_1^* = \frac{1}{2}$ 。

- 验证是否满足充分性：

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= x_1 + x_2 \\ \text{s.t.} \quad c_1(x) &= 2 - x_1^2 - 2x_2^2 \geq 0, \end{aligned}$$

- Lagrange函数  $\mathcal{L}(x_1, x_2; \lambda_1) = (x_1 + x_2) - \lambda_1(2 - x_1^2 - x_2^2)$
- 由一阶最优性条件得到

$$\nabla_x \mathcal{L} = \begin{bmatrix} 1 + 2\lambda_1 x_1 \\ 1 + 2\lambda_1 x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, x_1^2 + x_2^2 = 2, \lambda_1 > 0$$

得到  $x^* = (-1, -1)^T$ ,  $\lambda_1^* = \frac{1}{2}$ 。

- 验证是否满足充分性：

$$\nabla_{xx}^2 \mathcal{L} = \begin{bmatrix} 2\lambda_1^* & 0 \\ 0 & 2\lambda_1^* \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

于是对于任意的  $w \neq 0$  都满足  $w^T \nabla_{xx}^2 \mathcal{L} w = w^T w > 0$ 。

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= x_1 + x_2 \\ \text{s.t.} \quad c_1(x) &= 2 - x_1^2 - 2x_2^2 \geq 0, \end{aligned}$$

- Lagrange函数  $\mathcal{L}(x_1, x_2; \lambda_1) = (x_1 + x_2) - \lambda_1(2 - x_1^2 - x_2^2)$
- 由一阶最优性条件得到

$$\nabla_x \mathcal{L} = \begin{bmatrix} 1 + 2\lambda_1 x_1 \\ 1 + 2\lambda_1 x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, x_1^2 + x_2^2 = 2, \lambda_1 > 0$$

得到  $x^* = (-1, -1)^T$ ,  $\lambda_1^* = \frac{1}{2}$ 。

- 验证是否满足充分性：

$$\nabla_{xx}^2 \mathcal{L} = \begin{bmatrix} 2\lambda_1^* & 0 \\ 0 & 2\lambda_1^* \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

于是对于任意的  $w \neq 0$  都满足  $w^T \nabla_{xx}^2 \mathcal{L} w = w^T w > 0$ 。  
即  $x^*$  一定是一个局部最优解。

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= -0.1(x_1 - 4)^2 + x_2^2 \\ \text{s.t. } c_1(x) &= x_1^2 + x_2^2 - 1 \geq 0 \end{aligned}$$



## 二阶充分性条件

$$\begin{aligned} \min f(x) &= -0.1(x_1 - 4)^2 + x_2^2 \\ \text{s.t. } c_1(x) &= x_1^2 + x_2^2 - 1 \geq 0 \end{aligned}$$

- 首先可行域是单位圆的外部，目标函数值是可以趋于无穷大 $(\infty, 0)$ ，因此没有全局最优解，但是在可行域的边界上还是可以去到局部最小值。

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= -0.1(x_1 - 4)^2 + x_2^2 \\ \text{s.t. } c_1(x) &= x_1^2 + x_2^2 - 1 \geq 0 \end{aligned}$$

- 首先可行域是单位圆的外部，目标函数值是可以趋于无穷大 $(\infty, 0)$ ，因此没有全局最优解，但是在可行域的边界上还是可以去到局部最小值。
- 定义 $\mathcal{L}(x, \lambda_1) = -0.1(x_1 - 4)^2 + x_2^2 - \lambda_1(x_1^2 + x_2^2 - 1)$ 使用KKT条件，

$$\nabla f - \lambda_1 \nabla c_1 = \begin{bmatrix} -0.2(x_1 - 4) - 2\lambda_1 x_1 \\ 2x_2 - 2\lambda_1 x_2 \end{bmatrix} = 0, \quad \lambda_1(x_1^2 + x_2^2 - 1) = 0$$

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= -0.1(x_1 - 4)^2 + x_2^2 \\ \text{s.t. } c_1(x) &= x_1^2 + x_2^2 - 1 \geq 0 \end{aligned}$$

- 首先可行域是单位圆的外部，目标函数值是可以趋于无穷大 $(\infty, 0)$ ，因此没有全局最优解，但是在可行域的边界上还是可以去到局部最小值。
- 定义 $\mathcal{L}(x, \lambda_1) = -0.1(x_1 - 4)^2 + x_2^2 - \lambda_1(x_1^2 + x_2^2 - 1)$ 使用KKT条件，

$$\nabla f - \lambda_1 \nabla c_1 = \begin{bmatrix} -0.2(x_1 - 4) - 2\lambda_1 x_1 \\ 2x_2 - 2\lambda_1 x_2 \end{bmatrix} = 0, \quad \lambda_1(x_1^2 + x_2^2 - 1) = 0$$

- 求解得到 $x^* = (1, 0)^T$ ,  $\lambda_1^* = 0.3$ 。  $\mathcal{A}(x^*) = \{1\}$ 。

## 二阶充分性条件

$$\begin{aligned} \min f(x) &= -0.1(x_1 - 4)^2 + x_2^2 \\ \text{s.t. } c_1(x) &= x_1^2 + x_2^2 - 1 \geq 0 \end{aligned}$$

- 首先可行域是单位圆的外部，目标函数值是可以趋于无穷大 $(\infty, 0)$ ，因此没有全局最优解，但是在可行域的边界上还是可以去到局部最小值。
- 定义 $\mathcal{L}(x, \lambda_1) = -0.1(x_1 - 4)^2 + x_2^2 - \lambda_1(x_1^2 + x_2^2 - 1)$ 使用KKT条件，

$$\nabla f - \lambda_1 \nabla c_1 = \begin{bmatrix} -0.2(x_1 - 4) - 2\lambda_1 x_1 \\ 2x_2 - 2\lambda_1 x_2 \end{bmatrix} = 0, \quad \lambda_1(x_1^2 + x_2^2 - 1) = 0$$

- 求解得到 $x^* = (1, 0)^T$ ,  $\lambda_1^* = 0.3$ 。  $\mathcal{A}(x^*) = \{1\}$ 。
- 检验二阶最优性充分条件

$$\nabla c_1(x^*) = \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \quad \mathcal{C}(x^*, \lambda^*) = \{(0, w_2)^T \mid w_2 \in \mathbb{R}\},$$

$$w^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^2) w = \begin{bmatrix} 2 \\ 0 \end{bmatrix} \begin{bmatrix} -0.8 & 0 \\ 0 & 1.4 \end{bmatrix} \begin{bmatrix} 0 \\ w_2 \end{bmatrix} = 1.4w_2^2 > 0.$$

## 二阶条件和投影Hessians

- 二阶条件(必要性、充分性)的验证通常比较复杂，为此人们提出了一种稍微弱化但比较方便的形式。

## 二阶条件和投影Hessians

- 二阶条件(必要性、充分性)的验证通常比较复杂，为此人们提出了一种稍微弱化但比较方便的形式。
- 当满足KKT条件的 $\lambda^*$ 是唯一的(比如LICQ)，并且严格互补性条件成立，此时关键锥的定义可以简化为：

$$\mathcal{C}(x^*, \lambda^*) = \text{Null}[\nabla c_i(x^*)^T]_{i \in \mathcal{A}(x^*)} = \text{Null}A(x^*) = \{Zu \mid u \in \mathbb{R}^{|\mathcal{A}(x^*)|}\}$$

这里 $Z$ 表示 $A(x^*)$ 的零空间的基组成的矩阵， $|\mathcal{A}(x^*)|$ 表示活跃约束的个数。

## 二阶条件和投影Hessians

- 二阶条件(必要性、充分性)的验证通常比较复杂, 为此人们提出了一种稍微弱化但比较方便的形式。
- 当满足KKT条件的 $\lambda^*$ 是唯一的(比如LICQ), 并且严格互补性条件成立, 此时关键锥的定义可以简化为:

$$\mathcal{C}(x^*, \lambda^*) = \text{Null}[\nabla c_i(x^*)^T]_{i \in \mathcal{A}(x^*)} = \text{Null}A(x^*) = \{Zu \mid u \in \mathbb{R}^{|\mathcal{A}(x^*)|}\}$$

这里 $Z$ 表示 $A(x^*)$ 的零空间的基组成的矩阵,  $|\mathcal{A}(x^*)|$ 表示活跃约束的个数。

- 可以判定 $Z^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) Z$ 的半正定性或正定性。

## 二阶条件和投影 Hessians

- 二阶条件(必要性、充分性)的验证通常比较复杂, 为此人们提出了一种稍微弱化但比较方便的形式。
- 当满足KKT条件的 $\lambda^*$ 是唯一的(比如LICQ), 并且严格互补性条件成立, 此时关键锥的定义可以简化为:

$$\mathcal{C}(x^*, \lambda^*) = \text{Null}[\nabla c_i(x^*)^T]_{i \in \mathcal{A}(x^*)} = \text{Null}A(x^*) = \{Zu \mid u \in \mathbb{R}^{|\mathcal{A}(x^*)|}\}$$

这里 $Z$ 表示 $A(x^*)$ 的零空间的基组成的矩阵,  $|\mathcal{A}(x^*)|$ 表示活跃约束的个数。

- 可以判定 $Z^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) Z$ 的半正定性或正定性。
- 如何得到 $Z$ ?



## 二阶条件和投影Hessians

- 二阶条件(必要性、充分性)的验证通常比较复杂, 为此人们提出了一种稍微弱化但比较方便的形式。
- 当满足KKT条件的 $\lambda^*$ 是唯一的(比如LICQ), 并且严格互补性条件成立, 此时关键锥的定义可以简化为:

$$\mathcal{C}(x^*, \lambda^*) = \text{Null}[\nabla c_i(x^*)^T]_{i \in \mathcal{A}(x^*)} = \text{Null}A(x^*) = \{Zu \mid u \in \mathbb{R}^{|\mathcal{A}(x^*)|}\}$$

这里 $Z$ 表示 $A(x^*)$ 的零空间的基组成的矩阵,  $|\mathcal{A}(x^*)|$ 表示活跃约束的个数。

- 可以判定 $Z^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) Z$ 的半正定性或正定性。
- 如何得到 $Z$ ? 对 $A(x^*)$ 进行QR分解即可:

$$A(x^*)^T = [Q_1, Q_2] \begin{bmatrix} R \\ 0 \end{bmatrix} = Q_1 R$$

如果 $R$ 非奇异, 则 $Z = Q_2$ 。如果 $R$ 奇异(LICQ不成立)时, 可以对QR分解做适当的列交换来确定 $Z$ 。

## 其他形式的约束限制

约束限制，**本质上**是对可行区域 $\Omega$ 而言，其线性化代数表示，能否准确地抓住 $x^*$ 邻域内的几何形状。

## 其他形式的约束限制

约束限制，**本质上**是对可行区域 $\Omega$ 而言，其线性化代数表示，能否准确地抓住 $x^*$ 邻域内的几何形状。所以当活跃的约束都是线性函数即 $c_i(x) = a_i^T x + b_i$ ，显然是满足条件的。

## 其他形式的约束限制

约束限制，**本质上**是对可行区域 $\Omega$ 而言，其线性化代数表示，能否准确地抓住 $x^*$ 邻域内的几何形状。所以当活跃的约束都是线性函数即 $c_i(x) = a_i^T x + b_i$ ，显然是满足条件的。

引理：假设 $x^* \in \Omega$ 处的活跃约束条件 $c_i(x^*), i \in \mathcal{A}(x^*)$ 都是线性函数，则有 $\mathcal{F}(x^*) = T_\Omega(x^*)$ 。

证明：首先 $T_\Omega \subset \mathcal{F}(x^*)$ 。我们只需要证明 $\mathcal{F}(x^*) \subset T_\Omega(x^*)$ 。

## 其他形式的约束限制

约束限制，**本质上**是对可行区域 $\Omega$ 而言，其线性化代数表示，能否准确地抓住 $x^*$ 邻域内的几何形状。所以当活跃的约束都是线性函数即 $c_i(x) = a_i^T x + b_i$ ，显然是满足条件的。

引理：假设 $x^* \in \Omega$ 处的活跃约束条件 $c_i(x^*), i \in \mathcal{A}(x^*)$ 都是线性函数，则有 $\mathcal{F}(x^*) = T_\Omega(x^*)$ 。

证明：首先 $T_\Omega \subset \mathcal{F}(x^*)$ 。我们只需要证明 $\mathcal{F}(x^*) \subset T_\Omega(x^*)$ 。即要证明 $\forall d \in \mathcal{F}(x^*), d \in T_\Omega(x^*)$ ，

## 其他形式的约束限制

约束限制，**本质上**是对可行区域 $\Omega$ 而言，其线性化代数表示，能否准确地抓住 $x^*$ 邻域内的几何形状。所以当活跃的约束都是线性函数即 $c_i(x) = a_i^T x + b_i$ ，显然是满足条件的。

引理：假设 $x^* \in \Omega$ 处的活跃约束条件 $c_i(x^*)$ ,  $i \in \mathcal{A}(x^*)$ 都是线性函数，则有 $\mathcal{F}(x^*) = T_\Omega(x^*)$ 。

证明：首先 $T_\Omega \subset \mathcal{F}(x^*)$ 。我们只需要证明 $\mathcal{F}(x^*) \subset T_\Omega(x^*)$ 。即要证明 $\forall d \in \mathcal{F}(x^*)$ ,  $d \in T_\Omega(x^*)$ ，也就是要证明对于 $d$ ，存在一个序列 $z_k \in \Omega$ ，满足 $\lim_{t_k \rightarrow 0^+} \frac{z_k - x^*}{t_k} = d$ 。

$$\mathcal{F}(x^*) = \left\{ d \mid \begin{array}{l} a_i^T d = 0, \quad \forall i \in \mathcal{E}, \\ a_i^T d \geq 0, \quad \forall i \in \mathcal{A}(x^*) \cap \mathcal{J} \end{array} \right\}.$$

- 首先 $i \in \mathcal{J} \setminus \mathcal{A}(x^*)$ (即不活跃)，则存在 $\bar{t}$ ，使得 $x^* + td$ 也不活跃，即 $c_i(x^* + tw) > 0$ ,  $t \in [0, \bar{t}]$ 。
- 构造序列 $z_k = x^* + (\bar{t}/k)d$ ，**可以分三种约束**分别验证 $z_k \in \Omega$ 。满足 $d \in T_\Omega(x^*)$

## 其他形式的约束限制

定义Mangasarian-Fromovitz约束限制(MFCQ):

如果存在 $w$ 使得

$$\begin{aligned}\nabla c_i(x^*)w &= 0, & \forall i \in \mathcal{E} \\ \nabla c_i(x^*)^T w &> 0, & \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}.\end{aligned}$$

并且等式约束的梯度 $\nabla c_i(x^*)$ ,  $i \in \mathcal{E}$ 都是线性无关的。

## 其他形式的约束限制

定义Mangasarian-Fromovitz约束限制(MFCQ):

如果存在 $w$ 使得

$$\begin{aligned}\nabla c_i(x^*)w &= 0, & \forall i \in \mathcal{E} \\ \nabla c_i(x^*)^T w &> 0, & \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}.\end{aligned}$$

并且等式约束的梯度 $\nabla c_i(x^*)$ ,  $i \in \mathcal{E}$ 都是线性无关的。

- 上面的不等式限制是严格的。



## 其他形式的约束限制

定义Mangasarian-Fromovitz约束限制(MFCQ):

如果存在 $w$ 使得

$$\begin{aligned}\nabla c_i(x^*)w &= 0, & \forall i \in \mathcal{E} \\ \nabla c_i(x^*)^T w &> 0, & \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}.\end{aligned}$$

并且等式约束的梯度 $\nabla c_i(x^*)$ ,  $i \in \mathcal{E}$ 都是线性无关的。

- 上面的不等式限制是严格的。
- MFCQ比LICQ条件弱。

## 其他形式的约束限制

定义Mangasarian-Fromovitz约束限制(MFCQ):

如果存在 $w$ 使得

$$\begin{aligned}\nabla c_i(x^*)w &= 0, & \forall i \in \mathcal{E} \\ \nabla c_i(x^*)^T w &> 0, & \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}.\end{aligned}$$

并且等式约束的梯度 $\nabla c_i(x^*)$ ,  $i \in \mathcal{E}$ 都是线性无关的。

- 上面的不等式限制是严格的。
- MFCQ比LICQ条件弱。
- 不管是MFCQ还是LICQ, 都只是 $\mathcal{F}(x^*) = T_{\Omega}(x^*)$ 的充分条件, 而不是必要条件。

## 其他形式的约束限制

定义Mangasarian-Fromovitz约束限制(MFCQ):

如果存在 $w$ 使得

$$\begin{aligned}\nabla c_i(x^*)w &= 0, & \forall i \in \mathcal{E} \\ \nabla c_i(x^*)^T w &> 0, & \forall i \in \mathcal{A}(x^*) \cap \mathcal{J}.\end{aligned}$$

并且等式约束的梯度 $\nabla c_i(x^*)$ ,  $i \in \mathcal{E}$ 都是线性无关的。

- 上面的不等式限制是严格的。
- MFCQ比LICQ条件弱。
- 不管是MFCQ还是LICQ, 都只是 $\mathcal{F}(x^*) = T_{\Omega}(x^*)$ 的充分条件, 而不是必要条件。反例

$$x_1^2 + x_2 \geq 0, \quad x_1^2 - x_2 \geq 0$$

在 $x^* = (0, 0)^T$ 处, 约束限制都不成立, 但是其线性化方向集

$$\mathcal{F}(x^*) = \{(w_1, 0) | w_1 \in \mathbb{R}\}$$

确实准确地反映了 $x^*$ 附近可行域的几何性质。

# 其他形式的一阶必要性条件

## 定义法向锥(Normal Cone)

如果  $x \in \Omega$ , 称  $N_{\Omega}(x) = \{v | v^T w \leq 0 \text{ 对于任意的 } w \in T_{\Omega}(x)\}$  为法向锥

## 定理

假设  $x^*$  是  $f$  在  $\Omega$  内的一个局部最优解, 则

$$-\nabla f(x^*) \in N_{\Omega}(x^*).$$

# 主问题和对偶问题(Primal and Dual Problem)

## 主问题

$$\min_{x \in \mathcal{R}^n} f(x), \quad s.t. \quad c(x) \geq 0$$

其中  $c(x) = (c_1(x), \dots, c_m(x))^T$ ,  $f(x)$  和  $-c_i(x)$  都是凸函数。

# 主问题和对偶问题(Primal and Dual Problem)

## 主问题

$$\min_{x \in \mathcal{R}^n} f(x), \quad s.t. \quad c(x) \geq 0$$

其中  $c(x) = (c_1(x), \dots, c_m(x))^T$ ,  $f(x)$  和  $-c_i(x)$  都是凸函数。

定义其拉格朗日函数为

$$\mathcal{L}(x, \lambda) = f(x) - \lambda^T c(x)$$

# 主问题和对偶问题(Primal and Dual Problem)

## 主问题

$$\min_{x \in \mathcal{R}^n} f(x), \quad s.t. \quad c(x) \geq 0$$

其中  $c(x) = (c_1(x), \dots, c_m(x))^T$ ,  $f(x)$  和  $-c_i(x)$  都是凸函数。

定义其拉格朗日函数为

$$\mathcal{L}(x, \lambda) = f(x) - \lambda^T c(x)$$

再定义对偶问题的目标函数：

$$q(\lambda) \equiv \inf_x \mathcal{L}(x, \lambda)$$

# 主问题和对偶问题(Primal and Dual Problem)

## 主问题

$$\min_{x \in \mathcal{R}^n} f(x), \quad s.t. \quad c(x) \geq 0$$

其中  $c(x) = (c_1(x), \dots, c_m(x))^T$ ,  $f(x)$  和  $-c_i(x)$  都是凸函数。

定义其拉格朗日函数为

$$\mathcal{L}(x, \lambda) = f(x) - \lambda^T c(x)$$

再定义对偶问题的目标函数：

$$q(\lambda) \equiv \inf_x \mathcal{L}(x, \lambda)$$

通常情况下，对于某些  $\lambda$  该最小值可能是  $-\infty$ 。我们定义  $\lambda$  的可行区域为



# 主问题和对偶问题(Primal and Dual Problem)

## 主问题

$$\min_{x \in \mathcal{R}^n} f(x), \quad s.t. \quad c(x) \geq 0$$

其中  $c(x) = (c_1(x), \dots, c_m(x))^T$ ,  $f(x)$  和  $-c_i(x)$  都是凸函数。

定义其拉格朗日函数为

$$\mathcal{L}(x, \lambda) = f(x) - \lambda^T c(x)$$

再定义对偶问题的目标函数：

$$q(\lambda) \equiv \inf_x \mathcal{L}(x, \lambda)$$

通常情况下，对于某些  $\lambda$  该最小值可能是  $-\infty$ 。我们定义  $\lambda$  的可行区域为

$$\mathcal{D} \equiv \{\lambda \mid q(\lambda) > -\infty\}$$

# 主问题和对偶问题(Primal and Dual Problem)

## 主问题

$$\min_{x \in \mathcal{R}^n} f(x), \quad s.t. \quad c(x) \geq 0$$

其中  $c(x) = (c_1(x), \dots, c_m(x))^T$ ,  $f(x)$  和  $-c_i(x)$  都是凸函数。

定义其拉格朗日函数为

$$\mathcal{L}(x, \lambda) = f(x) - \lambda^T c(x)$$

再定义对偶问题的目标函数：

$$q(\lambda) \equiv \inf_x \mathcal{L}(x, \lambda)$$

通常情况下，对于某些  $\lambda$  该最小值可能是  $-\infty$ 。我们定义  $\lambda$  的可行区域为

$$\mathcal{D} \equiv \{\lambda \mid q(\lambda) > -\infty\}$$

## 对偶问题

$$\max_{\lambda \in \mathcal{R}^m} q(\lambda), \quad s.t. \quad \lambda \geq 0$$

# 弱对偶性

定理：对偶问题的目标函数 $q(\lambda)$ 以及它的区域 $\mathcal{D}$ 都是凸的。

# 弱对偶性

定理：对偶问题的目标函数 $q(\lambda)$ 以及它的区域 $\mathcal{D}$ 都是凸的。

证明：

$$\begin{aligned}\mathcal{L}(x, (1-\alpha)\lambda^0 + \alpha\lambda^1) &= (1-\alpha)\mathcal{L}(x, \lambda^0) + \alpha\mathcal{L}(x, \lambda^1), \quad \forall \lambda^0, \lambda^1 \in \mathcal{R}^m, \alpha \in [0, 1] \\ q(x, (1-\alpha)\lambda^0 + \alpha\lambda^1) &\geq (1-\alpha)q(x, \lambda^0) + \alpha q(x, \lambda^1).\end{aligned}$$

定理：对于任意的 $\bar{x}$ ，如果是满足主问题的解，和任意的 $\bar{\lambda} \geq 0$ ，都有 $q(\bar{\lambda}) \leq f(\bar{x})$

# 弱对偶性

定理：对偶问题的目标函数 $q(\lambda)$ 以及它的区域 $\mathcal{D}$ 都是凸的。

证明：

$$\begin{aligned}\mathcal{L}(x, (1-\alpha)\lambda^0 + \alpha\lambda^1) &= (1-\alpha)\mathcal{L}(x, \lambda^0) + \alpha\mathcal{L}(x, \lambda^1), \quad \forall \lambda^0, \lambda^1 \in \mathcal{R}^m, \alpha \in [0, 1] \\ q(x, (1-\alpha)\lambda^0 + \alpha\lambda^1) &\geq (1-\alpha)q(x, \lambda^0) + \alpha q(x, \lambda^1).\end{aligned}$$

定理：对于任意的 $\bar{x}$ ，如果是满足主问题的解，和任意的 $\bar{\lambda} \geq 0$ ，都有 $q(\bar{\lambda}) \leq f(\bar{x})$

证明：

$$q(\bar{\lambda}) = \inf_x f(x) - \bar{\lambda}^T c(x) \leq f(\bar{x}) - \bar{\lambda}^T c(\bar{x}) \leq f(\bar{x}).$$

# 主问题和对偶问题的关联性

定理：如果 $\bar{x}$ 是主问题的一个解，而且 $f$ 和 $-c_i(x)$ 都是凸可微函数，那么对于任意满足KKT条件的 $\bar{\lambda}$ 都是其对偶问题的解

# 主问题和对偶问题的关联性

定理：如果 $\bar{x}$ 是主问题的一个解，而且 $f$ 和 $-c_i(x)$ 都是凸可微函数，那么对于任意满足KKT条件的 $\bar{\lambda}$ 都是其对偶问题的解

证明：假设 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，则有

$$\nabla_x \mathcal{L}(\bar{x}, \bar{\lambda}) = 0, \quad c(\bar{x}) \geq 0, \quad \bar{\lambda} \geq 0, \quad \bar{\lambda}^T c(\bar{x}) = 0.$$

# 主问题和对偶问题的关联性

定理：如果 $\bar{x}$ 是主问题的一个解，而且 $f$ 和 $-c_i(x)$ 都是凸可微函数，那么对于任意满足KKT条件的 $\bar{\lambda}$ 都是其对偶问题的解

证明：假设 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，则有

$$\nabla_x \mathcal{L}(\bar{x}, \bar{\lambda}) = 0, \quad c(\bar{x}) \geq 0, \quad \bar{\lambda} \geq 0, \quad \bar{\lambda}^T c(\bar{x}) = 0.$$

根据 $\mathcal{L}(\cdot, \bar{\lambda})$ 是凸可微函数，即对任意的 $x$ ，

$$\mathcal{L}(x, \bar{\lambda}) \geq \mathcal{L}(\bar{x}, \bar{\lambda}) + \nabla_x \mathcal{L}(\bar{x}, \bar{\lambda})^T (x - \bar{x}) = \mathcal{L}(\bar{x}, \bar{\lambda}).$$



# 主问题和对偶问题的关联性

定理：如果 $\bar{x}$ 是主问题的一个解，而且 $f$ 和 $-c_i(x)$ 都是凸可微函数，那么对于任意满足KKT条件的 $\bar{\lambda}$ 都是其对偶问题的解

证明：假设 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，则有

$$\nabla_x \mathcal{L}(\bar{x}, \bar{\lambda}) = 0, \quad c(\bar{x}) \geq 0, \quad \bar{\lambda} \geq 0, \quad \bar{\lambda}^T c(\bar{x}) = 0.$$

根据 $\mathcal{L}(\cdot, \bar{\lambda})$ 是凸可微函数，即对任意的 $x$ ，

$$\mathcal{L}(x, \bar{\lambda}) \geq \mathcal{L}(\bar{x}, \bar{\lambda}) + \nabla_x \mathcal{L}(\bar{x}, \bar{\lambda})^T (x - \bar{x}) = \mathcal{L}(\bar{x}, \bar{\lambda}).$$

因此

$$q(\bar{\lambda}) = \inf_x \mathcal{L}(x, \bar{\lambda}) = \mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x}) - \bar{\lambda}^T c(\bar{x}) = f(\bar{x})$$

由于 $q(\bar{\lambda}) \leq f(\bar{x}), \forall \lambda \geq 0$ ,

# 主问题和对偶问题的关联性

定理：如果 $\bar{x}$ 是主问题的一个解，而且 $f$ 和 $-c_i(x)$ 都是凸可微函数，那么对于任意满足KKT条件的 $\bar{\lambda}$ 都是其对偶问题的解

证明：假设 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，则有

$$\nabla_x \mathcal{L}(\bar{x}, \bar{\lambda}) = 0, \quad c(\bar{x}) \geq 0, \quad \bar{\lambda} \geq 0, \quad \bar{\lambda}^T c(\bar{x}) = 0.$$

根据 $\mathcal{L}(\cdot, \bar{\lambda})$ 是凸可微函数，即对任意的 $x$ ，

$$\mathcal{L}(x, \bar{\lambda}) \geq \mathcal{L}(\bar{x}, \bar{\lambda}) + \nabla_x \mathcal{L}(\bar{x}, \bar{\lambda})^T (x - \bar{x}) = \mathcal{L}(\bar{x}, \bar{\lambda}).$$

因此

$$q(\bar{\lambda}) = \inf_x \mathcal{L}(x, \bar{\lambda}) = \mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x}) - \bar{\lambda}^T c(\bar{x}) = f(\bar{x})$$

由于 $q(\bar{\lambda}) \leq f(\bar{x})$ ,  $\forall \lambda \geq 0$ ，我们可以立即得到 $q(\bar{\lambda}) = f(\bar{x})$ ，

# 主问题和对偶问题的关联性

定理：如果 $\bar{x}$ 是主问题的一个解，而且 $f$ 和 $-c_i(x)$ 都是凸可微函数，那么对于任意满足KKT条件的 $\bar{\lambda}$ 都是其对偶问题的解

证明：假设 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，则有

$$\nabla_x \mathcal{L}(\bar{x}, \bar{\lambda}) = 0, \quad c(\bar{x}) \geq 0, \quad \bar{\lambda} \geq 0, \quad \bar{\lambda}^T c(\bar{x}) = 0.$$

根据 $\mathcal{L}(\cdot, \bar{\lambda})$ 是凸可微函数，即对任意的 $x$ ，

$$\mathcal{L}(x, \bar{\lambda}) \geq \mathcal{L}(\bar{x}, \bar{\lambda}) + \nabla_x \mathcal{L}(\bar{x}, \bar{\lambda})^T (x - \bar{x}) = \mathcal{L}(\bar{x}, \bar{\lambda}).$$

因此

$$q(\bar{\lambda}) = \inf_x \mathcal{L}(x, \bar{\lambda}) = \mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x}) - \bar{\lambda}^T c(\bar{x}) = f(\bar{x})$$

由于 $q(\bar{\lambda}) \leq f(\bar{x})$ ,  $\forall \lambda \geq 0$ ，我们可以立即得到 $q(\bar{\lambda}) = f(\bar{x})$ ，所以 $\bar{\lambda}$ 是对偶问题的一个解。

# 主问题和对偶问题的关联性

定理：如果 $f$ 和 $-c_i$ 都是凸可微，而且 $\bar{x}$ 是主问题的一个解，并且满足LICQ。假设 $\hat{\lambda}$ 是对偶问题的一个解， $\mathcal{L}(\cdot, \hat{\lambda})$ 是严格凸函数，并且在 $\hat{x}$ 处取到 $\inf_x \mathcal{L}(x, \hat{\lambda})$ 的极小值。那么 $\hat{x} = \bar{x}$

# 主问题和对偶问题的关联性

定理：如果  $f$  和  $-c_i$  都是凸可微，而且  $\bar{x}$  是主问题的一个解，并且满足LICQ。假设  $\hat{\lambda}$  是对偶问题的一个解， $\mathcal{L}(\cdot, \hat{\lambda})$  是严格凸函数，并且在  $\hat{x}$  处取到  $\inf_x \mathcal{L}(x, \hat{\lambda})$  的极小值。那么  $\hat{x} = \bar{x}$

- 如果  $\bar{x} \neq \hat{x}$ ，那么根据  $\bar{x}$  处满足LICQ，则一定至少存在一个  $\bar{\lambda}$ ，使得  $(\bar{x}, \bar{\lambda})$  是原主问题的解。

# 主问题和对偶问题的关联性

定理：如果  $f$  和  $-c_i$  都是凸可微，而且  $\bar{x}$  是主问题的一个解，并且满足 LICQ。假设  $\bar{\lambda}$  是对偶问题的一个解， $\mathcal{L}(\cdot, \bar{\lambda})$  是严格凸函数，并且在  $\hat{x}$  处取到  $\inf_x \mathcal{L}(x, \bar{\lambda})$  的极小值。那么  $\hat{x} = \bar{x}$

- 如果  $\bar{x} \neq \hat{x}$ ，那么根据  $\bar{x}$  处满足 LICQ，则一定至少存在一个  $\bar{\lambda}$ ，使得  $(\bar{x}, \bar{\lambda})$  是原主问题的解。
- 再根据上面的定理，可以得到  $\bar{\lambda}$  是对偶问题的解，即  $\mathcal{L}(\bar{x}, \bar{\lambda}) = q(\bar{\lambda})$ 。

# 主问题和对偶问题的关联性

定理：如果 $f$ 和 $-c_i$ 都是凸可微，而且 $\bar{x}$ 是主问题的一个解，并且满足LICQ。假设 $\hat{\lambda}$ 是对偶问题的一个解， $\mathcal{L}(\cdot, \hat{\lambda})$ 是严格凸函数，并且在 $\hat{x}$ 处取到 $\inf_x \mathcal{L}(x, \hat{\lambda})$ 的极小值。那么 $\hat{x} = \bar{x}$

- 如果 $\bar{x} \neq \hat{x}$ ，那么根据 $\bar{x}$ 处满足LICQ，则一定至少存在一个 $\bar{\lambda}$ ，使得 $(\bar{x}, \bar{\lambda})$ 是原主问题的解。
- 再根据上面的定理，可以得到 $\bar{\lambda}$ 是对偶问题的解，即 $\mathcal{L}(\bar{x}, \bar{\lambda}) = q(\bar{\lambda})$ 。
- 由题意， $q(\hat{\lambda})$ 也取到最小值，所以 $q(\bar{\lambda}) = q(\hat{\lambda}) = \mathcal{L}(\hat{x}, \hat{\lambda})$ 。

# 主问题和对偶问题的关联性

定理：如果  $f$  和  $-c_i$  都是凸可微，而且  $\bar{x}$  是主问题的一个解，并且满足LICQ。假设  $\hat{\lambda}$  是对偶问题的一个解， $\mathcal{L}(\cdot, \hat{\lambda})$  是严格凸函数，并且在  $\hat{x}$  处取到  $\inf_x \mathcal{L}(x, \hat{\lambda})$  的极小值。那么  $\hat{x} = \bar{x}$

- 如果  $\bar{x} \neq \hat{x}$ ，那么根据  $\bar{x}$  处满足LICQ，则一定至少存在一个  $\bar{\lambda}$ ，使得  $(\bar{x}, \bar{\lambda})$  是原主问题的解。
- 再根据上面的定理，可以得到  $\bar{\lambda}$  是对偶问题的解，即  $\mathcal{L}(\bar{x}, \bar{\lambda}) = q(\bar{\lambda})$ 。
- 由题意， $q(\hat{\lambda})$  也取到最小值，所以  $q(\bar{\lambda}) = q(\hat{\lambda}) = \mathcal{L}(\hat{x}, \hat{\lambda})$ 。
- 由于  $\hat{x} = \arg \min_x \mathcal{L}(x, \hat{\lambda})$ ,



# 主问题和对偶问题的关联性

定理：如果 $f$ 和 $-c_i$ 都是凸可微，而且 $\bar{x}$ 是主问题的一个解，并且满足LICQ。假设 $\hat{\lambda}$ 是对偶问题的一个解， $\mathcal{L}(\cdot, \hat{\lambda})$ 是严格凸函数，并且在 $\hat{x}$ 处取到 $\inf_x \mathcal{L}(x, \hat{\lambda})$ 的极小值。那么 $\hat{x} = \bar{x}$

- 如果 $\bar{x} \neq \hat{x}$ ，那么根据 $\bar{x}$ 处满足LICQ，则一定至少存在一个 $\bar{\lambda}$ ，使得 $(\bar{x}, \bar{\lambda})$ 是原主问题的解。
- 再根据上面的定理，可以得到 $\bar{\lambda}$ 是对偶问题的解，即 $\mathcal{L}(\bar{x}, \bar{\lambda}) = q(\bar{\lambda})$ 。
- 由题意， $q(\hat{\lambda})$ 也取到最小值，所以 $q(\bar{\lambda}) = q(\hat{\lambda}) = \mathcal{L}(\hat{x}, \hat{\lambda})$ 。
- 由于 $\hat{x} = \arg \min_x \mathcal{L}(x, \hat{\lambda})$ ，根据一阶最优性条件可以得到 $\nabla_x \mathcal{L}(\hat{x}, \hat{\lambda}) = 0$ 。

# 主问题和对偶问题的关联性

定理：如果 $f$ 和 $-c_i$ 都是凸可微，而且 $\bar{x}$ 是主问题的一个解，并且满足LICQ。假设 $\hat{\lambda}$ 是对偶问题的一个解， $\mathcal{L}(\cdot, \hat{\lambda})$ 是严格凸函数，并且在 $\hat{x}$ 处取到 $\inf_x \mathcal{L}(x, \hat{\lambda})$ 的极小值。那么 $\hat{x} = \bar{x}$

- 如果 $\bar{x} \neq \hat{x}$ ，那么根据 $\bar{x}$ 处满足LICQ，则一定至少存在一个 $\bar{\lambda}$ ，使得 $(\bar{x}, \bar{\lambda})$ 是原主问题的解。
- 再根据上面的定理，可以得到 $\bar{\lambda}$ 是对偶问题的解，即 $\mathcal{L}(\bar{x}, \bar{\lambda}) = q(\bar{\lambda})$ 。
- 由题意， $q(\hat{\lambda})$ 也取到最小值，所以 $q(\bar{\lambda}) = q(\hat{\lambda}) = \mathcal{L}(\hat{x}, \hat{\lambda})$ 。
- 由于 $\hat{x} = \arg \min_x \mathcal{L}(x, \hat{\lambda})$ ，根据一阶最优性条件可以得到 $\nabla_x \mathcal{L}(\hat{x}, \hat{\lambda}) = 0$ 。
- 再根据 $\mathcal{L}(\cdot, \hat{\lambda})$ 的严格凸性，可以得到

$$\mathcal{L}(\bar{x}, \hat{\lambda}) - \mathcal{L}(\hat{x}, \hat{\lambda}) > \nabla_x \mathcal{L}(\hat{x}, \hat{\lambda})^T (\bar{x} - \hat{x}) = 0$$

# 主问题和对偶问题的关联性

定理：如果 $f$ 和 $-c_i$ 都是凸可微，而且 $\bar{x}$ 是主问题的一个解，并且满足LICQ。假设 $\hat{\lambda}$ 是对偶问题的一个解， $\mathcal{L}(\cdot, \hat{\lambda})$ 是严格凸函数，并且在 $\hat{x}$ 处取到 $\inf_x \mathcal{L}(x, \hat{\lambda})$ 的极小值。那么 $\hat{x} = \bar{x}$

- 如果 $\bar{x} \neq \hat{x}$ ，那么根据 $\bar{x}$ 处满足LICQ，则一定至少存在一个 $\bar{\lambda}$ ，使得 $(\bar{x}, \bar{\lambda})$ 是原主问题的解。
- 再根据上面的定理，可以得到 $\bar{\lambda}$ 是对偶问题的解，即 $\mathcal{L}(\bar{x}, \bar{\lambda}) = q(\bar{\lambda})$ 。
- 由题意， $q(\hat{\lambda})$ 也取到最小值，所以 $q(\bar{\lambda}) = q(\hat{\lambda}) = \mathcal{L}(\hat{x}, \hat{\lambda})$ 。
- 由于 $\hat{x} = \arg \min_x \mathcal{L}(x, \hat{\lambda})$ ，根据一阶最优性条件可以得到 $\nabla_x \mathcal{L}(\hat{x}, \hat{\lambda}) = 0$ 。
- 再根据 $\mathcal{L}(\cdot, \hat{\lambda})$ 的严格凸性，可以得到

$$\mathcal{L}(\bar{x}, \hat{\lambda}) - \mathcal{L}(\hat{x}, \hat{\lambda}) > \nabla_x \mathcal{L}(\hat{x}, \hat{\lambda})^T (\bar{x} - \hat{x}) = 0$$

- 所以，我们得到  $\mathcal{L}(\bar{x}, \hat{\lambda}) > \mathcal{L}(\hat{x}, \hat{\lambda}) = \mathcal{L}(\bar{x}, \bar{\lambda})$ 。

# 主问题和对偶问题的关联性

定理：如果  $f$  和  $-c_i$  都是凸可微，而且  $\bar{x}$  是主问题的一个解，并且满足LICQ。假设  $\hat{\lambda}$  是对偶问题的一个解， $\mathcal{L}(\cdot, \hat{\lambda})$  是严格凸函数，并且在  $\hat{x}$  处取到  $\inf_x \mathcal{L}(x, \hat{\lambda})$  的极小值。那么  $\hat{x} = \bar{x}$

- 如果  $\bar{x} \neq \hat{x}$ ，那么根据  $\bar{x}$  处满足LICQ，则一定至少存在一个  $\bar{\lambda}$ ，使得  $(\bar{x}, \bar{\lambda})$  是原主问题的解。
- 再根据上面的定理，可以得到  $\bar{\lambda}$  是对偶问题的解，即  $\mathcal{L}(\bar{x}, \bar{\lambda}) = q(\bar{\lambda})$ 。
- 由题意， $q(\hat{\lambda})$  也取到最小值，所以  $q(\bar{\lambda}) = q(\hat{\lambda}) = \mathcal{L}(\hat{x}, \hat{\lambda})$ 。
- 由于  $\hat{x} = \arg \min_x \mathcal{L}(x, \hat{\lambda})$ ，根据一阶最优性条件可以得到  $\nabla_x \mathcal{L}(\hat{x}, \hat{\lambda}) = 0$ 。
- 再根据  $\mathcal{L}(\cdot, \hat{\lambda})$  的严格凸性，可以得到

$$\mathcal{L}(\bar{x}, \hat{\lambda}) - \mathcal{L}(\hat{x}, \hat{\lambda}) > \nabla_x \mathcal{L}(\hat{x}, \hat{\lambda})^T (\bar{x} - \hat{x}) = 0$$

- 所以，我们得到  $\mathcal{L}(\bar{x}, \hat{\lambda}) > \mathcal{L}(\hat{x}, \hat{\lambda}) = \mathcal{L}(\bar{x}, \bar{\lambda})$ 。
- 特别地，我们有  $-\hat{\lambda}^T c(\bar{x}) > -\bar{x}c(\bar{x}) = 0$ ，这里最后的不等式显然是矛盾。

# Wolfe对偶

为了计算简便，对偶问题有一个更简洁的形式：

# Wolfe对偶

为了计算简便，对偶问题有一个更简洁的形式：

## Wolfe Dual

$$\begin{aligned} \max_{x, \lambda} \quad & \mathcal{L}(x, \lambda) \\ \text{s.t.} \quad & \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0. \end{aligned}$$

# Wolfe对偶

为了计算简便，对偶问题有一个更简洁的形式：

## Wolfe Dual

$$\begin{aligned} \max_{x, \lambda} \quad & \mathcal{L}(x, \lambda) \\ \text{s.t.} \quad & \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0. \end{aligned}$$

定理：如果 $f$ 和 $-c_i$ 是凸可微的。 $(\bar{x}, \bar{\lambda})$ 是主问题的一组解，并且满足LICQ。那么 $(\bar{x}, \bar{\lambda})$ 也是Wolfe对偶问题的一组解。

# Wolfe对偶

为了计算简便，对偶问题有一个更简洁的形式：

## Wolfe Dual

$$\begin{aligned} \max_{x, \lambda} \quad & \mathcal{L}(x, \lambda) \\ \text{s.t.} \quad & \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0. \end{aligned}$$

定理：如果 $f$ 和 $-c_i$ 是凸可微的。 $(\bar{x}, \bar{\lambda})$ 是主问题的一组解，并且满足LICQ。那么 $(\bar{x}, \bar{\lambda})$ 也是Wolfe对偶问题的一组解。

证明：

- 由于 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，显然也满足Wolfe对偶问题的约束条件，



# Wolfe对偶

为了计算简便，对偶问题有一个更简洁的形式：

## Wolfe Dual

$$\begin{aligned} \max_{x, \lambda} \quad & \mathcal{L}(x, \lambda) \\ \text{s.t.} \quad & \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0. \end{aligned}$$

定理：如果 $f$ 和 $-c_i$ 是凸可微的。 $(\bar{x}, \bar{\lambda})$ 是主问题的一组解，并且满足LICQ。那么 $(\bar{x}, \bar{\lambda})$ 也是Wolfe对偶问题的一组解。

证明：

- 由于 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，显然也满足Wolfe对偶问题的约束条件，并且 $\mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x})$ .

# Wolfe对偶

为了计算简便，对偶问题有一个更简洁的形式：

## Wolfe Dual

$$\begin{aligned} \max_{x, \lambda} \quad & \mathcal{L}(x, \lambda) \\ \text{s.t.} \quad & \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0. \end{aligned}$$

定理：如果 $f$ 和 $-c_i$ 是凸可微的。 $(\bar{x}, \bar{\lambda})$ 是主问题的一组解，并且满足LICQ。那么 $(\bar{x}, \bar{\lambda})$ 也是Wolfe对偶问题的一组解。

证明：

- 由于 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，显然也满足Wolfe对偶问题的约束条件，并且 $\mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x})$ 。
- 再验证Wolfe对偶问题的第一个条件。对于任意的 $(x, \lambda)$ ,

# Wolfe对偶

为了计算简便，对偶问题有一个更简洁的形式：

## Wolfe Dual

$$\begin{aligned} \max_{x, \lambda} \quad & \mathcal{L}(x, \lambda) \\ \text{s.t.} \quad & \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0. \end{aligned}$$

定理：如果 $f$ 和 $-c_i$ 是凸可微的。 $(\bar{x}, \bar{\lambda})$ 是主问题的一组解，并且满足LICQ。那么 $(\bar{x}, \bar{\lambda})$ 也是Wolfe对偶问题的一组解。

证明：

- 由于 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，显然也满足Wolfe对偶问题的约束条件，并且 $\mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x})$ 。
- 再验证Wolfe对偶问题的第一个条件。对于任意的 $(x, \lambda)$ ,

$$\begin{aligned} \mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x}) &\geq f(\bar{x}) - \lambda^T c(\bar{x}) = \mathcal{L}(\bar{x}, \lambda) \\ &\geq \mathcal{L}(x, \lambda) + \nabla_x \mathcal{L}(x, \lambda)(\bar{x} - x) = \mathcal{L}(x, \lambda) \end{aligned}$$

# Wolfe对偶

为了计算简便，对偶问题有一个更简洁的形式：

## Wolfe Dual

$$\begin{aligned} \max_{x, \lambda} \quad & \mathcal{L}(x, \lambda) \\ \text{s.t.} \quad & \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0. \end{aligned}$$

定理：如果 $f$ 和 $-c_i$ 是凸可微的。 $(\bar{x}, \bar{\lambda})$ 是主问题的一组解，并且满足LICQ。那么 $(\bar{x}, \bar{\lambda})$ 也是Wolfe对偶问题的一组解。

证明：

- 由于 $(\bar{x}, \bar{\lambda})$ 满足KKT条件，显然也满足Wolfe对偶问题的约束条件，并且 $\mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x})$ 。
- 再验证Wolfe对偶问题的第一个条件。对于任意的 $(x, \lambda)$ ,

$$\begin{aligned} \mathcal{L}(\bar{x}, \bar{\lambda}) = f(\bar{x}) &\geq f(\bar{x}) - \lambda^T c(\bar{x}) = \mathcal{L}(\bar{x}, \lambda) \\ &\geq \mathcal{L}(x, \lambda) + \nabla_x \mathcal{L}(x, \lambda)(\bar{x} - x) = \mathcal{L}(x, \lambda) \end{aligned}$$

- 这样 $(\bar{x}, \bar{\lambda})$ 就是Wolfe对偶问题的一个极大值解。

# 对偶问题的例子

线性规划例子

# 对偶问题的例子

线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

# 对偶问题的例子

线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

## 对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$



# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$

如果  $(c - A^T \lambda) \neq 0$ , 极小值可以取到  $-\infty$ 。

# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$

如果  $(c - A^T \lambda) \neq 0$ , 极小值可以取到  $-\infty$ 。如果  $c - A^T \lambda = 0$ , 则目标函数就是  $b^T \lambda$ 。

# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$

如果  $(c - A^T \lambda) \neq 0$ , 极小值可以取到  $-\infty$ 。如果  $c - A^T \lambda = 0$ , 则目标函数就是  $b^T \lambda$ 。后面要对  $q(\lambda)$  取极大值, 所以我们可以排除掉  $c - A^T \lambda \neq 0$  的情形。

# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$

如果  $(c - A^T \lambda) \neq 0$ , 极小值可以取到  $-\infty$ 。如果  $c - A^T \lambda = 0$ , 则目标函数就是  $b^T \lambda$ 。后面要对  $q(\lambda)$  取极大值, 所以我们可以排除掉  $c - A^T \lambda \neq 0$  的情形。因此, 我们可以直接写出对偶问题:

# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$

如果  $(c - A^T \lambda) \neq 0$ , 极小值可以取到  $-\infty$ 。如果  $c - A^T \lambda = 0$ , 则目标函数就是  $b^T \lambda$ 。后面要对  $q(\lambda)$  取极大值, 所以我们可以排除掉  $c - A^T \lambda \neq 0$  的情形。因此, 我们可以直接写出对偶问题:

$$\max_{\lambda} b^T \lambda \quad \text{subject to } A^T \lambda = c, \lambda \geq 0.$$

# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$

如果  $(c - A^T \lambda) \neq 0$ , 极小值可以取到  $-\infty$ 。如果  $c - A^T \lambda = 0$ , 则目标函数就是  $b^T \lambda$ 。后面要对  $q(\lambda)$  取极大值, 所以我们可以排除掉  $c - A^T \lambda \neq 0$  的情形。因此, 我们可以直接写出对偶问题:

$$\max_{\lambda} b^T \lambda \quad \text{subject to } A^T \lambda = c, \lambda \geq 0.$$

Wolfe对偶问题可以写为:

# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$

如果  $(c - A^T \lambda) \neq 0$ , 极小值可以取到  $-\infty$ 。如果  $c - A^T \lambda = 0$ , 则目标函数就是  $b^T \lambda$ 。后面要对  $q(\lambda)$  取极大值, 所以我们可以排除掉  $c - A^T \lambda \neq 0$  的情形。因此, 我们可以直接写出对偶问题:

$$\max_{\lambda} b^T \lambda \quad \text{subject to } A^T \lambda = c, \lambda \geq 0.$$

Wolfe对偶问题可以写为:

$$\max_{\lambda} c^T x - \lambda^T (Ax - b) \quad \text{subject to } A^T \lambda = c, \lambda \geq 0$$

# 对偶问题的例子

## 线性规划例子

$$\min c^T x \quad \text{subject to } Ax - b \geq 0,$$

对应的对偶目标函数

$$q(\lambda) = \inf_x [c^T x - \lambda^T (Ax - b)] = \inf_x [(c - A^T \lambda)^T x + b^T \lambda]$$

如果  $(c - A^T \lambda) \neq 0$ , 极小值可以取到  $-\infty$ 。如果  $c - A^T \lambda = 0$ , 则目标函数就是  $b^T \lambda$ 。后面要对  $q(\lambda)$  取极大值, 所以我们可以排除掉  $c - A^T \lambda \neq 0$  的情形。因此, 我们可以直接写出对偶问题:

$$\max_{\lambda} b^T \lambda \quad \text{subject to } A^T \lambda = c, \lambda \geq 0.$$

Wolfe对偶问题可以写为:

$$\max_{\lambda} c^T x - \lambda^T (Ax - b) \quad \text{subject to } A^T \lambda = c, \lambda \geq 0$$



# 对偶问题的例子

## 二次凸规划例子

$$\min \frac{1}{2} x^T G x + c^T x \quad \text{subject to } Ax - b \geq 0, \quad G \text{ 对称正定.}$$

# 对偶问题的例子

## 二次凸规划例子

$$\min \frac{1}{2}x^T Gx + c^T x \quad \text{subject to } Ax - b \geq 0, \quad G \text{ 对称正定}.$$

$$\text{对偶目标函数: } q(\lambda) = \inf_x \mathcal{L}(x, \lambda) = \inf_x \left[ \frac{1}{2}x^T Gx + c^T x - \lambda^T (Ax - b) \right].$$

# 对偶问题的例子

## 二次凸规划例子

$$\min \frac{1}{2} x^T G x + c^T x \quad \text{subject to } Ax - b \geq 0, \quad G \text{ 对称正定}.$$

$$\text{对偶目标函数: } q(\lambda) = \inf_x \mathcal{L}(x, \lambda) = \inf_x \left[ \frac{1}{2} x^T G x + c^T x - \lambda^T (Ax - b) \right].$$

因为  $G$  是正定的, 所以  $\mathcal{L}(\cdot, \lambda)$  是严格凸函数, 取到最小值的条件是  $\nabla_x \mathcal{L}(x, \lambda) = 0$ , 即  $Gx + c - A^T \lambda = 0$ .

# 对偶问题的例子

## 二次凸规划例子

$$\min \frac{1}{2} x^T G x + c^T x \quad \text{subject to } Ax - b \geq 0, \quad G \text{ 对称正定}.$$

$$\text{对偶目标函数: } q(\lambda) = \inf_x \mathcal{L}(x, \lambda) = \inf_x \left[ \frac{1}{2} x^T G x + c^T x - \lambda^T (Ax - b) \right].$$

因为 $G$ 是正定的, 所以 $\mathcal{L}(\cdot, \lambda)$ 是严格凸函数, 取到最小值的条件是 $\nabla_x \mathcal{L}(x, \lambda) = 0$ , 即  $Gx + c - A^T \lambda = 0$ . 从上式可以求出 $x = G^{-1}(A^T \lambda - c)$ , 然后代入 $q(\lambda)$ 中得到对偶问题的目标函数:

$$q(\lambda) = -0.5(A^T \lambda - c)^T G^{-1}(A^T \lambda - c)^T + b^T \lambda$$

# 对偶问题的例子

## 二次凸规划例子

$$\min \frac{1}{2}x^T Gx + c^T x \quad \text{subject to } Ax - b \geq 0, \quad G \text{ 对称正定.}$$

$$\text{对偶目标函数: } q(\lambda) = \inf_x \mathcal{L}(x, \lambda) = \inf_x \left[ \frac{1}{2}x^T Gx + c^T x - \lambda^T (Ax - b) \right].$$

因为 $G$ 是正定的, 所以 $\mathcal{L}(\cdot, \lambda)$ 是严格凸函数, 取到最小值的条件是 $\nabla_x \mathcal{L}(x, \lambda) = 0$ , 即  $Gx + c - A^T \lambda = 0$ . 从上式可以求出 $x = G^{-1}(A^T \lambda - c)$ , 然后代入 $q(\lambda)$ 中得到对偶问题的目标函数:

$$q(\lambda) = -0.5(A^T \lambda - c)^T G^{-1}(A^T \lambda - c)^T + b^T \lambda$$

或者, 我们可以写出相应的Wolfe对偶问题:

$$\max_{(\lambda, x)} 0.5x^T Gx + c^T x - \lambda^T (Ax - b), \quad \text{s.t. } Gx + c - A^T \lambda = 0, \lambda \geq 0.$$

# 对偶问题的例子

## 二次凸规划例子

$$\min \frac{1}{2}x^T Gx + c^T x \quad \text{subject to } Ax - b \geq 0, \quad G \text{ 对称正定.}$$

$$\text{对偶目标函数: } q(\lambda) = \inf_x \mathcal{L}(x, \lambda) = \inf_x \left[ \frac{1}{2}x^T Gx + c^T x - \lambda^T (Ax - b) \right].$$

因为 $G$ 是正定的, 所以 $\mathcal{L}(\cdot, \lambda)$ 是严格凸函数, 取到最小值的条件是 $\nabla_x \mathcal{L}(x, \lambda) = 0$ , 即  $Gx + c - A^T \lambda = 0$ . 从上式可以求出 $x = G^{-1}(A^T \lambda - c)$ , 然后代入 $q(\lambda)$ 中得到对偶问题的目标函数:

$$q(\lambda) = -0.5(A^T \lambda - c)^T G^{-1}(A^T \lambda - c)^T + b^T \lambda$$

或者, 我们可以写出相应的Wolfe对偶问题:

$$\max_{(\lambda, x)} 0.5x^T Gx + c^T x - \lambda^T (Ax - b), \quad \text{s.t. } Gx + c - A^T \lambda = 0, \lambda \geq 0.$$

当然如果我们利用约束条件 $(c - A^T \lambda)^T x = -x^T Gx$ , 可以重新写成对偶问题

$$\max_{(\lambda, x)} -0.5x^T Gx + \lambda^T b, \quad \text{s.t. } Gx + c - A^T \lambda = 0, \lambda \geq 0.$$

THANKS FOR YOUR ATTENTION