

PRACTICAL OPTIMIZATION ALGORITHMS

徐 翔

数学科学学院
浙江大学

JUNE 7, 2022

第十二讲：罚函数和增广拉格朗日法 (PENALTY AND AUGMENTED LAGRANGIAN METHODS)

简介(INTRODUCTION)

OUTLINE

- 在求解约束优化问题时，很多方法都是把约束条件加入到目标函数中。

OUTLINE

- 在求解约束优化问题时，很多方法都是把约束条件加入到目标函数中。
- 三种方式：二次罚函数(quadratic penalty)
非光滑精确罚函数 (nonsmooth exact penalty)
增广拉格朗日法或者乘子法
(augmented Lagrangian method or method of multiplier)

OUTLINE

- 在求解约束优化问题时，很多方法都是把约束条件加入到目标函数中。
- 三种方式：二次罚函数(quadratic penalty)
非光滑精确罚函数 (nonsmooth exact penalty)
增广拉格朗日法或者乘子法
(augmented Lagrangian method or method of multiplier)
- 简单介绍log-barrier method, 用log项阻止迭代过程靠近边界，是非线性规划内点法的基础。

二次罚函数(QUADRATIC PENALTY): MOTIVATION

首先考虑等式约束问题

二次罚函数(QUADRATIC PENALTY): MOTIVATION

首先考虑等式约束问题

- 一般形式

$$\min_x f(x) \quad \text{subject to } c_i(x) = 0, i \in \mathcal{E}$$

二次罚函数(QUADRATIC PENALTY): MOTIVATION

首先考虑等式约束问题

- 一般形式

$$\min_x f(x) \quad \text{subject to } c_i(x) = 0, i \in \mathcal{E}$$

- 相应的二次罚函数形式为

$$Q(x; \mu) = f(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x),$$

其中 $\mu > 0$ 是惩罚参数(penalty parameter).

二次罚函数(QUADRATIC PENALTY): MOTIVATION

首先考虑等式约束问题

- 一般形式

$$\min_x f(x) \quad \text{subject to } c_i(x) = 0, i \in \mathcal{E}$$

- 相应的二次罚函数形式为

$$Q(x; \mu) = f(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x),$$

其中 $\mu > 0$ 是惩罚参数(penalty parameter).

- 当 $\mu \rightarrow \infty$, 我们逐渐提高对违反约束条件的惩罚。

二次罚函数(QUADRATIC PENALTY): MOTIVATION

首先考虑等式约束问题

- 一般形式

$$\min_x f(x) \quad \text{subject to } c_i(x) = 0, i \in \mathcal{E}$$

- 相应的二次罚函数形式为

$$Q(x; \mu) = f(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x),$$

其中 $\mu > 0$ 是惩罚参数(penalty parameter).

- 当 $\mu \rightarrow \infty$, 我们逐渐提高对违反约束条件的惩罚。
- 因此直观地, 我们可以考虑 $\mu_k \rightarrow \infty$, 求解 $Q(x; \mu_k)$ 得到 x_k 。

二次罚函数(QUADRATIC PENALTY): MOTIVATION

首先考虑等式约束问题

- 一般形式

$$\min_x f(x) \quad \text{subject to } c_i(x) = 0, i \in \mathcal{E}$$

- 相应的二次罚函数形式为

$$Q(x; \mu) = f(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x),$$

其中 $\mu > 0$ 是惩罚参数(penalty parameter).

- 当 $\mu \rightarrow \infty$, 我们逐渐提高对违反约束条件的惩罚。
- 因此直观地, 我们可以考虑 $\mu_k \rightarrow \infty$, 求解 $Q(x; \mu_k)$ 得到 x_k 。
- 我们可以使用无约束优化问题的方法求解 $Q(x; \mu_k)$. 而且可以把 x_{k-1} 当成很好的初值。选择好的 $\{\mu_k\}$ 序列以及好的初值, 可以使得在每次迭代中只需要很小的计算量。

二次罚函数(QUADRATIC PENALTY): MOTIVATION

例1: $\min x_1 + x_2$ subject to $x_1^2 + x_2^2 - 2 = 0$.

二次罚函数(QUADRATIC PENALTY): MOTIVATION

例1: $\min x_1 + x_2$ subject to $x_1^2 + x_2^2 - 2 = 0$.

精确解是 $(-1, -1)^T$, 对应的二次罚函数是


$$Q(x; \mu) = x_1 + x_2 + \frac{\mu}{2}(x_1^2 + x_2^2 - 2)^2.$$

二次罚函数(QUADRATIC PENALTY): MOTIVATION

例1: $\min x_1 + x_2$ subject to $x_1^2 + x_2^2 - 2 = 0$.

精确解是 $(-1, -1)^T$, 对应的二次罚函数是

$$Q(x; \mu) = x_1 + x_2 + \frac{\mu}{2}(x_1^2 + x_2^2 - 2)^2.$$





二次罚函数(QUADRATIC PENALTY): MOTIVATION

例1: $\min x_1 + x_2$ subject to $x_1^2 + x_2^2 - 2 = 0$.

精确解是 $(-1, -1)^T$, 对应的二次罚函数是

$$Q(x; \mu) = x_1 + x_2 + \frac{\mu}{2}(x_1^2 + x_2^2 - 2)^2.$$





二次罚函数(QUADRATIC PENALTY): MOTIVATION

例1: $\min x_1 + x_2$ subject to $x_1^2 + x_2^2 - 2 = 0$.

精确解是 $(-1, -1)^T$, 对应的二次罚函数是

$$Q(x; \mu) = x_1 + x_2 + \frac{\mu}{2}(x_1^2 + x_2^2 - 2)^2.$$





- 在左图中, 有一个局部极小值 $(-1.1, -1.1)^T$,

二次罚函数(QUADRATIC PENALTY): MOTIVATION

例1: $\min x_1 + x_2$ subject to $x_1^2 + x_2^2 - 2 = 0$.

精确解是 $(-1, -1)^T$, 对应的二次罚函数是

$$Q(x; \mu) = x_1 + x_2 + \frac{\mu}{2}(x_1^2 + x_2^2 - 2)^2.$$





- 在左图中, 有一个局部极小值 $(-1.1, -1.1)^T$,
- 在右图中, 局部极小值更靠近 $(-1, -1)^T$.

二次罚函数(QUADRATIC PENALTY): MOTIVATION

例1: $\min x_1 + x_2$ subject to $x_1^2 + x_2^2 - 2 = 0$.

精确解是 $(-1, -1)^T$, 对应的二次罚函数是

$$Q(x; \mu) = x_1 + x_2 + \frac{\mu}{2}(x_1^2 + x_2^2 - 2)^2.$$



- 在左图中, 有一个局部极小值 $(-1.1, -1.1)^T$,
- 在右图中, 局部极小值更靠近 $(-1, -1)^T$.

不是所有问题都像这个例子这么好, 例如



$$\min -5x_1^2 + x_2^2 \quad \text{subject to } x_1 = 1$$

二次罚函数(QUADRATIC PENALTY): MOTIVATION

例1: $\min x_1 + x_2$ subject to $x_1^2 + x_2^2 - 2 = 0$.

精确解是 $(-1, -1)^T$, 对应的二次罚函数是

$$Q(x; \mu) = x_1 + x_2 + \frac{\mu}{2}(x_1^2 + x_2^2 - 2)^2.$$



- 在左图中, 有一个局部极小值 $(-1.1, -1.1)^T$,
- 在右图中, 局部极小值更靠近 $(-1, -1)^T$.

不是所有问题都像这个例子这么好, 例如

$$\min -5x_1^2 + x_2^2 \quad \text{subject to } x_1 = 1$$

解是 $(1, 0)$, 但是当 $\mu < 10$ 时, 罚函数都是无界的。因此对 $\mu < 10$ 时, 算法都是发散的。这种缺陷是广泛存在的。

二次罚函数: ALGORITHMIC FRAMEWORK

二次罚函数: ALGORITHMIC FRAMEWORK

- 对于一般的约束优化问题

$$\min_x \quad \text{subject to } c_i(x) = 0, i \in \mathcal{E}, c_i(x) \geq 0 i \in \mathcal{I}.$$

二次罚函数: ALGORITHMIC FRAMEWORK

- 对于一般的约束优化问题

$$\min_x \quad \text{subject to } c_i(x) = 0, \ i \in \mathcal{E}, \ c_i(x) \geq 0 \ i \in \mathcal{I}.$$

- 定义相关的二次罚函数

$$Q(x; \mu) = f(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i(x)^2 + \frac{\mu}{2} \sum_{i \in \mathcal{I}} ([c_i(x)]^-)^2$$

这里 $[y]^- = \max(-y, 0)$.

二次罚函数: ALGORITHMIC FRAMEWORK

- 对于一般的约束优化问题

$$\min_x \quad \text{subject to } c_i(x) = 0, i \in \mathcal{E}, c_i(x) \geq 0 i \in \mathcal{I}.$$

- 定义相关的二次罚函数

$$Q(x; \mu) = f(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i(x)^2 + \frac{\mu}{2} \sum_{i \in \mathcal{I}} ([c_i(x)]^-)^2$$

这里 $[y]^- = \max(-y, 0)$.

- Q 可能没有目标函数光滑, 有可能不能二阶可导。

二次罚函数: ALGORITHMIC FRAMEWORK

ALGORITHM 1: 二次罚函数算法

给定 $\mu_0 > 0$, 非负的 $\tau_k \rightarrow 0$ 以及一个初始点 x_0^s ;
for $k = 0, 1, 2, \dots$
 寻找 $Q(\cdot; \mu_k)$ 的近似解 x_k , 使得 $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$;
 if 满足了收敛性测试
 stop $x^* \approx x_k$;
 end(if)
 选择一个新的惩罚参数 $\mu_{k+1} > \mu_k$;
 选择一个新的初始值 x_{k+1}^s ;
end(for)

二次罚函数: ALGORITHMIC FRAMEWORK

ALGORITHM 1: 二次罚函数算法

```

给定  $\mu_0 > 0$ , 非负的  $\tau_k \rightarrow 0$  以及一个初始点  $x_0^s$ ;
for  $k = 0, 1, 2, \dots$ 
    寻找  $Q(\cdot; \mu_k)$  的近似解  $x_k$ , 使得  $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$ ;
    if 满足了收敛性测试
        stop  $x^* \approx x_k$ ;
    end(if)
    选择一个新的惩罚参数  $\mu_{k+1} > \mu_k$ ;
    选择一个新的初始值  $x_{k+1}^s$ ;
end(for)
  
```

- $\{\mu_k\}$ 可以根据罚函数求解的困难程度自适应地选择。

二次罚函数: ALGORITHMIC FRAMEWORK

ALGORITHM 1: 二次罚函数算法

给定 $\mu_0 > 0$, 非负的 $\tau_k \rightarrow 0$ 以及一个初始点 x_0^s ;
for $k = 0, 1, 2, \dots$
 寻找 $Q(\cdot; \mu_k)$ 的近似解 x_k , 使得 $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$;
 if 满足了收敛性测试
 stop $x^* \approx x_k$;
 end(if)
 选择一个新的惩罚参数 $\mu_{k+1} > \mu_k$;
 选择一个新的初始值 x_{k+1}^s ;
end(for)

- $\{\mu_k\}$ 可以根据罚函数求解的困难程度自适应地选择。如果对 μ_k 求解比较困难, 那么可以选个小一点的 $\mu_{k+1} = 1.5\mu_k$,

二次罚函数: ALGORITHMIC FRAMEWORK

ALGORITHM 1: 二次罚函数算法

```

给定  $\mu_0 > 0$ , 非负的  $\tau_k \rightarrow 0$  以及一个初始点  $x_0^s$ ;
for  $k = 0, 1, 2, \dots$ 
    寻找  $Q(\cdot; \mu_k)$  的近似解  $x_k$ , 使得  $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$ ;
    if 满足了收敛性测试
        stop  $x^* \approx x_k$ ;
    end(if)
    选择一个新的惩罚参数  $\mu_{k+1} > \mu_k$ ;
    选择一个新的初始值  $x_{k+1}^s$ ;
end(for)

```

- $\{\mu_k\}$ 可以根据罚函数求解的困难程度自适应地选择。如果对 μ_k 求解比较困难, 那么可以选个小一点的 $\mu_{k+1} = 1.5\mu_k$, 如果比较容易求解, 那么可以选个比较激进的 $\mu_{k+1} = 10\mu_k$ 。

二次罚函数: ALGORITHMIC FRAMEWORK

ALGORITHM 1: 二次罚函数算法

```

给定  $\mu_0 > 0$ , 非负的  $\tau_k \rightarrow 0$  以及一个初始点  $x_0^s$ ;
for  $k = 0, 1, 2, \dots$ 
    寻找  $Q(\cdot; \mu_k)$  的近似解  $x_k$ , 使得  $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$ ;
    if 满足了收敛性测试
        stop  $x^* \approx x_k$ ;
    end(if)
    选择一个新的惩罚参数  $\mu_{k+1} > \mu_k$ ;
    选择一个新的初始值  $x_{k+1}^s$ ;
end(for)
  
```

- $\{\mu_k\}$ 可以根据罚函数求解的困难程度自适应地选择。如果对 μ_k 求解比较困难, 那么可以选个小一点的 $\mu_{k+1} = 1.5\mu_k$, 如果比较容易求解, 那么可以选个比较激进的 $\mu_{k+1} = 10\mu_k$ 。
- τ_k 的选取只要求 $\tau_k \rightarrow 0$, 就可以保证在迭代过程中越来越逼近精确解。

二次罚函数: ALGORITHMIC FRAMEWORK

ALGORITHM 1: 二次罚函数算法

```

给定  $\mu_0 > 0$ , 非负的  $\tau_k \rightarrow 0$  以及一个初始点  $x_0^s$ ;
for  $k = 0, 1, 2, \dots$ 
    寻找  $Q(\cdot; \mu_k)$  的近似解  $x_k$ , 使得  $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$ ;
    if 满足了收敛性测试
        stop  $x^* \approx x_k$ ;
    end(if)
    选择一个新的惩罚参数  $\mu_{k+1} > \mu_k$ ;
    选择一个新的初始值  $x_{k+1}^s$ ;
end(for)
  
```

- $\{\mu_k\}$ 可以根据罚函数求解的困难程度自适应地选择。如果对 μ_k 求解比较困难, 那么可以选个小一点的 $\mu_{k+1} = 1.5\mu_k$, 如果比较容易求解, 那么可以选个比较激进的 $\mu_{k+1} = 10\mu_k$ 。
- τ_k 的选取只要求 $\tau_k \rightarrow 0$, 就可以保证在迭代过程中越来越逼近精确解。
- 当 μ_k 比较小的时候, 迭代的解可能会远离可行域, $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$ 停止测试不一定能够满足。

二次罚函数: ALGORITHMIC FRAMEWORK

ALGORITHM 1: 二次罚函数算法

```

给定  $\mu_0 > 0$ , 非负的  $\tau_k \rightarrow 0$  以及一个初始点  $x_0^s$ ;
for  $k = 0, 1, 2, \dots$ 
    寻找  $Q(\cdot; \mu_k)$  的近似解  $x_k$ , 使得  $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$ ;
    if 满足了收敛性测试
        stop  $x^* \approx x_k$ ;
    end(if)
    选择一个新的惩罚参数  $\mu_{k+1} > \mu_k$ ;
    选择一个新的初始值  $x_{k+1}^s$ ;
end(for)
  
```

- $\{\mu_k\}$ 可以根据罚函数求解的困难程度自适应地选择。如果对 μ_k 求解比较困难, 那么可以选个小一点的 $\mu_{k+1} = 1.5\mu_k$, 如果比较容易求解, 那么可以选个比较激进的 $\mu_{k+1} = 10\mu_k$ 。
- τ_k 的选取只要求 $\tau_k \rightarrow 0$, 就可以保证在迭代过程中越来越逼近精确解。
- 当 μ_k 比较小的时候, 迭代的解可能会远离可行域, $\|\nabla_x Q(\cdot; \mu_k)\| \leq \tau_k$ 停止测试不一定能够满足。一个常用的策略是, 当发现违反约束下降不够快, 或者迭代不收敛时, 需要加大 μ_k 。

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。
- 当 μ_k 变大时, 优化过程会越来越困难, 除非我们有好的技巧计算搜索方向。

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。
- 当 μ_k 变大时, 优化过程会越来越困难, 除非我们有好的技巧计算搜索方向。
- 原因之一是当 $x \rightarrow x_k$ 时, $\nabla_{xx}^2 Q(x; \mu_k)$ 的条件数会变的很大。

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。
- 当 μ_k 变大时, 优化过程会越来越困难, 除非我们有好的技巧计算搜索方向。
- 原因之一是当 $x \rightarrow x_k$ 时, $\nabla_{xx}^2 Q(x; \mu_k)$ 的条件数会变的很大。
- 这个性质会使得拟牛顿法、共轭梯度法失效。

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。
- 当 μ_k 变大时, 优化过程会越来越困难, 除非我们有好的技巧计算搜索方向。
- 原因之一是当 $x \rightarrow x_k$ 时, $\nabla_{xx}^2 Q(x; \mu_k)$ 的条件数会变的很大。
- 这个性质会使得拟牛顿法、共轭梯度法失效。虽然牛顿法本身不受坏条件数的影响, 但是当 μ_k 很大时, 也会遇到另外的困难

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。
- 当 μ_k 变大时, 优化过程会越来越困难, 除非我们有好的技巧计算搜索方向。
- 原因之一是当 $x \rightarrow x_k$ 时, $\nabla_{xx}^2 Q(x; \mu_k)$ 的条件数会变的很大。
- 这个性质会使得拟牛顿法、共轭梯度法失效。虽然牛顿法本身不受坏条件数的影响, 但是当 μ_k 很大时, 也会遇到另外的困难
 - 首先, 坏条件数可能会影响求解牛顿步,

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。
- 当 μ_k 变大时, 优化过程会越来越困难, 除非我们有好的技巧计算搜索方向。
- 原因之一是当 $x \rightarrow x_k$ 时, $\nabla_{xx}^2 Q(x; \mu_k)$ 的条件数会变的很大。
- 这个性质会使得拟牛顿法、共轭梯度法失效。虽然牛顿法本身不受坏条件数的影响, 但是当 μ_k 很大时, 也会遇到另外的困难
 - 首先, 坏条件数可能会影响求解牛顿步, 但这个不是致命的, 可以通过转化牛顿方程克服。

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。
- 当 μ_k 变大时, 优化过程会越来越困难, 除非我们有好的技巧计算搜索方向。
- 原因之一是当 $x \rightarrow x_k$ 时, $\nabla_{xx}^2 Q(x; \mu_k)$ 的条件数会变的很大。
- 这个性质会使得拟牛顿法、共轭梯度法失效。虽然牛顿法本身不受坏条件数的影响, 但是当 μ_k 很大时, 也会遇到另外的困难
 - 首先, 坏条件数可能会影响求解牛顿步, 但这个不是致命的, 可以通过转化牛顿方程克服。
 - 当 x 接近 $Q(x; \mu_k)$ 的极小值时, 其等高线围的区域是香蕉形状而不是椭圆形状。但是牛顿法最适用的局部展开区域是椭圆区域, 这说明可能牛顿法可能收敛会变慢。

二次罚函数: ALGORITHMIC FRAMEWORK

- 当只有等式约束时, $Q(x; \mu_k)$ 是光滑的, 无约束优化问题的算法都可以使用。
- 当 μ_k 变大时, 优化过程会越来越困难, 除非我们有好的技巧计算搜索方向。
- 原因之一是当 $x \rightarrow x_k$ 时, $\nabla_{xx}^2 Q(x; \mu_k)$ 的条件数会变的很大。
- 这个性质会使得拟牛顿法、共轭梯度法失效。虽然牛顿法本身不受坏条件数的影响, 但是当 μ_k 很大时, 也会遇到另外的困难
 - 首先, 坏条件数可能会影响求解牛顿步, 但这个不是致命的, 可以通过转化牛顿方程克服。
 - 当 x 接近 $Q(x; \mu_k)$ 的极小值时, 其等高线围的区域是香蕉形状而不是椭圆形状。但是牛顿法最适用的局部展开区域是椭圆区域, 这说明可能牛顿法可能收敛会变慢。这个一般可以通过选择好的初始值来克服, 比如可以选取 $x_{k+1}^s = x_k$ 并且 μ_{k+1} 只比 μ_k 大一些。

二次罚函数: CONVERGENCE ANALYSIS

假设 $Q(x, \mu_k)$ 仅有有限个极小子。首先我们看只有等式约束的情形

二次罚函数: CONVERGENCE ANALYSIS

假设 $Q(x, \mu_k)$ 仅有有限个极小子。首先我们看只有等式约束的情形

定理1: (精确求解 $Q(x; \mu_k)$)

假设 x_k 是 $Q(x; \mu_k)$ 的精确的全局极小子, 且 $\mu_k \rightarrow \infty$ 。则 $\{x_k\}$ 的每个极限点 x^* 是原极小化问题的全局解。

二次罚函数: CONVERGENCE ANALYSIS

假设 $Q(x, \mu_k)$ 仅有有限个极小子。首先我们看只有等式约束的情形

定理1: (精确求解 $Q(x; \mu_k)$)

假设 x_k 是 $Q(x; \mu_k)$ 的精确的全局极小子, 且 $\mu_k \rightarrow \infty$ 。则 $\{x_k\}$ 的每个极限点 x^* 是原极小化问题的全局解。

证明:

- 假设 \bar{x} 是原问题的全局解, 则 $f(\bar{x}) \leq f(x)$, 对于任意可行域内的点 $c_i(x) = 0, i \in \mathcal{E}$.

二次罚函数: CONVERGENCE ANALYSIS

假设 $Q(x, \mu_k)$ 仅有有限个极小子。首先我们看只有等式约束的情形

定理1: (精确求解 $Q(x; \mu_k)$)

假设 x_k 是 $Q(x; \mu_k)$ 的精确的全局极小子, 且 $\mu_k \rightarrow \infty$ 。则 $\{x_k\}$ 的每个极限点 x^* 是原极小化问题的全局解。

证明:

- 假设 \bar{x} 是原问题的全局解, 则 $f(\bar{x}) \leq f(x)$, 对于任意可行域内的点 $c_i(x) = 0, i \in \mathcal{E}$.
- 由于 x_k 是每个子问题 $Q(x; \mu_k)$ 的全局极小解, 我们有 $Q(x_k; \mu_k) \leq Q(\bar{x}; \mu_k)$, 即

二次罚函数: CONVERGENCE ANALYSIS

假设 $Q(x, \mu_k)$ 仅有有限个极小子。首先我们看只有等式约束的情形

定理1: (精确求解 $Q(x; \mu_k)$)

假设 x_k 是 $Q(x; \mu_k)$ 的精确的全局极小子, 且 $\mu_k \rightarrow \infty$ 。则 $\{x_k\}$ 的每个极限点 x^* 是原极小化问题的全局解。

证明:

- 假设 \bar{x} 是原问题的全局解, 则 $f(\bar{x}) \leq f(x)$, 对于任意可行域内的点 $c_i(x) = 0, i \in \mathcal{E}$.
- 由于 x_k 是每个子问题 $Q(x; \mu_k)$ 的全局极小解, 我们有 $Q(x_k; \mu_k) \leq Q(\bar{x}; \mu_k)$, 即

$$f(x_k) + \frac{\mu_k}{2} \sum_{i \in \mathcal{E}} c_i^2(x_k) \leq f(\bar{x}) + \frac{\mu_k}{2} \sum_{i \in \mathcal{E}} c_i^2(\bar{x}) = f(\bar{x})$$

二次罚函数: CONVERGENCE ANALYSIS

假设 $Q(x, \mu_k)$ 仅有有限个极小子。首先我们看只有等式约束的情形

定理1: (精确求解 $Q(x; \mu_k)$)

假设 x_k 是 $Q(x; \mu_k)$ 的精确的全局极小子, 且 $\mu_k \rightarrow \infty$ 。则 $\{x_k\}$ 的每个极限点 x^* 是原极小化问题的全局解。

证明:

- 假设 \bar{x} 是原问题的全局解, 则 $f(\bar{x}) \leq f(x)$, 对于任意可行域内的点 $c_i(x) = 0, i \in \mathcal{E}$.
- 由于 x_k 是每个子问题 $Q(x; \mu_k)$ 的全局极小解, 我们有 $Q(x_k; \mu_k) \leq Q(\bar{x}; \mu_k)$, 即

$$f(x_k) + \frac{\mu_k}{2} \sum_{i \in \mathcal{E}} c_i^2(x_k) \leq f(\bar{x}) + \frac{\mu_k}{2} \sum_{i \in \mathcal{E}} c_i^2(\bar{x}) = f(\bar{x})$$

- 进而可以得到

$$\sum_{i \in \mathcal{E}} c_i^2(x_k) \leq \frac{2}{\mu_k} [f(\bar{x}) - f(x_k)].$$

二次罚函数: CONVERGENCE ANALYSIS

二次罚函数: CONVERGENCE ANALYSIS

- 假设 $\{x_k\}$ 有一个极限点 x^* , 即存在一个无限子列 \mathcal{K} , 有 $\lim_{k \in \mathcal{K}} x_k = x^*$

二次罚函数: CONVERGENCE ANALYSIS

- 假设 $\{x_k\}$ 有一个极限点 x^* , 即存在一个无限子列 \mathcal{K} , 有 $\lim_{k \in \mathcal{K}} x_k = x^*$
- 对上式两边取极限 $k \in \mathcal{K}$, 得到

$$\sum_{i \in \mathcal{E}} c_i^2(x^*) = \lim_{k \in \mathcal{K}} \sum_{i \in \mathcal{E}} c_i^2(x_k) \leq \lim_{k \in \mathcal{K}} \frac{2}{\mu_k} [f(\bar{x}) - f(x_k)] = 0.$$

二次罚函数: CONVERGENCE ANALYSIS

- 假设 $\{x_k\}$ 有一个极限点 x^* , 即存在一个无限子列 \mathcal{K} , 有 $\lim_{k \in \mathcal{K}} x_k = x^*$
- 对上式两边取极限 $k \in \mathcal{K}$, 得到

$$\sum_{i \in \mathcal{E}} c_i^2(x^*) = \lim_{k \in \mathcal{K}} \sum_{i \in \mathcal{E}} c_i^2(x_k) \leq \lim_{k \in \mathcal{K}} \frac{2}{\mu_k} [f(\bar{x}) - f(x_k)] = 0.$$

即 $c_i(x^*) = 0$, x^* 落在可行域内。

二次罚函数: CONVERGENCE ANALYSIS

- 假设 $\{x_k\}$ 有一个极限点 x^* , 即存在一个无限子列 \mathcal{K} , 有 $\lim_{k \in \mathcal{K}} x_k = x^*$
- 对上式两边取极限 $k \in \mathcal{K}$, 得到

$$\sum_{i \in \mathcal{E}} c_i^2(x^*) = \lim_{k \in \mathcal{K}} \sum_{i \in \mathcal{E}} c_i^2(x_k) \leq \lim_{k \in \mathcal{K}} \frac{2}{\mu_k} [f(\bar{x}) - f(x_k)] = 0.$$

即 $c_i(x^*) = 0$, x^* 落在可行域内。

- 再对

$$f(x_k) \leq Q(x, \mu_k) \leq Q(\bar{x}, \mu_k) = f(\bar{x})$$

两边同时取极限可以得到 $f(x^*) \leq f(\bar{x})$ 。

二次罚函数: CONVERGENCE ANALYSIS

- 假设 $\{x_k\}$ 有一个极限点 x^* ，即存在一个无限子列 \mathcal{K} ，有 $\lim_{k \in \mathcal{K}} x_k = x^*$
- 对上式两边取极限 $k \in \mathcal{K}$ ，得到

$$\sum_{i \in \mathcal{E}} c_i^2(x^*) = \lim_{k \in \mathcal{K}} \sum_{i \in \mathcal{E}} c_i^2(x_k) \leq \lim_{k \in \mathcal{K}} \frac{2}{\mu_k} [f(\bar{x}) - f(x_k)] = 0.$$

即 $c_i(x^*) = 0$ ， x^* 落在可行域内。

- 再对

$$f(x_k) \leq Q(x, \mu_k) \leq Q(\bar{x}, \mu_k) = f(\bar{x})$$

两边同时取极限可以得到 $f(x^*) \leq f(\bar{x})$ 。

- 由于假设 \bar{x} 是全局极小子，可以得到 x^* 也是一个全局极小子。

二次罚函数: CONVERGENCE ANALYSIS

定理2:(不精确求解 $Q(x; \mu_k)$)

假设在ALGORITHM 1中满足 $\tau_k \rightarrow 0$, $\mu_k \uparrow \infty$. $\{x_k\}$ 的一个极限点 x^* .

二次罚函数: CONVERGENCE ANALYSIS

定理2:(不精确求解 $Q(x; \mu_k)$)

假设在ALGORITHM 1中满足 $\tau_k \rightarrow 0$, $\mu_k \uparrow \infty$ 。 $\{x_k\}$ 的一个极限点 x^* 。

- ① 如果 x^* 是不可行点, 则 x^* 是 $\|c(x)\|^2$ 的一个稳定点。

二次罚函数: CONVERGENCE ANALYSIS

定理2:(不精确求解 $Q(x; \mu_k)$)

假设在ALGORITHM 1中满足 $\tau_k \rightarrow 0$, $\mu_k \uparrow \infty$ 。 $\{x_k\}$ 的一个极限点 x^* 。

- ① 如果 x^* 是不可行点, 则 x^* 是 $\|c(x)\|^2$ 的一个稳定点。
- ② 如果 x^* 是可行点, 并且 $\nabla c_i(x^*)$ 是线性无关的, 则 x^* 是一个KKT点。对于这种点 x^* , 我们有对于任意的子集序列 \mathcal{K} , $\lim_{k \in \mathcal{K}} x_k = x^*$, 则

$$\lim_{k \in \mathcal{K}} -\mu_k c_i(x_k) = \lambda_i^*, \text{ for all } i \in \mathcal{E},$$

这里 λ^* 是那些满足KKT条件中的等式约束乘子向量。

二次罚函数: CONVERGENCE ANALYSIS

定理2:(不精确求解 $Q(x; \mu_k)$)

假设在ALGORITHM 1中满足 $\tau_k \rightarrow 0$, $\mu_k \uparrow \infty$ 。 $\{x_k\}$ 的一个极限点 x^* 。

- ① 如果 x^* 是不可行点, 则 x^* 是 $\|c(x)\|^2$ 的一个稳定点。
- ② 如果 x^* 是可行点, 并且 $\nabla c_i(x^*)$ 是线性无关的, 则 x^* 是一个KKT点。对于这种点 x^* , 我们有对于任意的子集序列 \mathcal{K} , $\lim_{k \in \mathcal{K}} x_k = x^*$, 则

$$\lim_{k \in \mathcal{K}} -\mu_k c_i(x_k) = \lambda_i^*, \text{ for all } i \in \mathcal{E},$$

这里 λ^* 是那些满足KKT条件中的等式约束乘子向量。

Proof

二次罚函数: CONVERGENCE ANALYSIS

定理2:(不精确求解 $Q(x; \mu_k)$)

假设在ALGORITHM 1中满足 $\tau_k \rightarrow 0$, $\mu_k \uparrow \infty$ 。 $\{x_k\}$ 的一个极限点 x^* 。

- ① 如果 x^* 是不可行点, 则 x^* 是 $\|c(x)\|^2$ 的一个稳定点。
- ② 如果 x^* 是可行点, 并且 $\nabla c_i(x^*)$ 是线性无关的, 则 x^* 是一个KKT点。对于这种点 x^* , 我们有对于任意的子集序列 \mathcal{K} , $\lim_{k \in \mathcal{K}} x_k = x^*$, 则

$$\lim_{k \in \mathcal{K}} -\mu_k c_i(x_k) = \lambda_i^*, \text{ for all } i \in \mathcal{E},$$

这里 λ^* 是那些满足KKT条件中的等式约束乘子向量。

Proof

- 首先对 $Q(x; \mu_k)$ 求导可得:

$$\nabla_x Q(x_k; \mu_k) = \nabla f(x_k) + \sum_{i \in \mathcal{E}} \mu_k c_i(x_k) \nabla c_i(x_k)$$

二次罚函数: CONVERGENCE ANALYSIS

二次罚函数: CONVERGENCE ANALYSIS

- 对应的终止条件是

$$\|\nabla f(x_k) + \sum_{i \in \mathcal{E}} \mu_k c_i(x_k) \nabla c_i(x_k)\| \leq \tau_k$$

二次罚函数: CONVERGENCE ANALYSIS

- 对应的终止条件是

$$\|\nabla f(x_k) + \sum_{i \in \mathcal{E}} \mu_k c_i(x_k) \nabla c_i(x_k)\| \leq \tau_k$$

- 利用三角不等式可以得到

$$\left\| \sum_{i \in \mathcal{E}} c_i(x_k) \nabla c_i(x_k) \right\| \leq \frac{1}{\mu_k} [\tau_k + \|\nabla f(x_k)\|].$$

二次罚函数: CONVERGENCE ANALYSIS

- 对应的终止条件是

$$\|\nabla f(x_k) + \sum_{i \in \mathcal{E}} \mu_k c_i(x_k) \nabla c_i(x_k)\| \leq \tau_k$$

- 利用三角不等式可以得到

$$\left\| \sum_{i \in \mathcal{E}} c_i(x_k) \nabla c_i(x_k) \right\| \leq \frac{1}{\mu_k} [\tau_k + \|\nabla f(x_k)\|].$$

- 假设 x^* 是 x_k 的某一个极限点, 即存在一个无限子列 \mathcal{K} , 使得 $\lim_{k \in \mathcal{K}} x_k = x^*$ 。两边同时取极限可以得到

$$\sum_{i \in \mathcal{E}} c_i(x^*) \nabla c_i(x^*) = 0$$

二次罚函数: CONVERGENCE ANALYSIS

- 对应的终止条件是

$$\|\nabla f(x_k) + \sum_{i \in \mathcal{E}} \mu_k c_i(x_k) \nabla c_i(x_k)\| \leq \tau_k$$

- 利用三角不等式可以得到

$$\left\| \sum_{i \in \mathcal{E}} c_i(x_k) \nabla c_i(x_k) \right\| \leq \frac{1}{\mu_k} [\tau_k + \|\nabla f(x_k)\|].$$

- 假设 x^* 是 x_k 的某一个极限点, 即存在一个无限子列 \mathcal{K} , 使得 $\lim_{k \in \mathcal{K}} x_k = x^*$ 。两边同时取极限可以得到

$$\sum_{i \in \mathcal{E}} c_i(x^*) \nabla c_i(x^*) = 0$$

- 如果 x^* 不在可行域, 则 $c_i(x^*) \neq 0$ (即 $\nabla c_i(x^*)$ 线性相关), 则可以推出 x^* 是 $\|c(x)\|_2^2$ 的一个稳定点。

二次罚函数: CONVERGENCE ANALYSIS

二次罚函数: CONVERGENCE ANALYSIS

- 如果 $\nabla c_i(x^*)$ 线性无关, 则可以推出 $c_i(x^*) = 0$ 对于 $\forall i \in \mathcal{E}$. x^* 是可行的。

二次罚函数: CONVERGENCE ANALYSIS

- 如果 $\nabla c_i(x^*)$ 线性无关, 则可以推出 $c_i(x^*) = 0$ 对于 $\forall i \in \mathcal{E}$. x^* 是可行的。
- 记 $A(x)^T = [\nabla c_i(x)]_{i \in \mathcal{E}}$, $\lambda_k = -\mu_k c(x_k)$, 则有

$$A(x_k)^T \lambda_k = \nabla f(x_k) - \nabla_x Q(x_k; \mu_k), \quad \|\nabla_x Q(x_k; \mu_k)\| \leq \tau_k.$$

二次罚函数: CONVERGENCE ANALYSIS

- 如果 $\nabla c_i(x^*)$ 线性无关, 则可以推出 $c_i(x^*) = 0$ 对于 $\forall i \in \mathcal{E}$. x^* 是可行的。
- 记 $A(x)^T = [\nabla c_i(x)]_{i \in \mathcal{E}}$, $\lambda_k = -\mu_k c(x_k)$, 则有

$$A(x_k)^T \lambda_k = \nabla f(x_k) - \nabla_x Q(x_k; \mu_k), \quad \|\nabla_x Q(x_k; \mu_k)\| \leq \tau_k.$$

- 当 k 足够大时, 我们可以得到 $A(x_k)$ 是满秩的, 这样 AA^T 是可逆的, 可以得到

$$\lambda_k = [A(x_k)A(x_k)^T]^{-1} A(x_k) [\nabla f(x_k) - \nabla_x Q(x_k; \mu_k)]$$

二次罚函数: CONVERGENCE ANALYSIS

- 如果 $\nabla c_i(x^*)$ 线性无关, 则可以推出 $c_i(x^*) = 0$ 对于 $\forall i \in \mathcal{E}$. x^* 是可行的。
- 记 $A(x)^T = [\nabla c_i(x)]_{i \in \mathcal{E}}$, $\lambda_k = -\mu_k c(x_k)$, 则有

$$A(x_k)^T \lambda_k = \nabla f(x_k) - \nabla_x Q(x_k; \mu_k), \quad \|\nabla_x Q(x_k; \mu_k)\| \leq \tau_k.$$

- 当 k 足够大时, 我们可以得到 $A(x_k)$ 是满秩的, 这样 AA^T 是可逆的, 可以得到

$$\lambda_k = [A(x_k)A(x_k)^T]^{-1} A(x_k) [\nabla f(x_k) - \nabla_x Q(x_k; \mu_k)]$$

- 两边同时取极限可以得到

$$\lim_{k \in \mathcal{K}} \lambda_k = \lambda^* = [A(x^*)A(x^*)^T]^{-1} A(x^*) \nabla f(x^*)$$

二次罚函数: CONVERGENCE ANALYSIS

- 如果 $\nabla c_i(x^*)$ 线性无关, 则可以推出 $c_i(x^*) = 0$ 对于 $\forall i \in \mathcal{E}$. x^* 是可行的。
- 记 $A(x)^T = [\nabla c_i(x)]_{i \in \mathcal{E}}$, $\lambda_k = -\mu_k c(x_k)$, 则有

$$A(x_k)^T \lambda_k = \nabla f(x_k) - \nabla_x Q(x_k; \mu_k), \quad \|\nabla_x Q(x_k; \mu_k)\| \leq \tau_k.$$

- 当 k 足够大时, 我们可以得到 $A(x_k)$ 是满秩的, 这样 AA^T 是可逆的, 可以得到

$$\lambda_k = [A(x_k)A(x_k)^T]^{-1} A(x_k) [\nabla f(x_k) - \nabla_x Q(x_k; \mu_k)]$$

- 两边同时取极限可以得到

$$\lim_{k \in \mathcal{K}} \lambda_k = \lambda^* = [A(x^*)A(x^*)^T]^{-1} A(x^*) \nabla f(x^*)$$

- 对终止条件 $\|\nabla f(x_k) + \sum_{i \in \mathcal{E}} \mu_k c_i(x_k) \nabla c_i(x_k)\| \leq \tau_k$ 两边也同时取极限

$$\nabla f(x^*) - A(x^*)^T \lambda^* = 0.$$

二次罚函数: ILL-CONDITIONING

下面我们检查一下 $\nabla_{xx}^2 Q(x, \mu_k)$ 的条件数。

二次罚函数: ILL-CONDITIONING

下面我们检查一下 $\nabla_{xx}^2 Q(x, \mu_k)$ 的条件数。

- 首先 $Q(x; \mu_k)$ 的Hessian阵为:

$$\nabla_{xx}^2 Q(x; \mu_k) = \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) + \mu_k A(x)^T A(x)$$

二次罚函数: ILL-CONDITIONING

下面我们检查一下 $\nabla_{xx}^2 Q(x, \mu_k)$ 的条件数。

- 首先 $Q(x; \mu_k)$ 的 Hessian 阵为:

$$\nabla_{xx}^2 Q(x; \mu_k) = \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) + \mu_k A(x)^T A(x)$$

- 当 $x \rightarrow x^*$ 时, 前两项就是拉格朗日函数的 Hessian

$$\nabla_{xx}^2 Q(x; \mu_k) \approx \nabla_{xx}^2 \mathcal{L}(x, \lambda^*) + \mu_k A(x)^T A(x).$$

二次罚函数: ILL-CONDITIONING

下面我们检查一下 $\nabla_{xx}^2 Q(x, \mu_k)$ 的条件数。

- 首先 $Q(x; \mu_k)$ 的 Hessian 阵为:

$$\nabla_{xx}^2 Q(x; \mu_k) = \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) + \mu_k A(x)^T A(x)$$

- 当 $x \rightarrow x^*$ 时, 前两项就是拉格朗日函数的 Hessian

$$\nabla_{xx}^2 Q(x; \mu_k) \approx \nabla_{xx}^2 \mathcal{L}(x, \lambda^*) + \mu_k A(x)^T A(x).$$

- 通常来说等式约束的个数会小于变量个数, $|\mathcal{E}| < n$, 因此第二项是奇异。

二次罚函数: ILL-CONDITIONING

下面我们检查一下 $\nabla_{xx}^2 Q(x, \mu_k)$ 的条件数。

- 首先 $Q(x; \mu_k)$ 的 Hessian 阵为:

$$\nabla_{xx}^2 Q(x; \mu_k) = \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) + \mu_k A(x)^T A(x)$$

- 当 $x \rightarrow x^*$ 时, 前两项就是拉格朗日函数的 Hessian

$$\nabla_{xx}^2 Q(x; \mu_k) \approx \nabla_{xx}^2 \mathcal{L}(x, \lambda^*) + \mu_k A(x)^T A(x).$$

- 通常来说等式约束的个数会小于变量个数, $|\mathcal{E}| < n$, 因此第二项是奇异。
- 因此总矩阵的有些特征值会趋于一个常数, 另外有一些是 $\mathcal{O}(\mu_k)$ 。
当 μ_k 很大时, 总矩阵的条件数就会很大。

二次罚函数: ILL-CONDITIONING

下面我们检查一下 $\nabla_{xx}^2 Q(x, \mu_k)$ 的条件数。

- 首先 $Q(x; \mu_k)$ 的 Hessian 阵为:

$$\nabla_{xx}^2 Q(x; \mu_k) = \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) + \mu_k A(x)^T A(x)$$

- 当 $x \rightarrow x^*$ 时, 前两项就是拉格朗日函数的 Hessian

$$\nabla_{xx}^2 Q(x; \mu_k) \approx \nabla_{xx}^2 \mathcal{L}(x, \lambda^*) + \mu_k A(x)^T A(x).$$

- 通常来说等式约束的个数会小于变量个数, $|\mathcal{E}| < n$, 因此第二项是奇异。
- 因此总矩阵的有些特征值会趋于一个常数, 另外有一些是 $\mathcal{O}(\mu_k)$ 。
当 μ_k 很大时, 总矩阵的条件数就会很大。
- 条件数很大的一个后果是, 无法求解很好的牛顿步, 即求解

$$p^N = -(\nabla_{xx}^2 Q(x; \mu_k))^{-1} \nabla_x Q(x; \mu_k) \quad (15.1)$$

二次罚函数: ILL-CONDITIONING

下面我们检查一下 $\nabla_{xx}^2 Q(x, \mu_k)$ 的条件数。

- 首先 $Q(x; \mu_k)$ 的 Hessian 阵为:

$$\nabla_{xx}^2 Q(x; \mu_k) = \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) + \mu_k A(x)^T A(x)$$

- 当 $x \rightarrow x^*$ 时, 前两项就是拉格朗日函数的 Hessian

$$\nabla_{xx}^2 Q(x; \mu_k) \approx \nabla_{xx}^2 \mathcal{L}(x, \lambda^*) + \mu_k A(x)^T A(x).$$

- 通常来说等式约束的个数会小于变量个数, $|\mathcal{E}| < n$, 因此第二项是奇异。
- 因此总矩阵的有些特征值会趋于一个常数, 另外有一些是 $\mathcal{O}(\mu_k)$ 。当 μ_k 很大时, 总矩阵的条件数就会很大。
- 条件数很大的一个后果是, 无法求解很好的牛顿步, 即求解

$$p^N = -(\nabla_{xx}^2 Q(x; \mu_k))^{-1} \nabla_x Q(x; \mu_k) \quad (15.1)$$

- 一般来说很难求解, 除非有好的预条件子。

二次罚函数: TRANSFORMATION

通过引入变量 $\zeta = \mu A(x)p$

二次罚函数: TRANSFORMATION

通过引入变量 $\zeta = \mu A(x)p$

- 则 (p, ζ) 满足

$$\begin{bmatrix} \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) & A(x)^T \\ A(x) & -(\mu_k)^{-1} I \end{bmatrix} \begin{bmatrix} p \\ \zeta \end{bmatrix} = \begin{bmatrix} -\nabla_x Q(x, \mu_k) \\ 0 \end{bmatrix} \quad (15.2)$$

二次罚函数: TRANSFORMATION

通过引入变量 $\zeta = \mu A(x)p$

- 则 (p, ζ) 满足

$$\begin{bmatrix} \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) & A(x)^T \\ A(x) & -(\mu_k)^{-1} I \end{bmatrix} \begin{bmatrix} p \\ \zeta \end{bmatrix} = \begin{bmatrix} -\nabla_x Q(x, \mu_k) \\ 0 \end{bmatrix} \quad (15.2)$$

- 当 x 靠近 x^* 时, 上述系数矩阵没有大特征值 $\mathcal{O}(\mu_k)$, 因此是(15.1)的well-conditioned变换.

二次罚函数: TRANSFORMATION

通过引入变量 $\zeta = \mu A(x)p$

- 则 (p, ζ) 满足

$$\begin{bmatrix} \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) & A(x)^T \\ A(x) & -(\mu_k)^{-1} I \end{bmatrix} \begin{bmatrix} p \\ \zeta \end{bmatrix} = \begin{bmatrix} -\nabla_x Q(x, \mu_k) \\ 0 \end{bmatrix} \quad (15.2)$$

- 当 x 靠近 x^* 时, 上述系数矩阵没有大特征值 $\mathcal{O}(\mu_k)$, 因此是(15.1)的well-conditioned变换。
- 但是两个系统都不能很好地求解牛顿方向 p , 因为在(15.2)中 $\mu_k c_i(x)$ 并不能很好地逼近 $-\lambda_i^*$, 即使 x_k 已经逼近 $Q(x; \mu_k)$ 的极小子。

二次罚函数: TRANSFORMATION

通过引入变量 $\zeta = \mu A(x)p$

- 则 (p, ζ) 满足

$$\begin{bmatrix} \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) & A(x)^T \\ A(x) & -(\mu_k)^{-1} I \end{bmatrix} \begin{bmatrix} p \\ \zeta \end{bmatrix} = \begin{bmatrix} -\nabla_x Q(x, \mu_k) \\ 0 \end{bmatrix} \quad (15.2)$$

- 当 x 靠近 x^* 时, 上述系数矩阵没有大特征值 $\mathcal{O}(\mu_k)$, 因此是(15.1)的well-conditioned变换。
- 但是两个系统都不能很好地求解牛顿方向 p , 因为在(15.2)中 $\mu_k c_i(x)$ 并不能很好地逼近 $-\lambda_i^*$, 即使 x_k 已经逼近 $Q(x; \mu_k)$ 的极小子。
- 这个事实有可能是由于基于 p 的二次函数模型并不能很好地逼近 $Q(\cdot; \mu_k)$, 因此牛顿步可能本质上就不是一个很好的搜索方向。

二次罚函数: TRANSFORMATION

通过引入变量 $\zeta = \mu A(x)p$

- 则 (p, ζ) 满足

$$\begin{bmatrix} \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) & A(x)^T \\ A(x) & -(\mu_k)^{-1} I \end{bmatrix} \begin{bmatrix} p \\ \zeta \end{bmatrix} = \begin{bmatrix} -\nabla_x Q(x, \mu_k) \\ 0 \end{bmatrix} \quad (15.2)$$

- 当 x 靠近 x^* 时, 上述系数矩阵没有大特征值 $\mathcal{O}(\mu_k)$, 因此是(15.1)的well-conditioned变换。
- 但是两个系统都不能很好地求解牛顿方向 p , 因为在(15.2)中 $\mu_k c_i(x)$ 并不能很好地逼近 $-\lambda_i^*$, 即使 x_k 已经逼近 $Q(x; \mu_k)$ 的极小子。
- 这个事实有可能是由于基于 p 的二次函数模型并不能很好地逼近 $Q(\cdot; \mu_k)$, 因此牛顿步可能本质上就不是一个很好的搜索方向。
- 如果要求解(15.2), 即求解一个 $n + |\mathcal{E}|$ 的线性方程组。这里 μ_k^{-1} 可以看做是正则化参数, 用于帮助解决 A 是秩亏时带来的迭代矩阵有可能是奇异的困难。

二次罚函数: TRANSFORMATION

通过引入变量 $\zeta = \mu A(x)p$

- 则 (p, ζ) 满足

$$\begin{bmatrix} \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \mu_k c_i(x) \nabla^2 c_i(x) & A(x)^T \\ A(x) & -(\mu_k)^{-1} I \end{bmatrix} \begin{bmatrix} p \\ \zeta \end{bmatrix} = \begin{bmatrix} -\nabla_x Q(x, \mu_k) \\ 0 \end{bmatrix} \quad (15.2)$$

- 当 x 靠近 x^* 时, 上述系数矩阵没有大特征值 $\mathcal{O}(\mu_k)$, 因此是(15.1)的well-conditioned变换.
- 但是两个系统都不能很好地求解牛顿方向 p , 因为在(15.2)中 $\mu_k c_i(x)$ 并不能很好地逼近 $-\lambda_i^*$, 即使 x_k 已经逼近 $Q(x; \mu_k)$ 的极小子.
- 这个事实有可能是由于基于 p 的二次函数模型并不能很好地逼近 $Q(\cdot; \mu_k)$, 因此牛顿步可能本质上就不是一个很好的搜索方向.
- 如果要求解(15.2), 即求解一个 $n + |\mathcal{E}|$ 的线性方程组. 这里 μ_k^{-1} 可以看做是正则化参数, 用于帮助解决 A 是秩亏时带来的迭代矩阵有可能是奇异的困难.
- 如果 μ_k 不能很快趋于无穷大, 则无法到达超线性收敛.

非光滑罚函数

- 如果选取合适的惩罚参数，使得一次最优化就可以得到原问题的精确解。

非光滑罚函数

- 如果选取合适的惩罚参数，使得一次最优化就可以得到原问题的精确解。
- 二次罚函数不是精确的，对于任意的 $\mu > 0$ ，其解都不是原问题的解。

非光滑罚函数

- 如果选取合适的惩罚参数, 使得一次最优化就可以得到原问题的精确解。
- 二次罚函数不是精确的, 对于任意的 $\mu > 0$, 其解都不是原问题的解。
- 考虑 ℓ_1 罚函数

$$\phi_1(x; \mu) = f(x) + \mu \sum_{i \in \mathcal{E}} |c_i(x)| + \mu \sum_{i \in \mathcal{J}} [c_i(x)]^-. \quad (15.3)$$

其中 $[y]^- = \max(0, -y)$.

定理3: ℓ_1 是精确罚函数

假设 x^* 是原问题的一个精确解满足KKT条件。则 x^* 也是 $\phi_1(x; \mu)$ 在 $\mu > \mu^*$ 的一个局部解, 并且

$$\mu^* = \|\lambda^*\|_\infty = \max_{i \in \mathcal{E} \cup \mathcal{J}} |\lambda_i^*|. \quad (15.4)$$

此外, 如果对 $\mu > \mu^*$ 满足二阶充分性条件, 则 x^* 还是严格的局部极小子。

非光滑罚函数

例：

$$\min x \quad \text{subject to } x \geq 1$$

非光滑罚函数

例：

$$\min x \quad \text{subject to } x \geq 1$$

则对应的非光滑罚函数为

$$\phi_1(x; \mu) = x + \mu[x - 1]^- = \begin{cases} (1 - \mu)x + \mu & \text{if } x \leq 1, \\ x & \text{if } x > 1. \end{cases}$$

非光滑罚函数

例：

$$\min x \quad \text{subject to } x \geq 1$$

则对应的非光滑罚函数为

$$\phi_1(x; \mu) = x + \mu[x - 1]^- = \begin{cases} (1 - \mu)x + \mu & \text{if } x \leq 1, \\ x & \text{if } x > 1. \end{cases}$$




Figure: $\mu > 1$ (left), $\mu < 1$ (right).

非光滑罚函数

定义：平衡点

非光滑罚函数

定义：平衡点

- $\hat{x} \in R^n$ 被称为平衡点，如果对任意的 $p \in R^n$

$$D(\phi_1(\hat{x}; \mu); p) \geq 0.$$

非光滑罚函数

定义：平衡点

- $\hat{x} \in R^n$ 被称为平衡点，如果对任意的 $p \in R^n$

$$D(\phi_1(\hat{x}; \mu); p) \geq 0.$$

- 同样地， \hat{x} 也如下"不可行测度"的一个平衡点

$$h(x) = \sum_{i \in \mathcal{E}} |c_i(x)| + \sum_{i \in \mathcal{I}} [c_i(x)]^-$$

如果 $D(h(\hat{x}); p) \geq 0$, 对任意的 $p \in R^n$ 。

非光滑罚函数

定义：平衡点

- $\hat{x} \in R^n$ 被称为平衡点，如果对任意的 $p \in R^n$

$$D(\phi_1(\hat{x}; \mu); p) \geq 0.$$

- 同样地， \hat{x} 也如下"不可行测度"的一个平衡点

$$h(x) = \sum_{i \in \mathcal{E}} |c_i(x)| + \sum_{i \in \mathcal{I}} [c_i(x)]^-$$

如果 $D(h(\hat{x}); p) \geq 0$, 对任意的 $p \in R^n$ 。

- 如果 \hat{x} 是不可行的，但仍旧是 $h(x)$ 的平衡点，称之为不可行平衡点。

非光滑罚函数

定义：平衡点

- $\hat{x} \in R^n$ 被称为平衡点，如果对任意的 $p \in R^n$

$$D(\phi_1(\hat{x}; \mu); p) \geq 0.$$

- 同样地， \hat{x} 也如下"不可行测度"的一个平衡点

$$h(x) = \sum_{i \in \mathcal{E}} |c_i(x)| + \sum_{i \in \mathcal{I}} [c_i(x)]^-$$

如果 $D(h(\hat{x}); p) \geq 0$, 对任意的 $p \in R^n$ 。

- 如果 \hat{x} 是不可行的，但仍旧是 $h(x)$ 的平衡点，称之为不可行平衡点。
- 上述例子里

$$D(\phi_1(x^*; \mu); p) = \begin{cases} p & \text{if } p \geq 0, \\ (1 - \mu)p & \text{if } p < 0; \end{cases}$$

显然，当 $\mu > 1$ 时，我们有 $D(\phi_1(x^*; \mu); p) \geq 0$ 。

非光滑罚函数

定理4:

假设 \hat{x} 是罚函数 $\phi_1(x; \mu)$ 的稳定点对于 $\forall \mu > \hat{\mu}$. 那么以下结论成立。

- ① 如果 \hat{x} 是可行的, 则 \hat{x} 满足KKT条件。
- ② 如果 \hat{x} 不是可行点, 则它是不可行的稳定点。

非光滑罚函数

- 假设 \hat{x} 是可行的，则根据方向导数的定义有

$$D(\phi_1(\hat{x}, \mu); p) = \nabla f(\hat{x})^T p + \mu \sum_{i \in \mathcal{E}} |\nabla c_i(\hat{x})^T p| + \mu \sum_{i \in \mathcal{I} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^-$$

非光滑罚函数

- 假设 \hat{x} 是可行的，则根据方向导数的定义有

$$D(\phi_1(\hat{x}, \mu); p) = \nabla f(\hat{x})^T p + \mu \sum_{i \in \mathcal{E}} |\nabla c_i(\hat{x})^T p| + \mu \sum_{i \in \mathcal{I} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^-$$

- 在线性化后的可行方向集 $\mathcal{F}(\hat{x})$ 中考虑任何方向 p ，我们可以得到

$$|\nabla c_i(\hat{x})^T p| + \sum_{i \in \mathcal{I} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^- = 0$$

非光滑罚函数

- 假设 \hat{x} 是可行的，则根据方向导数的定义有

$$D(\phi_1(\hat{x}, \mu); p) = \nabla f(\hat{x})^T p + \mu \sum_{i \in \mathcal{E}} |\nabla c_i(\hat{x})^T p| + \mu \sum_{i \in \mathcal{I} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^-$$

- 在线性化后的可行方向集 $\mathcal{F}(\hat{x})$ 中考虑任何方向 p ，我们可以得到

$$|\nabla c_i(\hat{x})^T p| + \sum_{i \in \mathcal{I} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^- = 0$$

- 再根据平衡点的定义可知

$$0 \leq D(\phi_1(\hat{x}; \mu); p) = \nabla f(\hat{x})^T p, \quad \forall p \in \mathcal{F}(\hat{x}).$$

非光滑罚函数

- 假设 \hat{x} 是可行的, 则根据方向导数的定义有

$$D(\phi_1(\hat{x}, \mu); p) = \nabla f(\hat{x})^T p + \mu \sum_{i \in \mathcal{E}} |\nabla c_i(\hat{x})^T p| + \mu \sum_{i \in \mathcal{J} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^-$$

- 在线性化后的可行方向集 $\mathcal{F}(\hat{x})$ 中考虑任何方向 p , 我们可以得到

$$|\nabla c_i(\hat{x})^T p| + \sum_{i \in \mathcal{J} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^- = 0$$

- 再根据平衡点的定义可知

$$0 \leq D(\phi_1(\hat{x}; \mu); p) = \nabla f(\hat{x})^T p, \quad \forall p \in \mathcal{F}(\hat{x}).$$

- 最后使用Farkas引理可得

$$\nabla f(\hat{x}) = \sum_{i \in \mathcal{A}(\hat{x})} \hat{\lambda}_i \nabla c_i(\hat{x}), \text{ and } \hat{\lambda}_i \geq 0 \text{ for all } i \in \mathcal{J} \cap \mathcal{A}(\hat{x}).$$

非光滑罚函数

- 假设 \hat{x} 是可行的, 则根据方向导数的定义有

$$D(\phi_1(\hat{x}, \mu); p) = \nabla f(\hat{x})^T p + \mu \sum_{i \in \mathcal{E}} |\nabla c_i(\hat{x})^T p| + \mu \sum_{i \in \mathcal{J} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^-$$

- 在线性化后的可行方向集 $\mathcal{F}(\hat{x})$ 中考虑任何方向 p , 我们可以得到

$$|\nabla c_i(\hat{x})^T p| + \sum_{i \in \mathcal{J} \cap \mathcal{A}(\hat{x})} [\nabla c_i(\hat{x})^T p]^- = 0$$

- 再根据平衡点的定义可知

$$0 \leq D(\phi_1(\hat{x}; \mu); p) = \nabla f(\hat{x})^T p, \quad \forall p \in \mathcal{F}(\hat{x}).$$

- 最后使用Farkas引理可得

$$\nabla f(\hat{x}) = \sum_{i \in \mathcal{A}(\hat{x})} \hat{\lambda}_i \nabla c_i(\hat{x}), \text{ and } \hat{\lambda}_i \geq 0 \text{ for all } i \in \mathcal{J} \cap \mathcal{A}(\hat{x}).$$

- 再由一阶最优性条件定理(即KKT条件), 上述等式可以推出KKT条件满足。

非光滑函数

重新考虑第一个例子，其对应的 ℓ_1 罚函数应该是

$$\phi_1(x; \mu) = x_1 + x_2 + \mu|x_1^2 + x_2^2 - 2|.$$





Figure: contours of $\phi_1(x; 2)$

非光滑函数

重新考虑第一个例子，其对应的 ℓ_1 罚函数应该是

$$\phi_1(x; \mu) = x_1 + x_2 + \mu|x_1^2 + x_2^2 - 2|.$$



- 根据定理3，当 $\mu > |\lambda^*| = 0.5$ 时， $\phi_1(x; \mu)$ 的极小值与 $(-1, -1)^T$ 重合。
- 等高线上的尖点表示，沿着边界 $x_1^2 + x_2^2 = 2$ ， $\phi(x; \mu)$ 是不光滑的。

Figure: contours of $\phi_1(x; 2)$

非光滑函数算法

ALGORITHM 2: 经典 ℓ_1 罚函数法

给定 $\mu_0 > 0$, 容忍误差 $\tau > 0$, 起始点 x_k^s ;
for $k = 0, 1, 2, \dots$
 从初始值 x_k^s 出发, 寻找 $\phi_1(x; \mu_k)$ 的极小子 x_k ;
 if $h(x_k) \leq \tau$
 stop with x_k
 end(if)
 选择新的惩罚参数 $\mu_{k+1} > \mu_k$;
 选择新的初始点 x_{k+1}^s ;
end(for)

非光滑函数算法

ALGORITHM 2: 经典 ℓ_1 罚函数法

```

给定 $\mu_0 > 0$ , 容忍误差 $\tau > 0$ , 起始点 $x_k^s$ ;
for  $k = 0, 1, 2, \dots$ 
    从初始值 $x_k^s$ 出发, 寻找 $\phi_1(x; \mu_k)$ 的极小子 $x_k$ ;
    if  $h(x_k) \leq \tau$ 
        stop with  $x_k$ 
    end(if)
    选择新的惩罚参数 $\mu_{k+1} > \mu_k$ ;
    选择新的初始点 $x_{k+1}^s$ ;
end(for)

```

- 由于 $\phi_1(x; \mu)$ 是不光滑的, 求解有一定困难。可以用SQP(sequential quadratic programming)求解。

非光滑函数算法

ALGORITHM 2: 经典 ℓ_1 罚函数法

```

给定 $\mu_0 > 0$ , 容忍误差 $\tau > 0$ , 起始点 $x_k^s$ ;
for  $k = 0, 1, 2, \dots$ 
    从初始值 $x_k^s$ 出发, 寻找 $\phi_1(x; \mu_k)$ 的极小子 $x_k$ ;
    if  $h(x_k) \leq \tau$ 
        stop with  $x_k$ 
    end(if)
    选择新的惩罚参数 $\mu_{k+1} > \mu_k$ ;
    选择新的初始点 $x_{k+1}^s$ ;
end(for)

```

- 由于 $\phi_1(x; \mu)$ 是不光滑的, 求解有一定困难。可以用SQP(sequential quadratic programming)求解。
- 如何更新 μ_k ? 可以用简单的策略, 倍数增加。当 μ_k 比较大时, 更难求解, 需要更多计算量。

非光滑函数实用算法

● 定义

$$q(p; \mu) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T W p + \mu \sum_{i \in \mathcal{E}} |c_i(x) + \nabla c_i(x)^T p| \\ + \mu \sum_{i \in \mathcal{J}} [c_i(x) + \nabla c_i(x)^T p]^-$$

其中 W 是对称矩阵，包含了 f 以及 $c_i(x)$ 的二阶导数信息。

非光滑函数实用算法

- 定义

$$q(p; \mu) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T W p + \mu \sum_{i \in \mathcal{E}} |c_i(x) + \nabla c_i(x)^T p| \\ + \mu \sum_{i \in \mathcal{J}} [c_i(x) + \nabla c_i(x)^T p]^-$$

其中 W 是对称矩阵，包含了 f 以及 $c_i(x)$ 的二阶导数信息。

- 显然 $q(p; \mu)$ 也不是光滑的，但是我们将其转化为光滑的二次规划问题

$$\left\{ \begin{array}{ll} \min_{p, r, s, t} & f(x) + \frac{1}{2} p^T W p + \mu \sum_{i \in \mathcal{E}} (r_i + s_i) + \mu \sum_{i \in \mathcal{J}} t_i \\ \text{subject to} & \nabla c_i(x)^T p + c_i(x) = r_i - s_i, \quad i \in \mathcal{E} \\ & \nabla c_i(x)^T p + c_i(x) \geq -t_i, \quad i \in \mathcal{J} \\ & r, s, t \geq 0. \end{array} \right.$$

非光滑函数实用算法

- 定义

$$q(p; \mu) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T W p + \mu \sum_{i \in \mathcal{E}} |c_i(x) + \nabla c_i(x)^T p| \\ + \mu \sum_{i \in \mathcal{J}} [c_i(x) + \nabla c_i(x)^T p]^-$$

其中 W 是对称矩阵，包含了 f 以及 $c_i(x)$ 的二阶导数信息。

- 显然 $q(p; \mu)$ 也不是光滑的，但是我们将其转化为光滑的二次规划问题

$$\left\{ \begin{array}{ll} \min_{p, r, s, t} & f(x) + \frac{1}{2} p^T W p + \mu \sum_{i \in \mathcal{E}} (r_i + s_i) + \mu \sum_{i \in \mathcal{J}} t_i \\ \text{subject to} & \nabla c_i(x)^T p + c_i(x) = r_i - s_i, \quad i \in \mathcal{E} \\ & \nabla c_i(x)^T p + c_i(x) \geq -t_i, \quad i \in \mathcal{J} \\ & r, s, t \geq 0. \end{array} \right.$$

- 上述子问题可以由标准的二次罚函数方法求解。

拉格朗日增广函数

- 该方法可以看作是拉格朗日乘子函数和二次罚函数的组合

$$\mathcal{L}_A(x, \lambda; \mu) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i c_i(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x)$$

拉格朗日增广函数

- 该方法可以看作是拉格朗日乘子函数和二次罚函数的组合

$$\mathcal{L}_A(x, \lambda; \mu) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i c_i(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x)$$

- 首先固定 μ_k ，然后固定当前估计 λ^k ，寻找最优解 x_k 。其满足的最优性条件是

$$0 \approx \nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k) = \nabla f(x_k) - \sum_{i \in \mathcal{E}} [\lambda_i^k - \mu_k c_i(x_k)] \nabla c_i(x_k).$$

拉格朗日增广函数

- 该方法可以看作是拉格朗日乘子函数和二次罚函数的组合

$$\mathcal{L}_A(x, \lambda; \mu) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i c_i(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x)$$

- 首先固定 μ_k ，然后固定当前估计 λ^k ，寻找最优解 x_k 。其满足的最优性条件是

$$0 \approx \nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k) = \nabla f(x_k) - \sum_{i \in \mathcal{E}} [\lambda_i^k - \mu_k c_i(x_k)] \nabla c_i(x_k).$$

- 根据二次罚函数的定理2，我们可以得到

$$\lambda_i^* \approx \lambda_i^k - \mu_k c_i(x_k), \quad \forall i \in \mathcal{E}.$$

$$\text{即: } c_i(x_k) \approx -\frac{1}{\mu_k} (\lambda_i^* - \lambda_i^k), \quad \forall i \in \mathcal{E}.$$

拉格朗日增广函数

- 该方法可以看作是拉格朗日乘子函数和二次罚函数的组合

$$\mathcal{L}_A(x, \lambda; \mu) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i c_i(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x)$$

- 首先固定 μ_k ，然后固定当前估计 λ^k ，寻找最优解 x_k 。其满足的最优性条件是

$$0 \approx \nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k) = \nabla f(x_k) - \sum_{i \in \mathcal{E}} [\lambda_i^k - \mu_k c_i(x_k)] \nabla c_i(x_k).$$

- 根据二次罚函数的定理2，我们可以得到

$$\lambda_i^* \approx \lambda_i^k - \mu_k c_i(x_k), \quad \forall i \in \mathcal{E}.$$

$$\text{即: } c_i(x_k) \approx -\frac{1}{\mu_k} (\lambda_i^* - \lambda_i^k), \quad \forall i \in \mathcal{E}.$$

- 由于 λ^* 很接近 λ^k ，这说明 x_k 的不可行性远小于 $\frac{1}{\mu_k}$ ，因此我们可以设置

$$\lambda_i^{k+1} = \lambda_i^k - \mu_k c_i(x_k), \quad \forall i \in \mathcal{E}.$$

拉格朗日增广函数算法

ALGORITHM 3: 等式约束下的增广拉格朗日方法

给定 $\mu_0 > 0$, 容忍误差 τ_0 , 初始出发点 x_0^s 和 λ^0 ;

for $k = 0, 1, 2, \dots$

 从 x_k^s 出发找到 $\mathcal{L}_A(\cdot, \lambda^k; \mu_k)$ 的近似极小子 x_k 直到 $\|\nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k)\| \leq \tau_k$

if a convergence test is satisfied

stop with x_k

end(if)

 更新拉格朗日乘子 $\lambda_i^{k+1} = \lambda_i^k - \mu_k c_i(x_k)$;

 选择新的惩罚参数 $\mu_{k+1} \geq \mu_k$;

 选择新的迭代出发点 $x_{k+1}^s = x_k$;

 选择新的容忍误差 τ_{k+1} ;

end(for)

拉格朗日增广函数算法

ALGORITHM 3: 等式约束下的增广拉格朗日方法

给定 $\mu_0 > 0$, 容忍误差 τ_0 , 初始出发点 x_0^s 和 λ^0 ;

for $k = 0, 1, 2, \dots$

从 x_k^s 出发找到 $\mathcal{L}_A(\cdot, \lambda^k; \mu_k)$ 的近似极小子 x_k 直到 $\|\nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k)\| \leq \tau_k$

if a convergence test is satisfied

stop with x_k

end(if)

更新拉格朗日乘子 $\lambda_i^{k+1} = \lambda_i^k - \mu_k c_i(x_k)$;

选择新的惩罚参数 $\mu_{k+1} \geq \mu_k$;

选择新的迭代出发点 $x_{k+1}^s = x_k$;

选择新的容忍误差 τ_{k+1} ;

end(for)

- 这里不需要 $\mu_k \rightarrow \infty$ 来保证收敛性

拉格朗日增广函数算法

ALGORITHM 3: 等式约束下的增广拉格朗日方法

给定 $\mu_0 > 0$, 容忍误差 τ_0 , 初始出发点 x_0^s 和 λ^0 ;

for $k = 0, 1, 2, \dots$

 从 x_k^s 出发找到 $\mathcal{L}_A(\cdot, \lambda^k; \mu_k)$ 的近似极小子 x_k 直到 $\|\nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k)\| \leq \tau_k$

if a convergence test is satisfied

stop with x_k

end(if)

 更新拉格朗日乘子 $\lambda_i^{k+1} = \lambda_i^k - \mu_k c_i(x_k)$;

 选择新的惩罚参数 $\mu_{k+1} \geq \mu_k$;

 选择新的迭代出发点 $x_{k+1}^s = x_k$;

 选择新的容忍误差 τ_{k+1} ;

end(for)

- 这里不需要 $\mu_k \rightarrow \infty$ 来保证收敛性
- ill-condition 也不是一个问题, x_{k+1}^s 的选取也不是关键的.

拉格朗日增广函数算法

ALGORITHM 3: 等式约束下的增广拉格朗日方法

给定 $\mu_0 > 0$, 容忍误差 τ_0 , 初始出发点 x_0^s 和 λ^0 ;

for $k = 0, 1, 2, \dots$

从 x_k^s 出发找到 $\mathcal{L}_A(\cdot, \lambda^k; \mu_k)$ 的近似极小子 x_k 直到 $\|\nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k)\| \leq \tau_k$

if a convergence test is satisfied

stop with x_k

end(if)

更新拉格朗日乘子 $\lambda_i^{k+1} = \lambda_i^k - \mu_k c_i(x_k)$;

选择新的惩罚参数 $\mu_{k+1} \geq \mu_k$;

选择新的迭代出发点 $x_{k+1}^s = x_k$;

选择新的容忍误差 τ_{k+1} ;

end(for)

- 这里不需要 $\mu_k \rightarrow \infty$ 来保证收敛性
- ill-condition 也不是一个问题, x_{k+1}^s 的选取也不是关键的.
- τ_k 可以根据 $\sum_{i \in \mathcal{E}} |c(x_k)|$ 选取

拉格朗日增广函数算法

ALGORITHM 3: 等式约束下的增广拉格朗日方法

给定 $\mu_0 > 0$, 容忍误差 τ_0 , 初始出发点 x_0^s 和 λ^0 ;

for $k = 0, 1, 2, \dots$

从 x_k^s 出发找到 $\mathcal{L}_A(\cdot, \lambda^k; \mu_k)$ 的近似极小子 x_k 直到 $\|\nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k)\| \leq \tau_k$

if a convergence test is satisfied

stop with x_k

end(if)

更新拉格朗日乘子 $\lambda_i^{k+1} = \lambda_i^k - \mu_k c_i(x_k)$;

选择新的惩罚参数 $\mu_{k+1} \geq \mu_k$;

选择新的迭代出发点 $x_{k+1}^s = x_k$;

选择新的容忍误差 τ_{k+1} ;

end(for)

- 这里不需要 $\mu_k \rightarrow \infty$ 来保证收敛性
- ill-condition 也不是一个问题, x_{k+1}^s 的选取也不是关键的.
- τ_k 可以根据 $\sum_{i \in \mathcal{E}} |c(x_k)|$ 选取
- 如果不可行测度下降不充分, 可以增加 μ .

拉格朗日增广函数

仍然考虑前面的例子，其对应的拉格朗日增广函数是

$$\mathcal{L}_A(x, \lambda; \mu) = x_1 + x_2 - \lambda(x_1^2 + x_2^2 - 2) + \frac{\mu}{2}(x_1^2 + x_2^2 - 2).$$

拉格朗日增广函数

仍然考虑前面的例子，其对应的拉格朗日增广函数是

$$\mathcal{L}_A(x, \lambda; \mu) = x_1 + x_2 - \lambda(x_1^2 + x_2^2 - 2) + \frac{\mu}{2}(x_1^2 + x_2^2 - 2).$$




Figure: $\lambda = -0.4$ and $\mu = 1$

拉格朗日增广函数

仍然考虑前面的例子，其对应的拉格朗日增广函数是

$$\mathcal{L}_A(x, \lambda; \mu) = x_1 + x_2 - \lambda(x_1^2 + x_2^2 - 2) + \frac{\mu}{2}(x_1^2 + x_2^2 - 2).$$





Figure: $\lambda = -0.4$ and $\mu = 1$

拉格朗日增广函数

仍然考虑前面的例子，其对应的拉格朗日增广函数是

$$\mathcal{L}_A(x, \lambda; \mu) = x_1 + x_2 - \lambda(x_1^2 + x_2^2 - 2) + \frac{\mu}{2}(x_1^2 + x_2^2 - 2).$$




- 精确解是 $x^* = (-1, -1)^T$, $\lambda^* = -0.5$.

Figure: $\lambda = -0.4$ and $\mu = 1$

拉格朗日增广函数

仍然考虑前面的例子，其对应的拉格朗日增广函数是

$$\mathcal{L}_A(x, \lambda; \mu) = x_1 + x_2 - \lambda(x_1^2 + x_2^2 - 2) + \frac{\mu}{2}(x_1^2 + x_2^2 - 2).$$



- 精确解是 $x^* = (-1, -1)^T$, $\lambda^* = -0.5$.
- 从等高线密度来看与使用二次罚函数相似 ($\mu = 1$), 说明条件数还比较好。

Figure: $\lambda = -0.4$ and $\mu = 1$

拉格朗日增广函数

仍然考虑前面的例子，其对应的拉格朗日增广函数是

$$\mathcal{L}_A(x, \lambda; \mu) = x_1 + x_2 - \lambda(x_1^2 + x_2^2 - 2) + \frac{\mu}{2}(x_1^2 + x_2^2 - 2).$$




Figure: $\lambda = -0.4$ and $\mu = 1$

- 精确解是 $x^* = (-1, -1)^T$, $\lambda^* = -0.5$.
- 从等高线密度来看与使用二次罚函数相似 ($\mu = 1$), 说明条件数还比较好。
- 但是解 $(-1.02, -1.02)^T$ 要远好于使用二次罚函数情形。

拉格朗日增广函数性质

定理5:

如果 x^* 是原问题的解, 并且在 x^* 处LICQ成立, 二阶充分性条件在 $\lambda = \lambda^*$ 处也成立。那么, 存在一个阈值 $\bar{\mu}$, 当 $\mu \geq \bar{\mu}$ 时, x^* 是 $\mathcal{L}_A(x, \lambda^*; \mu)$ 的一个严格局部极小子。

拉格朗日增广函数性质

定理5:

如果 x^* 是原问题的解, 并且在 x^* 处LICQ成立, 二阶充分性条件在 $\lambda = \lambda^*$ 处也成立。那么, 存在一个阈值 $\bar{\mu}$, 当 $\mu \geq \bar{\mu}$ 时, x^* 是 $\mathcal{L}_A(x, \lambda^*; \mu)$ 的一个严格局部极小子。

定理6:

如果定理5中条件在 x^* 和 λ^* 处成立, $\bar{\mu}$ 也如定理5中取值。那么存在正的 δ, ϵ 和 M 满足 对于所有的 λ^k 和 μ_k 满足

$$\|\lambda^k - \lambda^*\| \leq \delta \mu_k, \mu_k \geq \bar{\mu}$$

拉格朗日增广函数性质

定理5:

如果 x^* 是原问题的解, 并且在 x^* 处LICQ成立, 二阶充分性条件在 $\lambda = \lambda^*$ 处也成立。那么, 存在一个阈值 $\bar{\mu}$, 当 $\mu \geq \bar{\mu}$ 时, x^* 是 $\mathcal{L}_A(x, \lambda^*; \mu)$ 的一个严格局部极小子。

定理6:

如果定理5中条件在 x^* 和 λ^* 处成立, $\bar{\mu}$ 也如定理5中取值。那么存在正的 δ, ϵ 和 M 满足 对于所有的 λ^k 和 μ_k 满足

$$\|\lambda^k - \lambda^*\| \leq \delta \mu_k, \mu_k \geq \bar{\mu}$$

- ① 问题 $\min_x \mathcal{L}_A(x, \lambda^k; \mu_k)$ subject to $\|x - x^*\| \leq \epsilon$ 存在唯一的解 x_k , 并且满足 $\|x_k - x^*\| \leq M \|\lambda^k - \lambda^*\| \mu_k^{-1}$ 。

拉格朗日增广函数性质

定理5:

如果 x^* 是原问题的解, 并且在 x^* 处LICQ成立, 二阶充分性条件在 $\lambda = \lambda^*$ 处也成立。那么, 存在一个阈值 $\bar{\mu}$, 当 $\mu \geq \bar{\mu}$ 时, x^* 是 $\mathcal{L}_A(x, \lambda^*; \mu)$ 的一个严格局部极小子。

定理6:

如果定理5中条件在 x^* 和 λ^* 处成立, $\bar{\mu}$ 也如定理5中取值。那么存在正的 δ, ϵ 和 M 满足 对于所有的 λ^k 和 μ_k 满足

$$\|\lambda^k - \lambda^*\| \leq \delta \mu_k, \mu_k \geq \bar{\mu}$$

- ① 问题 $\min_x \mathcal{L}_A(x, \lambda^k; \mu_k)$ subject to $\|x - x^*\| \leq \epsilon$ 存在唯一的解 x_k , 并且满足 $\|x_k - x^*\| \leq M \|\lambda^k - \lambda^*\| \mu_k^{-1}$ 。
- ② 如果 $\lambda^{k+1} = \lambda^k - \mu_k c_i(x_k)$, 则有 $\|\lambda^{k+1} - \lambda^*\| \leq M \|\lambda^k - \lambda^*\| \mu_k^{-1}$ 。

拉格朗日增广函数性质

定理5:

如果 x^* 是原问题的解, 并且在 x^* 处LICQ成立, 二阶充分性条件在 $\lambda = \lambda^*$ 处也成立。那么, 存在一个阈值 $\bar{\mu}$, 当 $\mu \geq \bar{\mu}$ 时, x^* 是 $\mathcal{L}_A(x, \lambda^*; \mu)$ 的一个严格局部极小子。

定理6:

如果定理5中条件在 x^* 和 λ^* 处成立, $\bar{\mu}$ 也如定理5中取值。那么存在正的 δ, ϵ 和 M 满足 对于所有的 λ^k 和 μ_k 满足

$$\|\lambda^k - \lambda^*\| \leq \delta \mu_k, \mu_k \geq \bar{\mu}$$

- ① 问题 $\min_x \mathcal{L}_A(x, \lambda^k; \mu_k)$ subject to $\|x - x^*\| \leq \epsilon$ 存在唯一的解 x_k , 并且满足 $\|x_k - x^*\| \leq M \|\lambda^k - \lambda^*\| \mu_k^{-1}$ 。
- ② 如果 $\lambda^{k+1} = \lambda^k - \mu_k c_i(x_k)$, 则有 $\|\lambda^{k+1} - \lambda^*\| \leq M \|\lambda^k - \lambda^*\| \mu_k^{-1}$ 。
- ③ 对应的Hessian阵 $\nabla_{xx}^2 \mathcal{L}_A(x_k, \lambda^k; \mu_k)$ 是正定的, 并且所有约束的梯度 $\nabla c_i(x_k)$ 是线性无关的。

拉格朗日增广函数实用方法：有界约束

- 如果出现不等式约束，可以转化为有界约束。引入变量 s_i ，把所有不等式约束 $c_i(x) \geq 0$ 改为 $c_i(x) - s_i = 0$ 和 $s_i \geq 0$.

拉格朗日增广函数实用方法：有界约束

- 如果出现不等式约束，可以转化为有界约束。引入变量 s_i ，把所有不等式约束 $c_i(x) \geq 0$ 改为 $c_i(x) - s_i = 0$ 和 $s_i \geq 0$.
- 原非线性规划的一般形式可以写为

$$\min_x f(x) \text{ subject to } c_i(x) = 0, i = 1, \dots, m, l \leq x \leq u.$$

拉格朗日增广函数实用方法：有界约束

- 如果出现不等式约束，可以转化为有界约束。引入变量 s_i ，把所有不等式约束 $c_i(x) \geq 0$ 改为 $c_i(x) - s_i = 0$ 和 $s_i \geq 0$.
- 原非线性规划的一般形式可以写为

$$\min_x f(x) \text{ subject to } c_i(x) = 0, i = 1, \dots, m, l \leq x \leq u.$$

- 其对应的增广拉格朗日函数为

$$\mathcal{L}_A(x, \lambda; \mu) = f(x) - \sum_{i=1}^m \lambda_i c_i(x) + \frac{\mu}{2} c_i^2(x).$$

拉格朗日增广函数实用方法：有界约束

- 如果出现不等式约束，可以转化为有界约束。引入变量 s_i ，把所有不等式约束 $c_i(x) \geq 0$ 改为 $c_i(x) - s_i = 0$ 和 $s_i \geq 0$.
- 原非线性规划的一般形式可以写为

$$\min_x f(x) \text{ subject to } c_i(x) = 0, i = 1, \dots, m, l \leq x \leq u.$$

- 其对应的增广拉格朗日函数为

$$\mathcal{L}_A(x, \lambda; \mu) = f(x) - \sum_{i=1}^m \lambda_i c_i(x) + \frac{\mu}{2} c_i^2(x).$$

- 有界约束直接显示地在子问题中强制成立

$$\min_x \mathcal{L}_A(x, \lambda; \mu) \text{ subject to } l \leq x \leq u.$$

拉格朗日增广函数实用方法：有界约束

- 求解有界约束的方法主要是梯度投影法。

拉格朗日增广函数实用方法：有界约束

- 求解有界约束的方法主要是梯度投影法。
- 上述问题的一阶最优性条件为

$$x - P(x - \nabla_x \mathcal{L}_A(x, \lambda; \mu), l, u) = 0$$

其中 $P(g, l, u)$ 是把向量 g 投影到有 l, u 确定的矩形区域算子

$$P(g, l, u)_i = \begin{cases} l_i & \text{if } g_i \leq l_i, \\ g_i & \text{if } g_i \in (l_i, u_i), \\ u_i & \text{if } g_i \geq u_i, \end{cases}$$

拉格朗日增广函数实用算法

ALGORITHM 4: 带有界约束的增广拉格朗日函数法

选择初始点 x_0 和初始乘子 λ^0 ; 选择收敛容忍误差 η_* 和 ω_* ;

设 $\mu_0 = 10$, $\omega_0 = \mu_0^{-1}$ 以及 $\eta_0 = \mu_0^{-0.1}$;

for $k = 0, 1, \dots$

找到上述子问题的一个解 x_k 满足

$$\|x_k - P(x_k - \nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k), l, u)\| \leq \omega_k;$$

if $\|c(x_k)\| \leq \eta_k$

(% 测试收敛性条件);

if $\|c(x_k)\| \leq \eta_*$ 并且 $\|x_k - P(x_k - \nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k), l, u)\| \leq \omega_*$

stop with 近似解 x_k ;

end(if)

(% 更新拉格朗日乘子, 收紧容忍误差)

$$\lambda^{k+1} = \lambda^k - \mu_k c(x_k), \mu_{k+1} = \mu_k, \eta_{k+1} = \eta_k \mu_{k+1}^{-0.9}, \omega_{k+1} = \omega_k \mu_{k+1}^{-1};$$

else

(% 增加惩罚参数, 收紧容忍误差)

$$\lambda^{k+1} = \lambda^k, \mu_{k+1} = 100\mu_k, \eta_{k+1} = \mu_{k+1}^{-0.1}, \omega_{k+1} = \mu_{k+1}^{-1}$$

end(if)

end(for)

THANKS FOR YOUR ATTENTION